ЛИТЕРАТУРА

1. Халафян А.А. Методы машинного обучения в DATA MINING пакета STATISTICA. М.: Горячая линия – Телеком. 2022г. 260с.
2. Халафян А.А. Методы искусственного интеллекта в медицинских задачах классификации и регрессии. М.: Горячая линия – Телеком, 2023.
3. В. Дюк. Data Mining – интеллектуальный анализ данных https://blog.iteam.ru/data-mining-intellektualnyj-analiz-dannyh/#metaslider_9552
4. Барсегян А.А., Куприянов М.С. и др. Технологии анализа данных. Data Mining, Visual Mining, text Mining. – 2-е изд., перераб. и доп. – СПБ.:БХВ-Петербург, 2007.-384с.
5. Халафян А.А. STATISTICA 6. Статистический анализ данных. М.: Бином, 2009. 528 с.
6. Халафян А.А. STATISTICA 6. Математическая статистика с элементами теории вероятностей. М.: Бином, 2010. 456 с.
7. http://statsoft.ru/products/STATISTICA_Data_Miner/modules-statistica-data-miner.php
8. http://statsoft.ru/home/textbook/modules/stgrowtrees.html
9. STATISTICA Electronic Manual
10. https://neurohive.io/ru/osnovy-data-science/7-arhitektur-nejronnyh-setej-
11. T.Kohonen, "Self-Organizing Maps Springer, 1995.
12. http://mechanoid.kiev.ua/neural-net-kohonen-clusterization.html

ВВЕДЕНИЕ

В современном развивающемся мире неуклонно растут объёмы накопленных данных. Одним из способов их переработки являются современные компьютерные технологии анализа данных, в том числе программа Data Mining в среде пакета STATISTICA.

Термин Data Mining можно перевести как «добыча данных» или «раскопка данных». Нередко под термином Data Mining подразумевают «обнаружение знаний в базах данных» (knowledge discovery in databases) и «интеллектуальный анализ данных» [2].

В настоящее время термин Data mining – собирательное название, используемое для обозначения методов выявления в данных новых знаний, полезных и необходимых для принятия решений в различных сферах человеческой деятельности. Определение этому термину дал Григорий Пятецкий-Шапиро в 1996 году [3]: Data Mining – исследование и обнаружение **"машиной"** (алгоритмами, средствами искусственного интеллекта) в сырых данных скрытых знаний, которые ранее не были известны, нетривиальны, практически полезны, доступны для интерпретации человеком. Присутствие в определении слова «машиной» подразумевает, что в методах Data Mining применяется **машинное обучение**!

Совершенствование технологий сбора, хранения данных позволило накапливать огромные потоки информации в различных областях человеческой деятельности, поэтому применение статистических методов, основанных на парадигме среднего, стало неэффективным. **Одна из причин, та, что в основе прикладной статистики лежат операции над средней арифметической, являющейся по сути, виртуальной величиной** (средняя температура больных в больнице, средняя зарплата граждан по стране и т.д.). Также надо учитывать, то, что существуют ограничения для корректного применения среднего, например, небольшие разбросы, симметричность распределения. Другая причина в **структуре современных данных**, которые могут быть разнородными (количественными, качественными, текстовыми) и неограниченного объема и главное.

С помощью «Добычи Данных» можно обработать исходные данные **путем запуска автоматизированного поиска закономерностей (видимо имеются в виду автоматизированные нейронные сети и программа** Data Miner. Данные шаблоны чаще всего ищутся среди фрагментов неоднородных многомерных данных. Процесс Data Mining подразумевает под собой три последовательных этапа выполнения: **исследование данных, построение модели и ее проверку**. В Data Mining гипотезы формулируются без участия человека, чего не скажешь о традиционных статистических методах и средств для сбора, хранения и анализа многомерных данных в целях поддержки процессов принятия решений [3]. Поэтому, классической математической статистике главным образом свойственна проверка **заранее сформулированных** исследователем гипотез (равенства средних, дисперсий, соответствие нормальному закону и т.д.). В то время как само формулирование гипотезы иногда бывает достаточно сложной и трудоемкой задачей.

Data Mining – это не один, а как уже ранее было отмечено, совокупность различных методов обнаружения знаний, например **классификация**, **кластеризация**, **анализ временных рядов и прогнозирование** и т. д. Выбор метода часто зависит от типа имеющихся данных и от того какую задачу вы планируете решить и какую информацию желаете получить. Важное положение Data Mining в том, что построенные модели должны отражать новые, ранее неизвестные свойства в данных, так называемые **скрытые знания**, которые могут быть использованы для принятия эффективных управленческих решений независимо от области их применения.

.

Data Mining представляют большую ценность для руководителей и аналитиков в их повседневной деятельности. Представители бизнеса и государственных структур осознали, что с помощью методов Data Mining они могут получить ощутимые преимущества в конкурентной борьбе [2].

Технологии Data Mining успешно применяются в **торговле** [2]. Это и анализ покупательской корзины, изучение характера потребностей различных категорий клиентов с определенным поведением, создание товарных запасов.

Data Mining используют в **банковском деле** для решения таких распространенных задач как выявление мошенничества с кредитными карточками, сегментация клиентов, прогнозирование изменений клиентуры. Data Mining помогает банкам строить прогнозные модели потенциала своих клиентов, и соответствующим образом обслуживать каждую категорию.

Data Mining успешно применяют в области **Интернет технологий**, **телекоммуникаций**, **страховании**, **логистики** транспортных и авиакомпаний, **медицине**, **молекулярной генетике**, **прикладной химии**.

Можно продолжить список примеров различных областей знания и практической деятельности, где применимы методы Data Mining. Особенность этих областей заключается в их сложной системной организации, **закономерности которой не могут быть достаточно точно описаны на языке статистических или математических моделей, в том числе и за счет наличия большого количества категориальных предикторов**.

Модели в Data Mining могут иметь графическую иллюстрацию, но в отличии от методов прикладной статистики не имеют аналитической записи, но они могут быть представлены программными кодами в различных средах, по которым несложно написать приложения для автоматизации вычислений.

Data Mining является мультидисциплинарной областью, возникшей и развивающейся на базе достижений прикладной статистики, распознавания образов, методов искусственного интеллекта, теории баз данных, экспертных систем и др. [2] (рис.1.1). Отсюда обилие методов и алгоритмов, реализованных в различных действующих системах Data Mining.

Таким образом, Data Mining это мощный инструментарий для обработки и, анализа данных сложной структуры и его применение в настоящее время весьма актуально.



Рис.1.1. Дисциплины, интегрированные в Data Mining

В пакете STATISTICA Data Mining состоит из широкого спектра модулей, представленных в меню (рис.1.2).

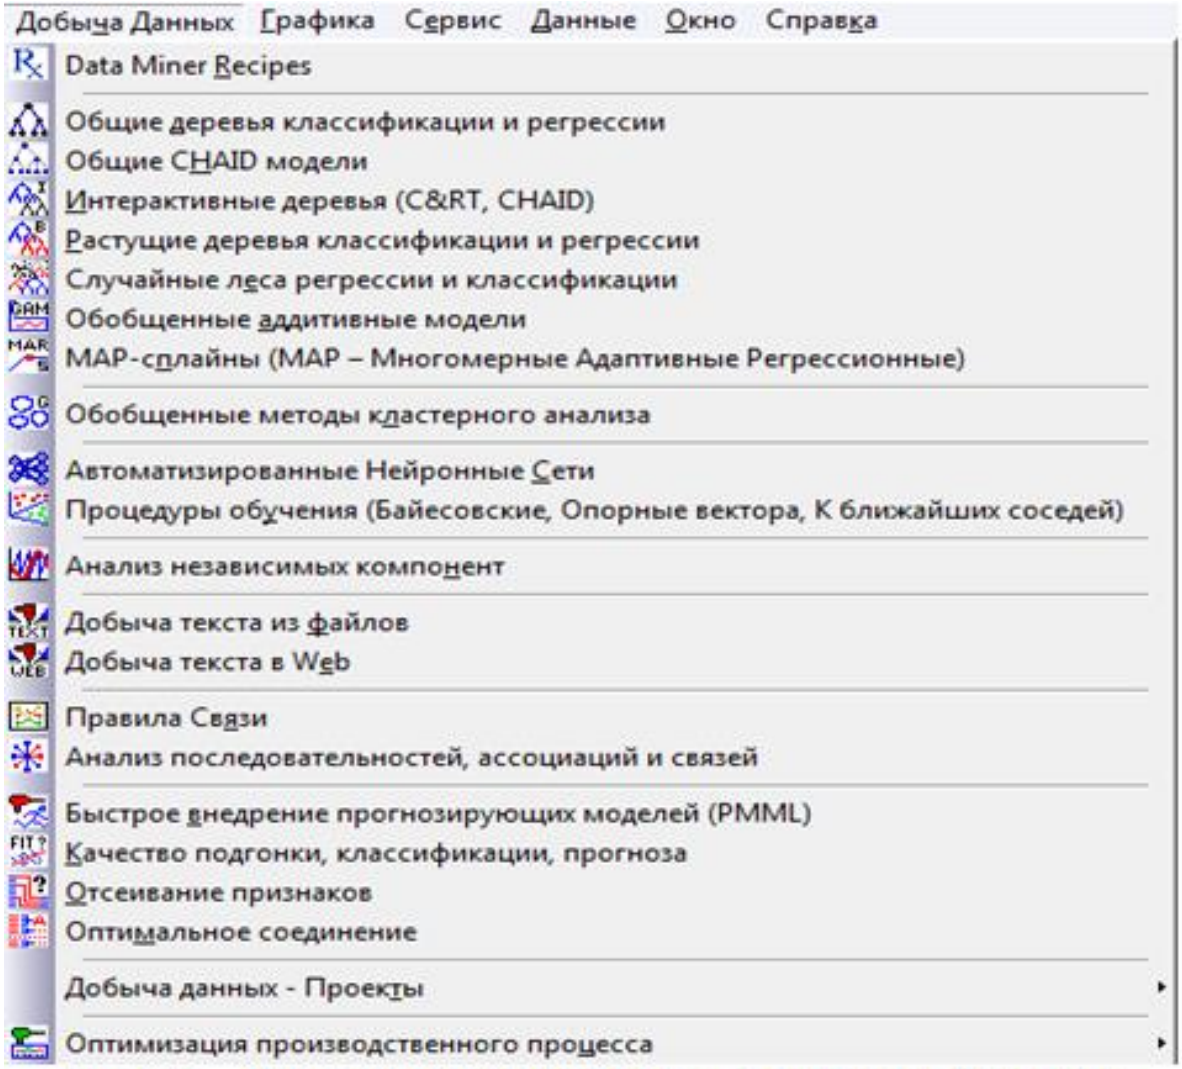


Рис.1.2 – Вкладка Data Mining в программе Statistica

В данном цикле лекций рассмотрена технология работы с модулями Data Mining, имеющими отношение к решению задач классификации. В качестве тренировочного примера использован файл с 153 образцами белых вин марок *Chardonnay* (*Шардоне*), *Riesling* (*Рислинг*), *Muscat* (*Мускат*), произведенных из винограда, выращенного в четырех регионах Краснодарского края – Taman (Таманской), Anapa (Анапской), South foothill (Южно-предгорной), Black Sea (Черноморской) зонах. Количественный состав вин по сортам и регионам произрастания винограда представлен в табл.1.1.

Вина характеризуются концентрациями 15 микроэлементов: *Li*, *Na*, *Mg*, *Al*, *K*, *Ca*, *Ti*, *Mn*, *Fe*, *Ni*, *Cu*, *Zn*, *Rb*, *Sr*, *Ba*. С точки зрения прикладной химии определенный интерес представляет вопрос – определяют ли концентрации микроэлементов группы однородности вин по сортам и регионам произрастания и возможна ли идентификация вин по сортовой и региональной принадлежности. Данная тема является актуальной, так как в наше время мировой рынок вина активно развивается, в связи, с чем немаловажным становится вопрос контроля качества продукции. Совершенствование методов классификации вин по их микроэлементному составу способно помочь в борьбе с их фальсификацией.

Таблица 1.1. Количественный состав вин

Sort	2-Way Summary Table: Observed Frequencies (White wines1) Marked cells have counts > 10				
	Region Taman	Region Anapa	Region South foothill	Region Black Sea	Row Totals
Chardonnay	29	6	13	8	56
Riesling	19	0	12	18	49
Muscat	25	12	5	6	48
Totals	73	18	30	32	153

Литература, использованная при составлении презентаций



