Лекция 2. Деревья решений. Метод C&RT

Деревья решений имеют две разновидности: деревья классификации и деревья регрессии. Это разделение происходит в зависимости от типа целевой переменной. Если целевая переменная является категориальной, дерево решений называют деревом классификации. Если целевая переменная является непрерывной, и необходимо спрогнозировать её количественное значение, то такое дерево именуют деревом регрессии. В обоих случаях предикторами могут быть как количественные, так и качественные переменные.

Привлекательность данного класса алгоритмов объясняется их широкой применимостью, наглядностью и элегантностью решения. Однако не следует полагать, что они во всём превосходят традиционные методы статистики, например дискриминантный анализ. Если выполнены более строгие теоретические предположения, необходимые для классических методов, то более результативным будет их использование. Однако, как метод разведочного анализа, или как последнее средство, когда все прочие алгоритмы оказываются неэффективны, деревья решений, по мнению многих специалистов, не знают себе равных. Также деревья решений – один из самых подходящих методов для графического представления и интерпретации результатов. О данных, организованных в виде древовидной структуры, гораздо проще вынести некоторое заключение, чем об их аналоге, представленном в числовой форме.

Деревья решений имеют несколько свойств:

1. **Иерархичность**. Вопросы, позволяющие отнести некоторый объект к конкретному классу, задаются последовательно, и окончательное решение зависит от ответов на все предшествующие вопросы. Благодаря этому мы имеем возможность последовательно изучать эффекты отдельных предикторов;

2. Гибкость. В процессе построения дерева решений можно работать с предикторными переменными различных типов, как количественных, так и качественных. К примеру, при определении риска смертности кровяное давление и возраст пациента являются непрерывными предикторами, а наличие или отсутствие тахикардии – категориальным;

3. Многомерность ветвлений. Деревья решений не ограничены использованием только одномерных ветвлений, т.е. ветвлений по одной переменной: если непрерывные предикторы измерены в интервальной шкале, то деревья классификации могут использовать ветвления и по их линейным комбинациям. Это выгодно в тех случаях, когда имеется много категорий, но мало непрерывных предикторов. Например, определение номинала монетки по её диаметру и толщине. Если не будет успешным ветвление по этим двум предикторам, то можно попробовать ветвление по новой переменной, являющейся их линейной комбинацией;

4. Неограниченность ветвлений. Одним из важнейших преимуществ перед другими инструментами анализа в подобных ситуациях является отсутствие ограничений на количество одномерных ветвлений и ветвлений по линейным комбинациям.

Для лучшего понимания, что такое Дерево решений, рассмотрим пример дерева, представленный на рис.2.1:

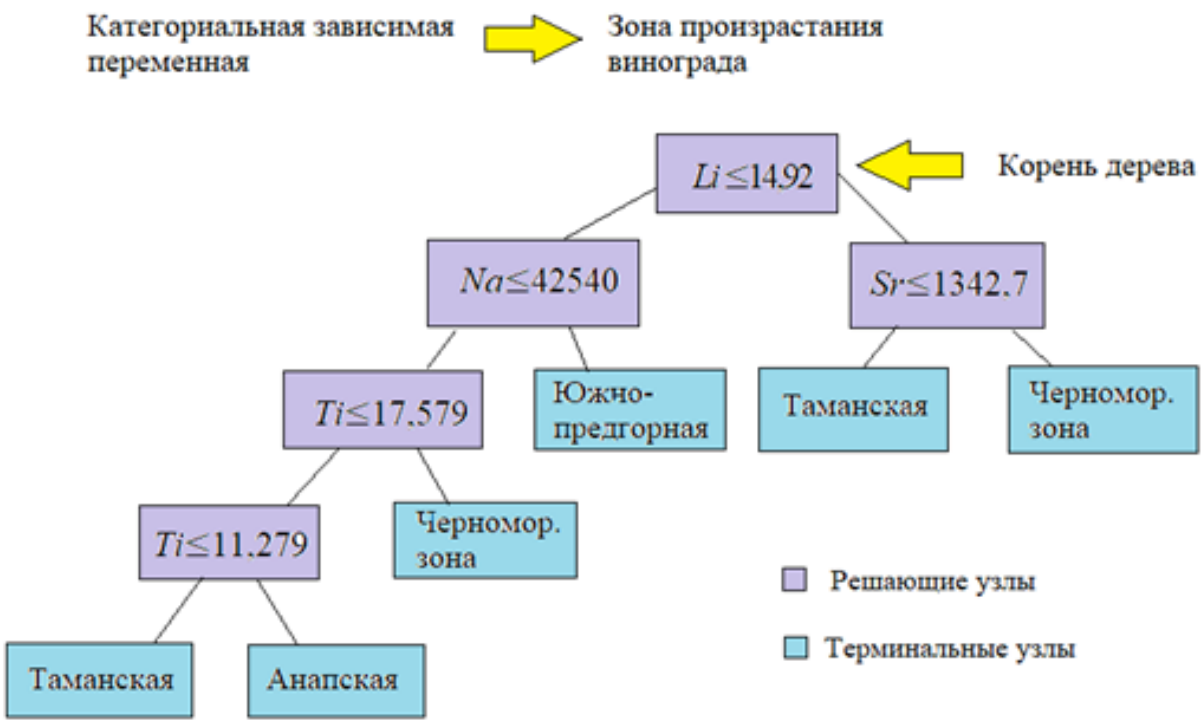


Рис.2.1 – Дерево решений для определения зоны произрастания винограда

Откликом является категориальная переменная, принимающая 4 значения, соответствующие Таманской, Черноморской, Анапской и Южно-предгорной зонам. В качестве предикторов выступают микроэлементы Li, Na, Sr, Ti. Они являются непрерывными величинами. Если бы мы в качестве независимой переменной использовали так же и сорт винограда, то сорт был бы качественным предиктором. Началом дерева считается самая верхняя решающая вершина, которую иногда также называют корнем дерева. Данное дерево имеет 5 ветвлений и 6 терминальных вершин. Узлы дерева разделяются на решающие и терминальные. Терминальные узлы (листья) это вершины дерева, начиная с которых никакие решения больше не принимаются. Различные типы вершин на рисунке имеют различные цвета. Если выполнено условие ветвления, то к новой вершине переходим по левой ветви, в противном случае – по правой ветви.

Метод Деревья решений имеет следующие преимущества:

– при небольшом дереве результаты наглядно представляются в виде графа дерева доступного для понимания;

– можно работать с большим числом предикторов, алгоритм сам выберет среди них те, которые обладают наибольшей значимостью для построения дерева;

– моделируют нелинейные взаимосвязи, что довольно сложно осуществить в стандартных статистических моделях;

– отсутствуют ограничения на типы переменных, которые могут быть количественными и категориальными;

– устойчивы к пропущенным значениям, так как используют собственные процедуры обработки пропусков.

Недостатки деревьев решений:

– в отличие от методов регрессионного анализа отсутствует уравнение прогноза, выражающего модель;

– некоторые методы деревьев решений, переобучаясь, строят чересчур детализированные иерархические структуры, которые сложны для восприятия и часто могут давать неверные результаты для тестовых данных;

– перед ветвлением узла дерево сравнивает различные варианты разбиения, число этих вариантов зависит от числа уровней предикторов, и, как правило, может привести к множественности сравнений;

– небольшие изменения в наборе данных могут приводить к построению совершенно другого дерева. В силу иерархичности дерева изменения в верхних узлах ведут к изменениям во всех узлах, расположенных ниже.

Следует отдельно заметить об одном несомненном преимуществе реализации деревьев решений в Data Mining пакета Statistica – возможен экспорт алгоритма классификации дерева в виде программного кода на следующих языках программирования: PMML; Statistica Visual Basic (SVB); C/C++; C#; Java; SAS и др. Используя программный код легко автоматизировать процедуру классификации объектов любой природы.

В Data Mining пакета STATISTICA реализовано несколько видов деревьев решений. Рассмотрим способы работы с некоторыми из них.

Метод General Classification and Regression Trees

Пакет STATISTICA содержит множество алгоритмов для прогнозирования непрерывных или категориальных **целевых** переменных на основе набора непрерывных и / или категориальных предикторов. Например, в модуле GLM (общие линейные модели) и GRM (общие регрессионные модели) можно строить линейные модели для прогнозирования непрерывной зависимой переменной. В модуле GDA (Общий дискриминантный анализ) можно прогнозировать значения категориальных переменных, то есть решать задачи классификации. **Все упомянутые методы предполагают построение моделей в виде уравнений**.

Метод STATISTICA General Classification and Regression Trees (C&RT) предназначен для построения деревьев классификации и регрессии, прогнозирующих непрерывную зависимую переменную (задача регрессии), или значения категориальной переменной (задача классификация наблюдений, объектов). **При этом прогностическая модель представляет собою алгоритм ветвления в соответствии с построенным деревом**. Одноименный модуль в Data Mining поддерживает классический алгоритм C&RT, популяризированный Брейманом и др. для обрезки деревьев при проведении v-кратной кросс-проверки для выбора оптимального дерева как компромисса между трудоемкостью и точностью.

Для реализации модуля следует воспользоваться разделом General Classification and Regression Trees (Общие деревья классификации и регрессии) в Data Mining (рис.2.1.2). Откроется окно, в котором следует указать тип анализа и метод, которые и выберем по умолчанию, как это представлено на рис.2.1.3.

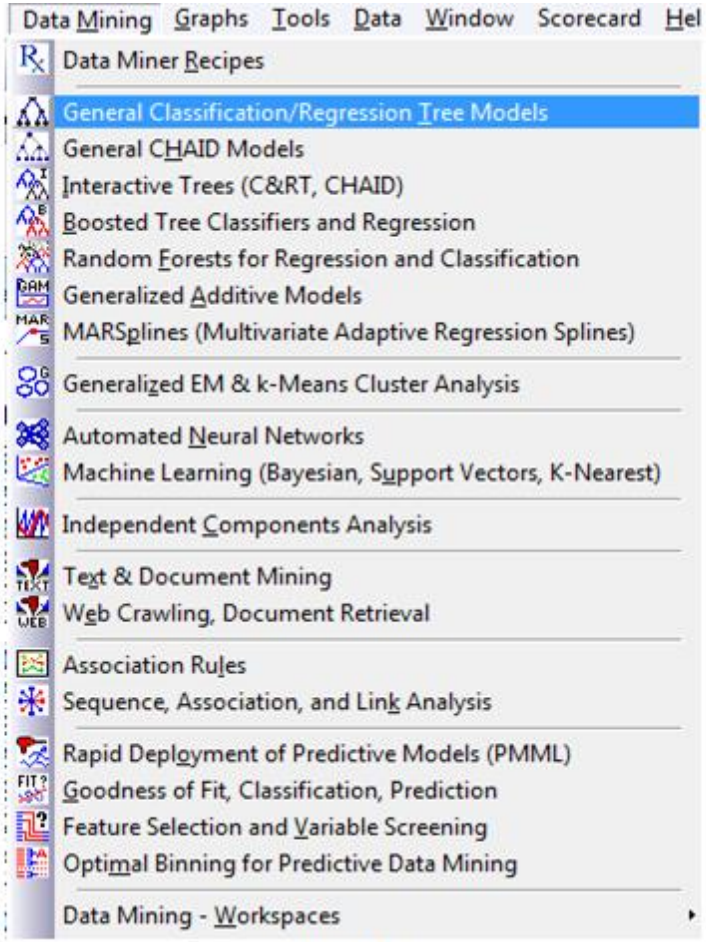


Рис.2.1.2

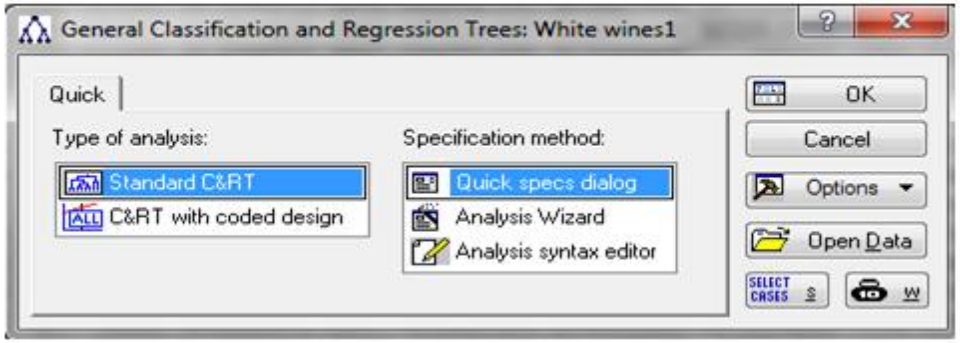


Рис.2.1.3

Различия между двумя типами анализа мы разъясним несколько позже. Работу с модулем традиционно следует начать с вкладки Quick, воспользовавшись кнопкой Variables. Если мы планируем построение регрессионной модели, то в поле Dependent в качестве зависимой переменной следует выбрать непрерывную величину (рис.2.1.4). Переменные в списке 1 и 2 должны содержать текстовые или числовые коды, которые идентифицируют классы или группы, к которым относится каждое наблюдение (в нашем случае образец винограда). Четвертый список не обязателен, предназначен для переменных, которые могут быть использованы, если входные данные агрегированы. В 3 списке следует указать непрерывные предикторы. Для большей полноты описания реализации метода в качестве зависимой переменной – отклика выберем категориальную величину Region, независимыми переменными – предикторами: количественные переменные, представленные концентрациями 15 металлов; и категориальную переменную Sort.

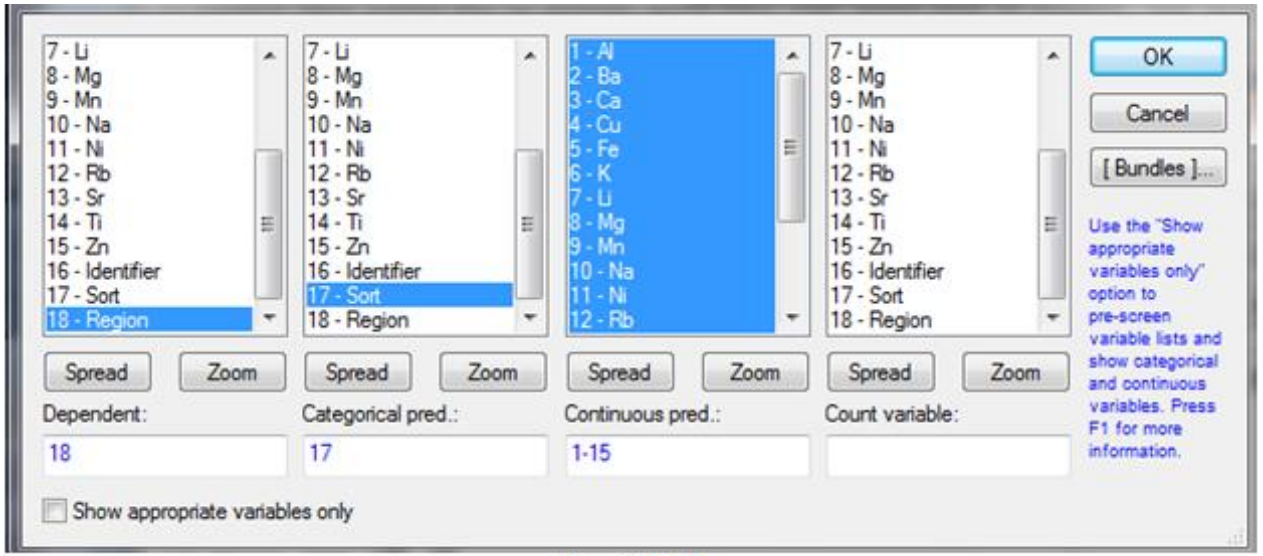


Рис.2.1.4

В модуле не предусмотрено автоматическое выделение тестовой выборки, ее следует задать при помощи переменной идентификатора, которая присвоит специальные коды для объектов обучающей, например 1, и тестовой выборки, например 0. После реализации ранее описанных действий вкладка Quick стартового окна примет вид, представленный на рис.2.1.5.

Для того чтобы программа восприняла зависимую переменную как категориальную, и решала задачу классификации, следует установить флажок на Categorial response. В противном случае, программа коды, присвоенные текстовым значениям категориальной переменной, будет воспринимать как значения непрерывной величины, и решать задачу регрессионного анализа. Аналогично, если выбранная зависимая переменная является непрерывной и установлен флажок Categorial response, зависимая переменная будет считаться категориальной. После выделения опции Categorial response станет активной кнопка Response codes.

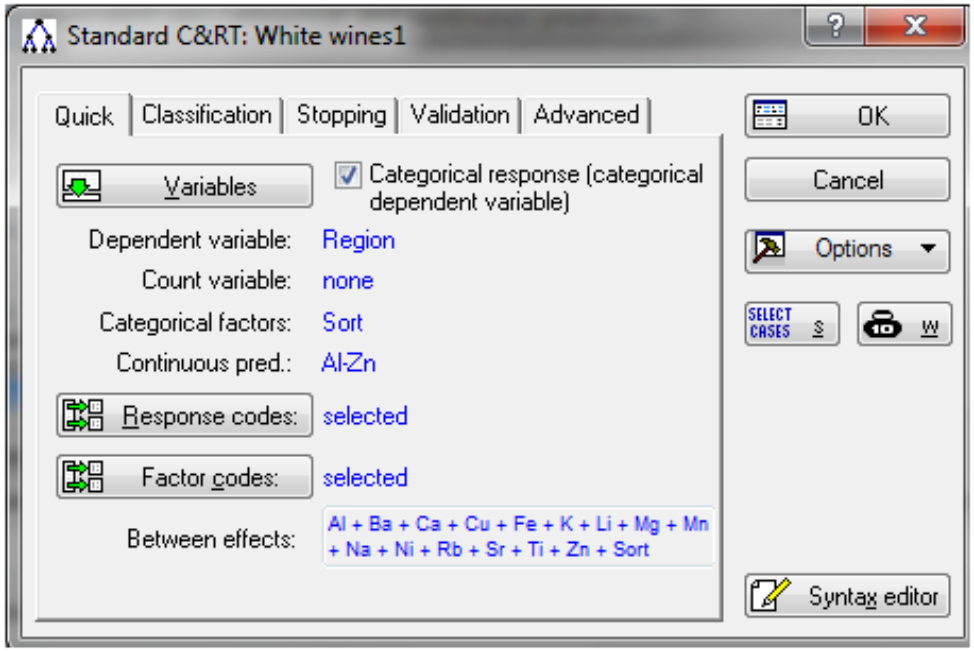


Рис.2.1.5.

Если при выделенной опции Categorial response на рис.2.1.5 в нижней левой части окна на рис.2.1.4 установить флажок на опцию Show appropriate variables only (показывать только соответствующие переменные), то программа самостоятельно в первых двух списках укажет только категориальные переменные, а в двух оставшихся – непрерывные (рис.2.1.6).

Если опция Categorial response не выделена, то программа выберет категориальные переменные только во втором списке, а в первом и третьем будут указаны непрерывные переменные. Собственно возможностью строить деревья регрессии в основном и отличается метод стандартный C&RT, реализованный в Data Mining, от реализованного в меню Statistics в разделе Multivariate Exploratory Techniques. Если дерево классификации предполагается строить для всех классов категориальной переменной – отклика, то программа автоматически выберет все коды (классы). В противном случае, следует щелкнуть по кнопке Response codes и при помощи кнопки Zoom выбрать надлежащие коды (классы).

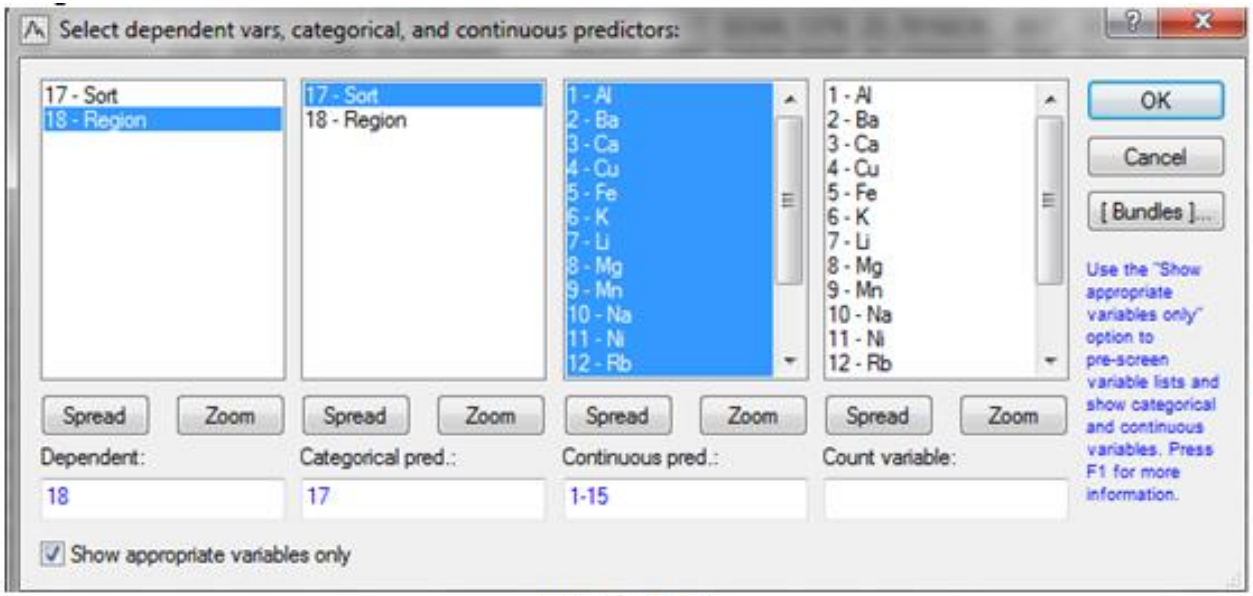


Рис.2.1.6

В нижней части окна на рис.2.1.5 в поле рядом с текстом Between effects показан текущий «дизайн» анализа, который в данном случае представляет собой простую комбинацию выбранных непрерывных и категориальных предикторов. При выборе в диалоговом окне на рис.2.1.3 метода C&RT with coded design (с закодированным дизайном), кнопка Between effects станет активной. Если щелкнуть по ней, то откроется окно (рис.2. 1.7), в котором можно указать ANOVA / ANCOVA-подобный дизайн для предикторных переменных, т.е. их произвольную комбинацию.

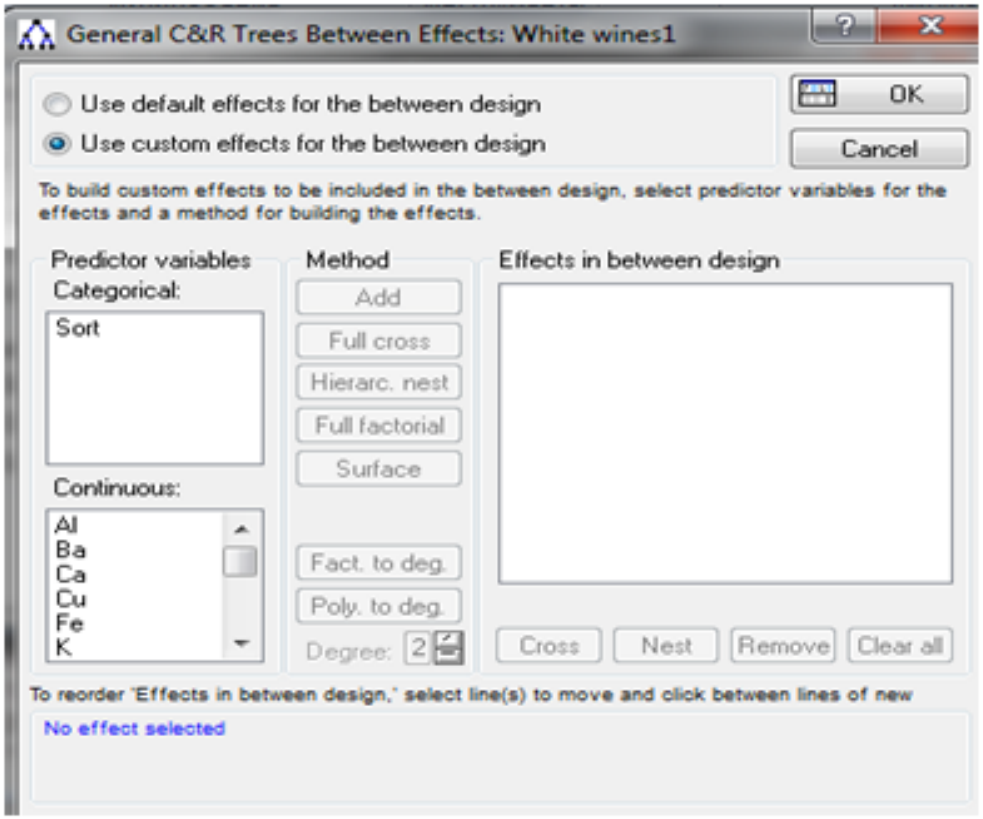


Рис.2.1.7

Вкладка Classification (рис.2.1.8) детально описана в учебных пособиях по многомерному анализу (см. последний слайд) и мы с нею знакомились на предыдущем курсе. Поэтому, здесь лишь коротко заметим, что в рамке Misclassification Costs при помощи опции *User spec* можно задать цену ошибок классификации для каждого класса, в нашем случае регионов произрастания винограда. Кнопка активна, если на вкладке Quick выбраны коды отклика и предикторов. При отличии приоритетов правильной классификации у различных классов по умолчанию принята одинаковая цена – Equal. Это означает, что все недиагональные элементы матрицы цен ошибок классификации (прогнозируемые классы – по строкам, наблюдаемые классы – по столбцам) полагаются равными 1.

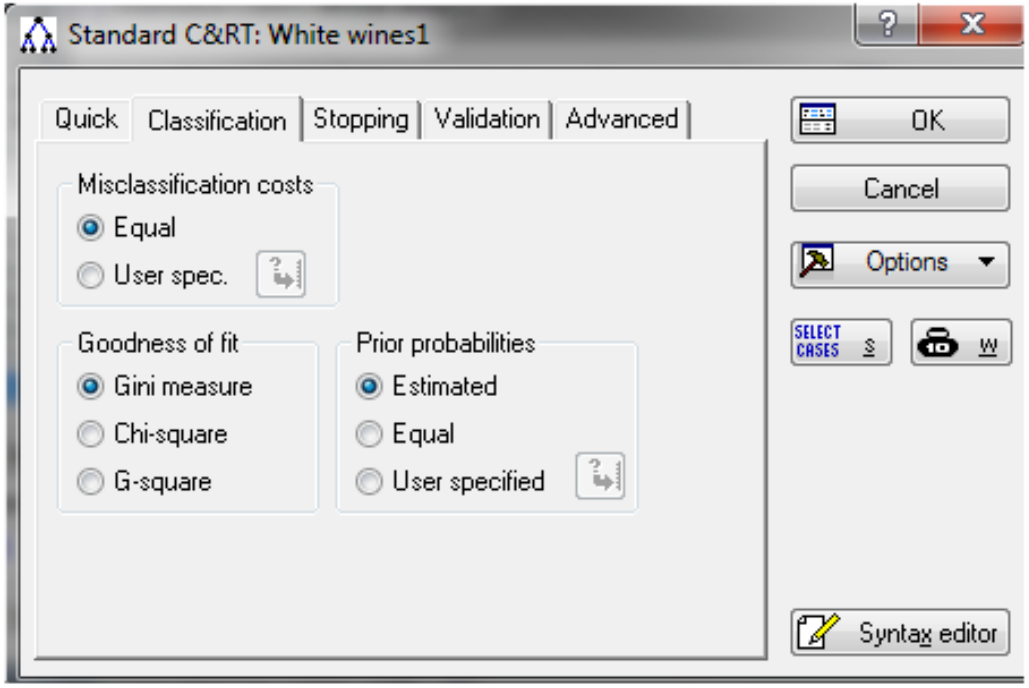


Рис.2.1.8

Класс	Класс Taman	Класс Anapa	Класс South foothill	Класс Black Sea
Taman		1	1	1
Anapa	1		1	1
South foothill	1	1		1
Black Sea	1	1	1	

- В рамке Goodness of fit пользователь для выбора **наилучшего из всех возможных вариантов ветвления** может выбрать критерий согласия в виде одной из трех возможных мер: Gini measure (мера Джини), Chi–square (мера χ^2 Бартлета) и G–square (G^2 мера максимума правдоподобия).
- В рамке Prior probabilities можно задать способ вычисления априорных вероятностей, которые показывают, насколько мы, не зная ничего о значениях предикторных переменных, считаем вероятным, что объект будет принадлежать определенному классу. **Можно** заметить, что если априорные вероятности выбраны пропорционально численности классов, а цена ошибки классификации – одинаковая для всех классов, то минимизация потерь в точности эквивалентна минимизации доли неправильно классифицированных наблюдений.

Выбор априорных вероятностей существенно влияет на результаты классификации. Если различия между исходными частотами в данной задаче не считаются существенными, или если мы знаем заранее, что классы содержат примерно одинаковое количество наблюдений, то тогда можно взять одинаковые априорные вероятности (*Equal*). В случаях, когда исходные частоты связаны с размерами классов (например, при работе со случайной выборкой), следует в качестве оценок для априорных вероятностей взять относительные размеры классов в выборке (*Estimated).* Наконец, если (на основании данных предыдущих исследований) располагаем какой-то информацией об исходных частотах, то априорные вероятности нужно выбирать с учетом этой информации (*User spec*).

На вкладке Stopping (рис.2.1.9) в рамке Stopping rule (правило остановки) реализованы три варианта остановки: Prune on misclassification error (отсечение по ошибке классификации), Prune on deviance (отсечение по вариации), и Fact–style direct stopping (прямая остановка по методу *FACT*).

При выборе первых двух правил в рамке Stopping parameters (параметры остановки) активизируется **только** опция *Minimum n of cases*. Она используется для управления моментом, когда прекращается отсечение. Ветвление продолжается до тех пор, пока все терминальные вершины дерева классификации не станут «чистыми» (т.е. не будут содержать неправильно классифицированных наблюдений). Усечение дерева прекращается, когда все терминальные вершины будут содержать не более чем заданное минимальное число неправильно классифицированных наблюдений.

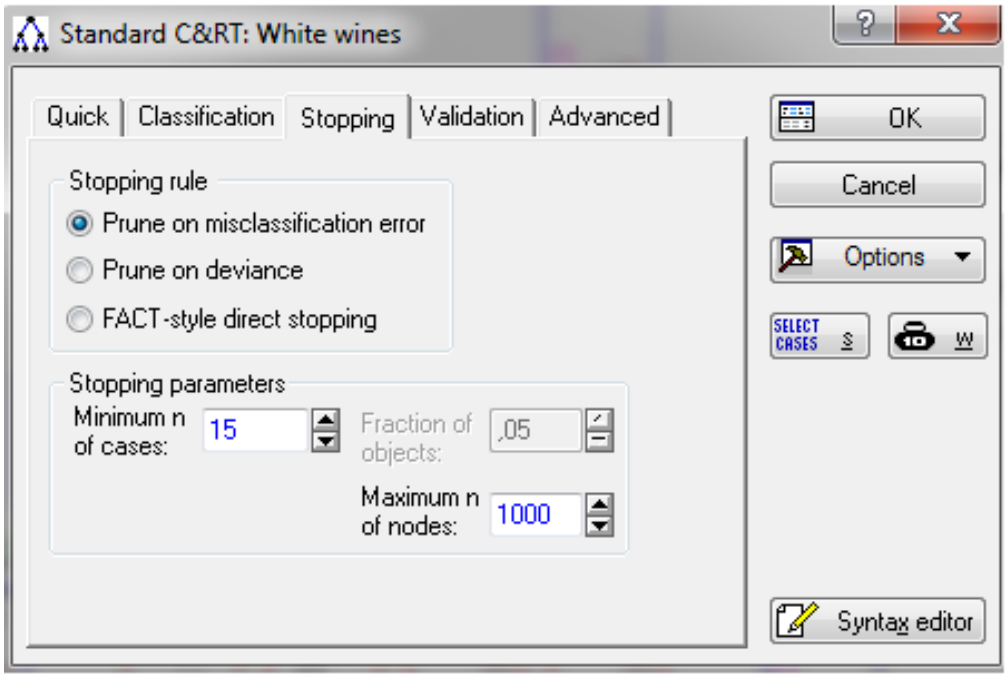


Рис.2.1.9

В опции Fact–style direct stopping отсечение продолжается до тех пор, пока в каждой терминальной вершине дерева классификации доля ошибочных классификаций классов не станет больше заданной в поле ввода Fraction of objects (доля неклассифицированных объектов) величины.

Параметр Maximum n nodes контролирует общее количество узлов в дереве, по умолчанию назначено достаточно большое значение – 1000. Экспериментально можно убедиться, что максимально возможное значение равно 9999.

Для возможности построения адекватной модели классификации в методе предусмотрено проведение v-кратной кросс-проверки (v-fold cross validation), при которой выборка виртуальным образом делится на V частей, после чего V раз происходит построение модели и усреднение полученных решений. При этом в каждом этапе построения участвует V–1 часть, а на оставшейся части выполняется тестирование. По умолчанию V =10, данные при помощи датчика случайных числе делятся на 10 частей (рис.2.1.10), из которых 9 используются для построения, и одна для оценки корректности. Программа перебирает различные варианты разбиений, для каждого из которых строит дерево и выбирает из них то, которое даёт наилучший результат. Наилучшим результатом считается то дерево, которому соответствует наименьшая цена ошибочной классификации, которая определяется как доля ошибочно классифицированных деревом наблюдений. Для задания перекрестной проверки следует перейти на вкладку Validation (рис.2.1.10), выделив соответствующую опцию.

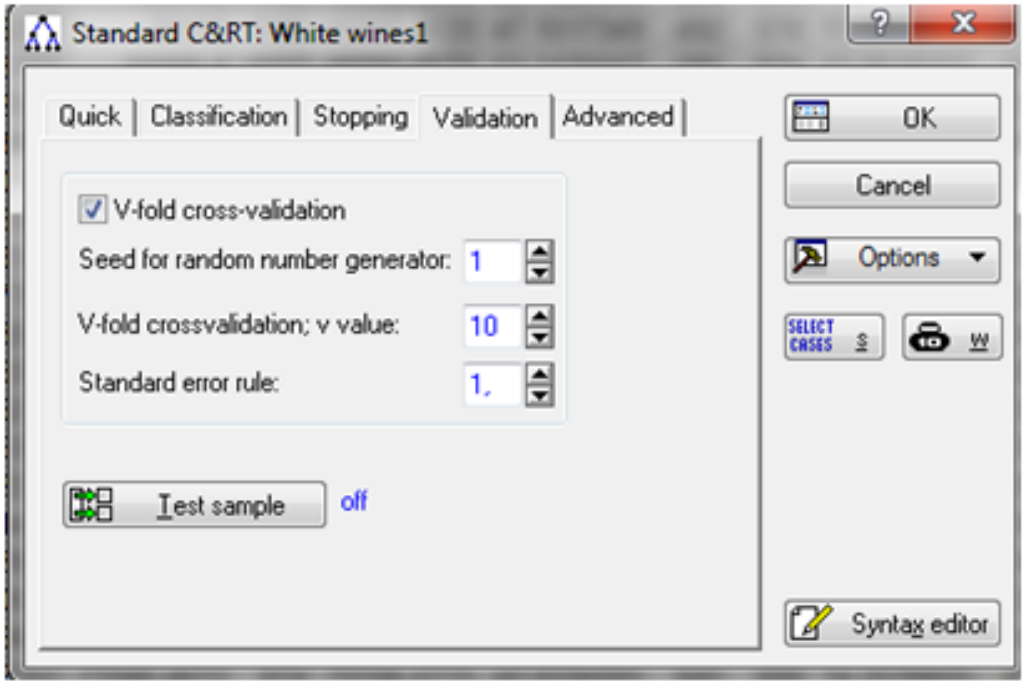


Рис.2.1.10

Проведение V-кратной кросс-проверки (перекрестной проверки) возможно только, если в окне на рис.2.1.9 выбрана опция **Prune on misclassification error**. Целесообразно применение перекрестной проверки, если объем выборки мал и недостаточен для выделения ее части для обучающей и тестовой выборки!!!

Чтобы использовать тестовую выборку следует предварительно создать переменную идентификатор, назовем ее Identifier, которая определит какие наблюдения (образцы вин) принадлежат обучающей выборке (training), а какие тестовой (test). Нами были заданы значения переменной таким образом, чтобы объем ее был невелик и в состав тестовой выборки вошли образцы вин со всех регионов и естественно представляли все сорта (табл.2.1.1.).

Таблица 2.1.1. Таблица частот для тестовой и обучающей выборк

Summary Frequency Table (White wines1)
Marked cells have counts > 10
(Marginal summaries are not marked)

Identifier	Sort	Region Taman	Region Anapa	Region South foothill	Region Black Sea	Row Totals
test	Chardonnay	2	1	2	1	6
test	Riesling	2	0	2	2	6
test	Muscat	2	2	1	1	6
Total		6	3	5	4	18
training	Chardonnay	27	5	11	7	50
training	Riesling	17	0	10	16	43
training	Muscat	23	10	4	5	42
Total		67	15	25	28	135
Column Total		73	18	30	32	153

Здесь же в диалоге на рис.2.1.10 можно активизировать проверку на тестовой выборке, щелкнув по одноименной кнопке. В открывшемся окне (рис.2.1.11) при помощи кнопки Sample Identifier Variables следует указать имя переменной идентификатора Identifier и код (1) для выбора наблюдений обучающей выборки и обязательно выделив опцию On, включить проверку построенного дерева на тестовой выборке.

Последняя вкладка Advanced (дополнительно) (рис.2.1.12) предназначена для построения дерева решений при наличии пропущенных значений, количество которых можно указать в поле Number of surrogate (число замен), и использования сигма-ограниченной параметризации, установив флажок на одноименной опции Sigma-restricted parameterization. Сигма-ограниченная параметризация применяется для кодирования категориальных предикторов (факторов), если они используются в дереве решений, по аналогии как это делается в Общих линейных моделях.

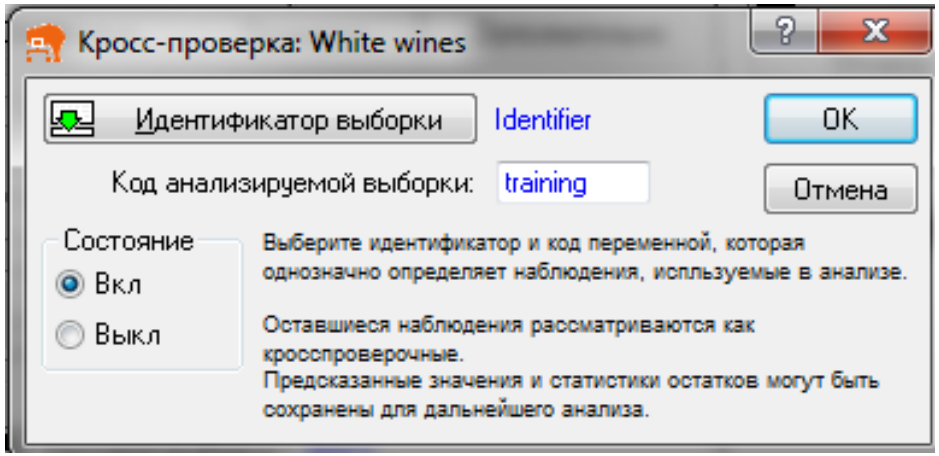


Рис.2.1.11

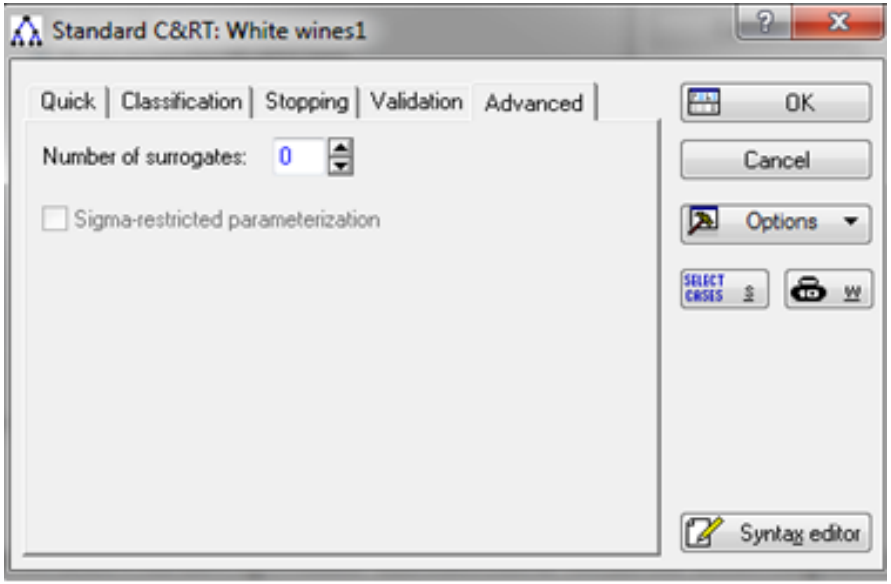


Рис.2.1.12

После детального описания всех опций модуля можем перейти к практической реализации метода. При выборе зависимой переменной Region, непрерывными предикторами – все 15 наименований микроэлементов (без выбора предиктора Sort) и при установке всех опций модуля по умолчанию без перекрестной проверки и тестовой выборки удалось построить дерево классификации с 11 терминальными вершинами с нулевым количеством ошибок классификации обучающей выборки (см. рис.2.1.13 – кнопка Tree graph и рис.2.1.14 кнопка Predicted observed ….).

При включении проверки на тестовой выборке и активизации кросс проверки было построено дерево с 9 терминальными вершинами, но с 9 и 3 ошибками соответственно на обучающей и тестовой выборке.

Улучшить прогностические способности дерева удалось при назначении *Minimum n* =2 в рамке Stopping parameters (параметры остановки) на вкладке Stopping (рис.2.1.9). Было построено дерево с 13 терминальными вершинами, но с 0 и 2 ошибками соответственно на обучающей и тестовой выборке.

Попробуем еще более улучшить точность прогнозирования, выбрав дополнительно в качестве фактора категориальную переменную Sort (рис.2.1.4). Остальные установки произведем в соответствии с окнами на рис.2.1.8-2.1.12 и разберем работу с вкладками окна результатов (рис.2.1.13, 2.1.14).

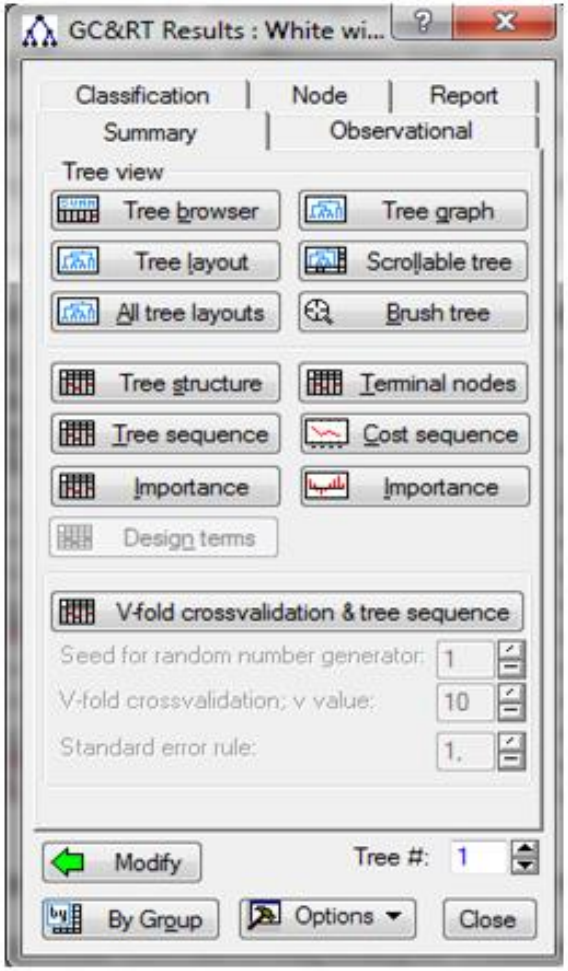


Рис.2.1.13

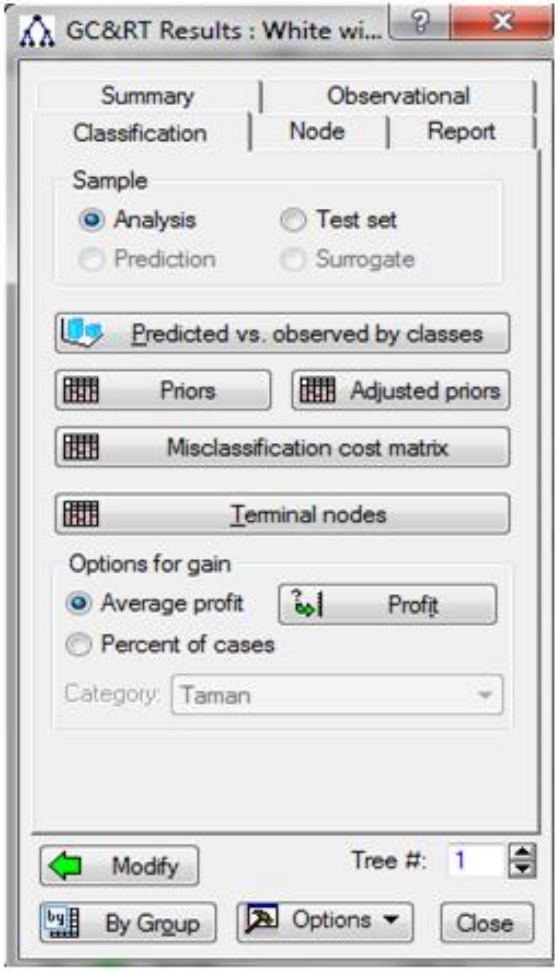


Рис.2.1.14

Для визуализации графа лучшего из построенных модулем дерева решений, воспользуемся кнопкой Tree graph на вкладке Summary. Как видно на рис.2.1.15, даже при не очень большом количестве вершин – 25, из которых 13 терминальные, 12 нетерминальные вершины, прочитать рисунок весьма проблематично.

Поэтому разработчиками предложено несколько дополнительных кнопок для анализа построенного дерева решений. Кнопка Tree browser позволяет фрагментарно визуализировать каждую вершину дерева, предварительно выделив ее на схеме слева (рис.2.1.16). На рисунке появится подробная информация о вершине: номер вершины, количество объектов, номер правой и левой ветви, исходящих из вершины, условие бинарного ветвления в виде неравенства, количественный состав в классах. Кнопка Tree layout показывает структуру нумерации вершин дерева.

Кнопка Scrollable tree строит граф дерева с вертикальными и горизонтальными прокрутками, обеспечивающими возможность в увеличенном формате легко прочитать все надписи, как на ветвях, так и в вершинах дерева, т.е. досконально визуализировать граф дерева решений.

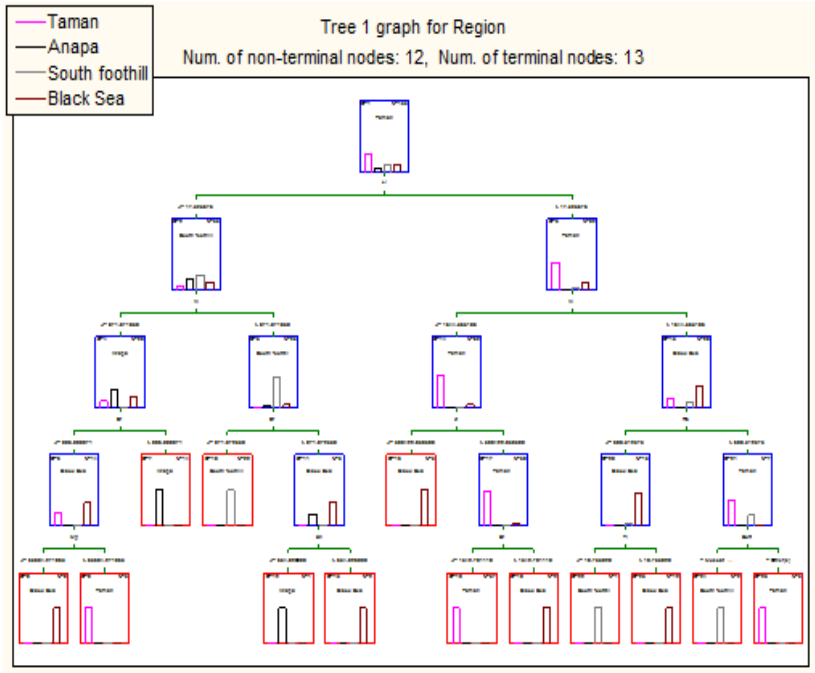


Рис.2.1.15

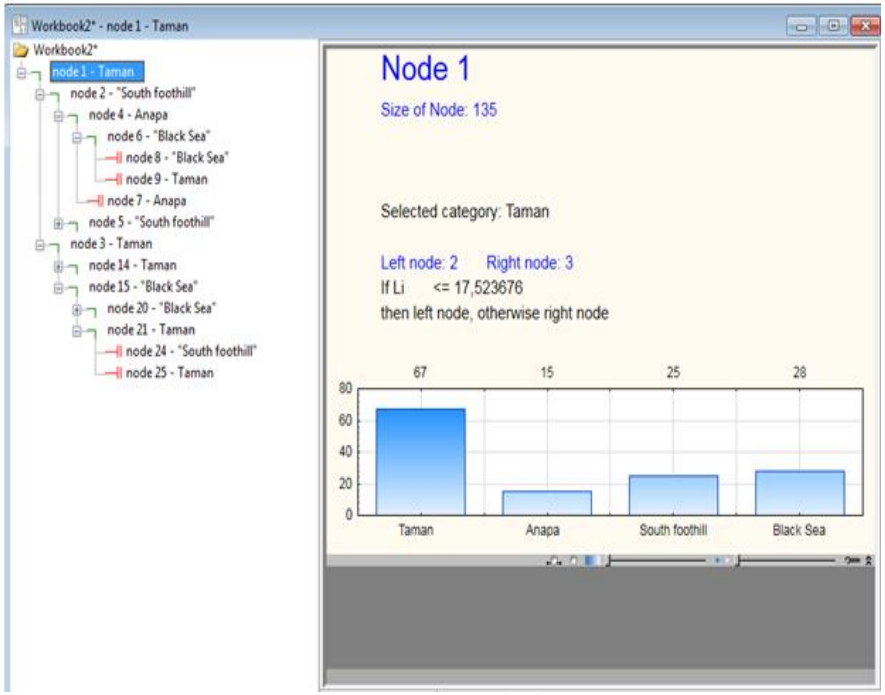
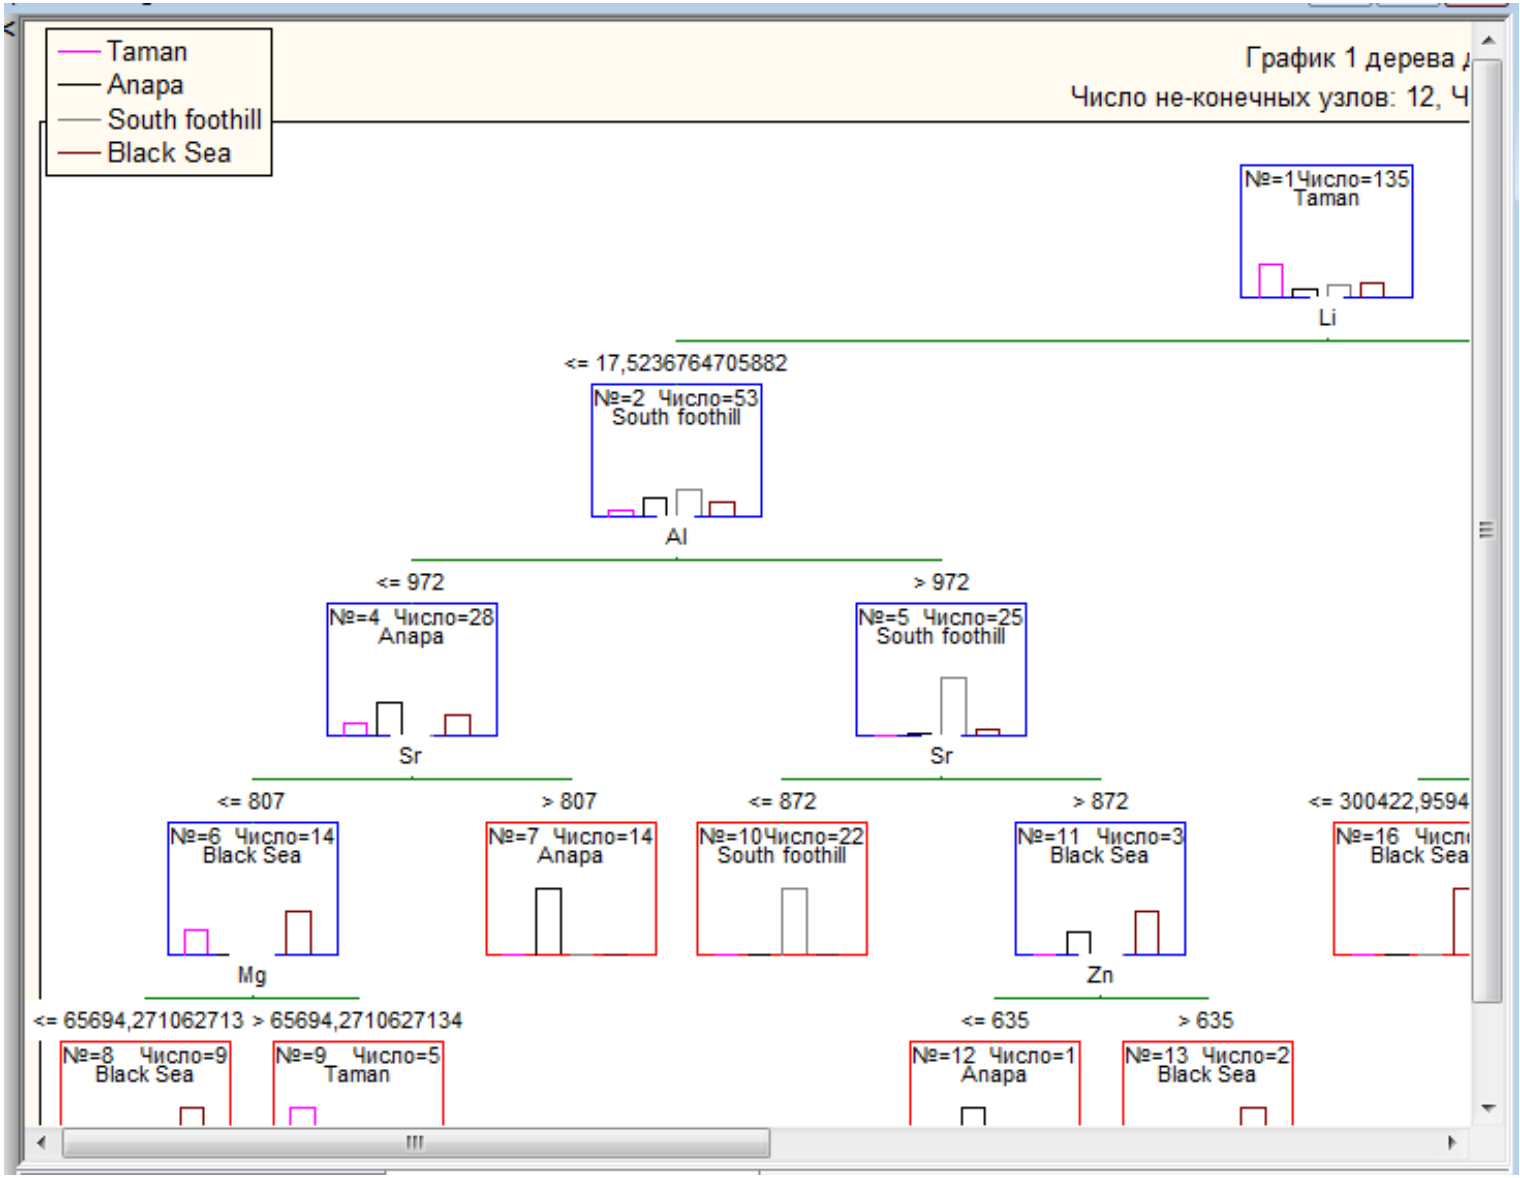


Рис.2.16


Taman
Anapa
South foothill
Black Sea
№=1Число=135
Taman
Li
<= 17,5236764705882
№=2 Число=53
South foothill
Al
<= 972
№=4 Число=28
Anapa
Sr
> 972
№=5 Число=25
South foothill
Sr
<= 807
№=6 Число=14
Black Sea
Mg
> 807
№=7 Число=14
Anapa
<= 872
№=10Число=22
South foothill
> 872
№=11 Число=3
Black Sea
Zn
<= 300422,9594
№=16 Числ
Black Sea
<= 65694,271062713
№=8 Число=9
Black Sea
> 65694,2710627134
№=9 Число=5
Taman
<= 635
№=12 Число=1
Anapa
> 635
№=13 Число=2
Black Sea

Если нажать на кнопку All tree layout программа построит каскад последовательно усеченных деревьев (рис.2.1.17). Легко заметить, что это варианты последовательного усечения одного и того же дерева, древовидная структура вершин которого представлена вверху слева.

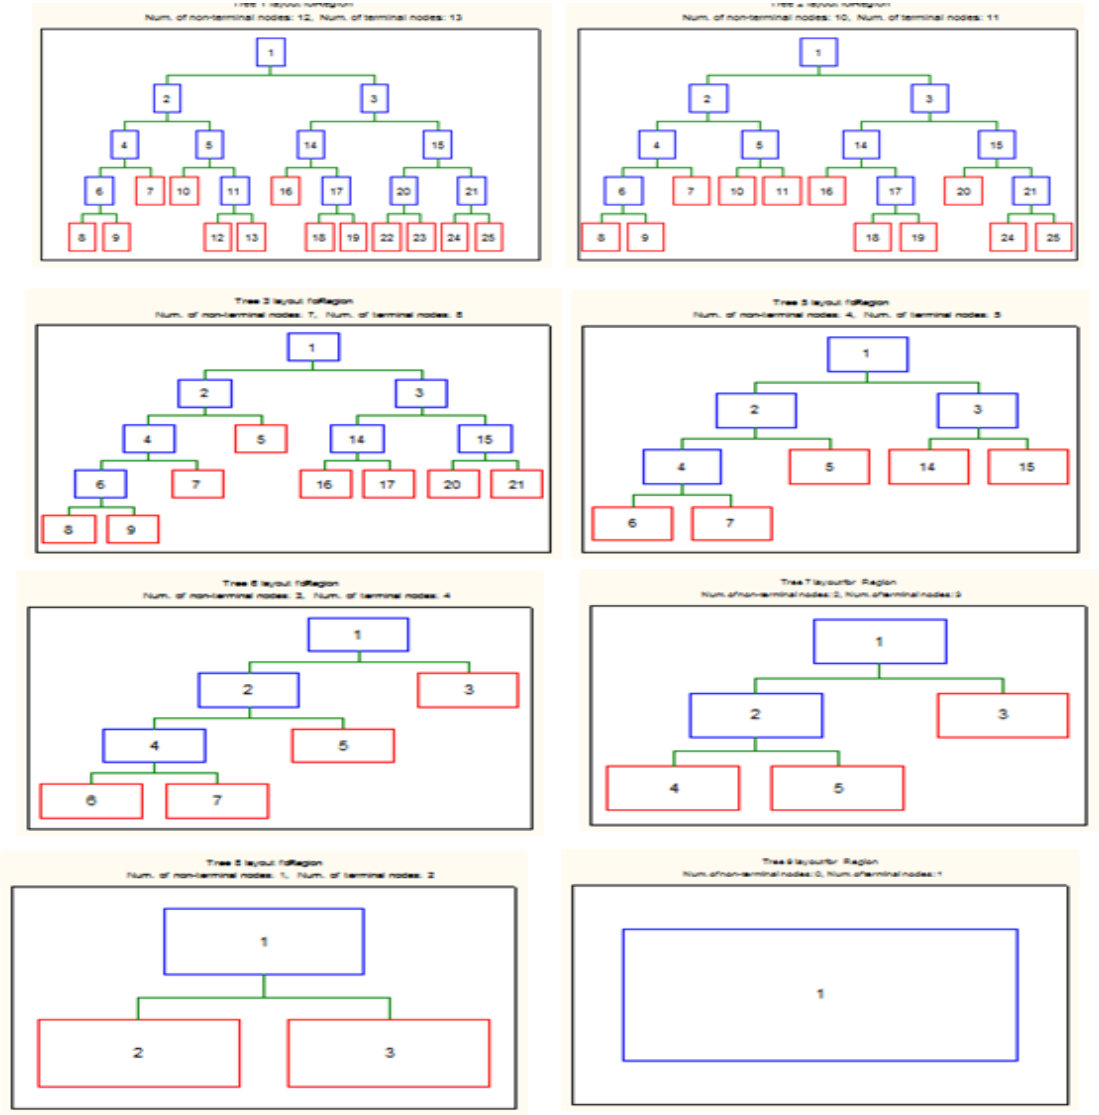


Рис.2.1.17

Структура дерева достаточно проста, первая вершина (рис.2.1.16) содержит все 135 образцов вин в соответствии с объемом обучающей выборки. Программа условно отнесла их к группе вин произведенных в Таманской зоне. Условие ветвления: если Li ≤ 17,523676, то переходим по левой ветви к вершине (2), в противном случае – по правой ветви к вершине (3). В верхней части записан номер вершины, ниже по центру – регион к которому модуль отнес образцы вин. Гистограммы условно изображают частоту регионального состава. Терминальные вершины обозначены красным цветом. При помощи кнопки Terminal nodes можно построить таблицу только терминальных вершин, строки которой обозначают номер вершины, а в столбцах с названиями регионов указано количество образцов вин данного региона, содержащихся в терминальной вершине (табл.2.1.2).

Таблица 2.1.2. Терминальные вершины

Node #	Result of terminal nodes 1 (White wines1) Dependent variable: Region Options: Categorical response, Tree number 1				
	Class Taman	Cla ss Anapa	Class South foothill	Class Black Sea	Gain
8	0	0	0	9	9,00000
9	5	0	0	0	5,00000
7	0	14	0	0	14,00000
10	0	0	22	0	22,00000
12	0	1	0	0	1,00000
13	0	0	0	2	2,00000
16	0	0	0	3	3,00000
18	57	0	0	0	57,00000
19	0	0	0	2	2,00000
22	0	0	1	0	1,00000
23	0	0	0	12	12,00000
24	0	0	2	0	2,00000
25	5	0	0	0	5,00000

Кнопка Three structure позволяет представить всю выше изложенную информацию о дереве в табличной форме (табл.2.1.3). Из таблицы видно, что лучшее из построенных программой деревьев решений для классификации образцов вин (дерево №1) из 15 микроэлементов использует лишь 8 – это Li, Al, Sr, Mg, Zn, K, Rb, Ti и категориальный фактор Sort. Причем данный фактор используется при расщеплении (разбиении) вершины 21 на две последние терминальные вершины 24 и 25 по правилу: если сорт вина Мускат, то виноград произведен в Южно-предгороной зоне, если не Мускат, то – в Таманской зоне. По сути, граф дерева решений на рис.2.1.15 и 4 последних столбца таблицы задают алгоритм идентификации региона произрастания винограда.

Таблица 2.1.3. табличное представление дерева решений

Node	Tree structure 1 (White wines1) Dependent variable: Region Options: Categorical response, Tree number 1										
	Left branch	Right branch	Size of node	N in class Taman	N in class Anapa	N in class South foothill	N in class Black Sea	Selected category	Split variable	Split constant	Split category
1	2	3	135	67	15	25	28	Taman	Li	17,5	
2	4	5	53	5	15	22	11	South foothill	Al	972,0	
4	6	7	28	5	14	0	9	Anapa		807,0	
6	8	9	14	5	0	0	9	Black Sea	Mg	65694,3	
8			9	0	0	0	9	Black Sea			
9			5	5	0	0	0	Taman			
7			14	0	14	0	0	Anapa			
5	10	11	25	0	1	22	2	South foothill	Sr	871,9	
10			22	0	0	22	0	South foothill			
11	12	13	3	0	1	0	2	Black Sea	Zn	634,8	
12			1	0	1	0	0	Anapa			
13			2	0	0	0	2	Black Sea			
3	14	15	82	62	0	3	17	Taman	Al	1644,4	
14	16	17	62	57	0	0	5	Taman	K	300423,0	
16			3	0	0	0	3	Black Sea			
17	18	19	59	57	0	0	2	Taman	Sr	1342,7	
18			57	57	0	0	0	Taman			
19			2	0	0	0	2	Black Sea			
15	20	21	20	5	0	3	12	Black Sea	Rb	609,5	
20	22	23	13	0	0	1	12	Black Sea	Ti	19,8	
22			1	0	0	1	0	South foothill			
23			12	0	0	0	12	Black Sea			
21	24	25	7	5	0	2	0	Taman	Sort		Muscat
24			2	0	0	2	0	South foothill			
25			5	5	0	0	0	Taman			

Естественно предположить, что роль предикторов при построении деревьев решений и выбора наилучшего различна. Если воспользоваться кнопкой Importance, то программа построит таблицу с оценкой от 0 до 1 важности всех 16 заявленных в окне на рис.2.1.4 предикторов, и значениями их рангов в баллах от 0 до 100. Ранги представляют собою округленные до целых значения важности, умноженные на 100.

Также при помощи одноименной кнопки можно получить графическое изображение, приведенное на рис.2.1.18. Как видно из графика первое место по важности занимает предиктор Fe с оценкой 1, который отсутствует в условиях ветвления дерева, последнее место у предиктора Sort с оценкой 0,4.

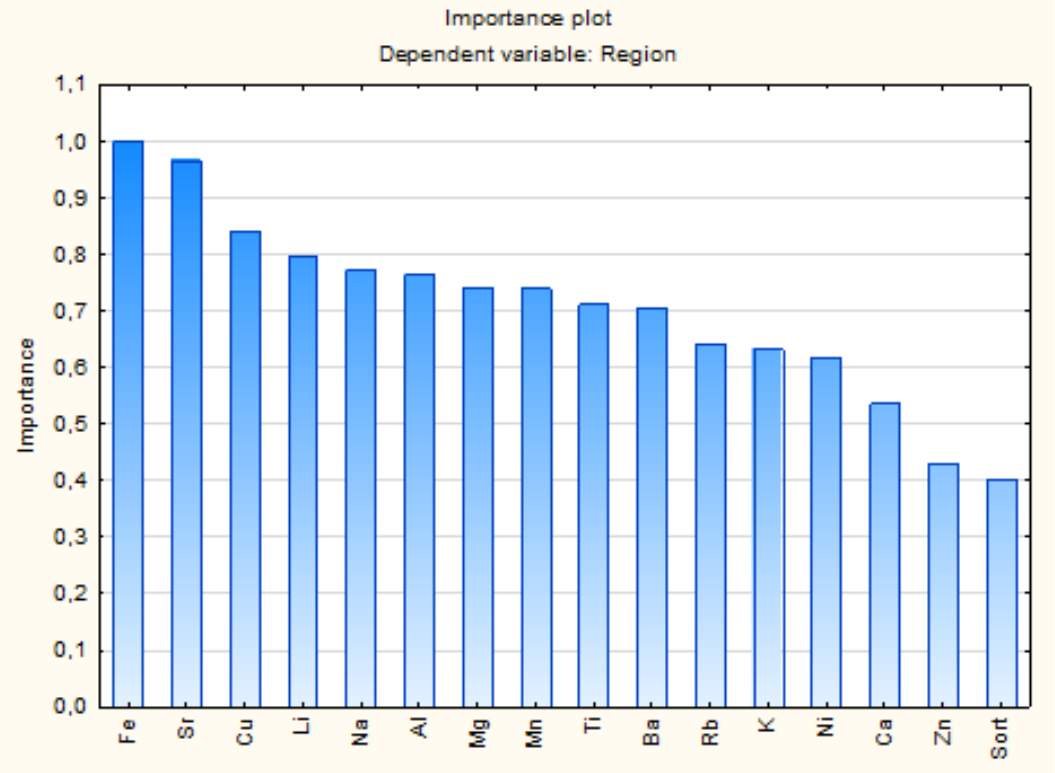


Рис.2.1.18

Информацию о построенной программой последовательности усеченных деревьев решений можно получить, если воспользоваться кнопкой Tree sequence. Наименованиями строк являются номера деревьев (табл.2.1.4), в первом столбце отображено количество терминальных вершин, в последующих столбцах приведены цена кросс-проверки (CV cost) , ее стандартная ошибка (CV std. error), цена обучения (Resubstitution cost), сложность узла (Node complexity) и цена тестовой выборки (Test set cost). Усеченное дерево, как оптимальное, компромиссное между сложностью и точностью, выбранное алгоритмом Бреймана, помечено звездочкой (*) и совпало с лучшим по ценам из построенных деревьев. Если не проводится кросс-проверка, и нет тестовой выборки, то в таблице будут отсутствовать столбцы 2, 3, 6 и не будет отмечено звездочкой выбранное дерево и также лучшим будет дерево 1.

Для дерева 1 все параметры принимают минимальные значения, которые с увеличением номеров деревьев монотонно растут. При этом цена обучения равна 0, а цена тестовой выборки, равная 0,074, отлична от 0. Это означает, что в обучающей выборке нет ошибочных классификаций, а в тестовой есть. В тоже время, построение и выбор дерева решений можно считать успешным, если цена обучения не выше цены тестовой выборки. Как видно, в нашем случае данное условие не выполняется.

Таблица 2.1.4. Параметры последовательности деревьев

	Tree sequence (White wines1) Dependent variable: Region Optimal tree denoted by *					
	Terminal nodes	CV cost	CV std. error	Resubstitution cost	Node complexity	Test set cost
*Tree 1	13	0,066667	0,021469	0,000000	0,000000	0,074074
Tree 2	11	0,096296	0,025389	0,014815	0,007407	0,111111
Tree 3	8	0,125926	0,028554	0,059259	0,014815	0,162963
Tree 4	7	0,125926	0,028554	0,081481	0,022222	0,162963
Tree 5	5	0,185185	0,033432	0,155556	0,037037	0,162963
Tree 6	4	0,259259	0,037717	0,207407	0,051852	0,162963
Tree 7	3	0,274074	0,038390	0,274074	0,066667	0,318519
Tree 8	2	0,377778	0,041728	0,377778	0,103704	0,355556
Tree 9	1	0,503704	0,043032	0,503704	0,125926	0,503704

Графическое изображение поведения цен кросс-проверки и обучения можно (рис.2.1.18) получить, воспользовавшись кнопкой Cost sequence. Информацию о результатах классификации построенным деревом решений образцов вин можно получить на вкладке Classification в рамке Sample окна результатов (рис.2.1.14). Если выделить опцию Analysis и щелкнуть по кнопке Predicted vs. observed by classes, программа построит таблицу с итогами классификации (табл.2.1.5), ее трехмерное графическое изображение (рис.2.1.19) и таблицу относительных частот в процентах по строкам (Row), столбцам (Column), а также частот относительно общего количества в обучающей выборке (Total) (табл.2.1.6). По столбцам указаны исходные частоты, по строкам – предсказанные. Как видно из таблиц и графика количество ошибочных классификаций в обучающей выборке равно 0.

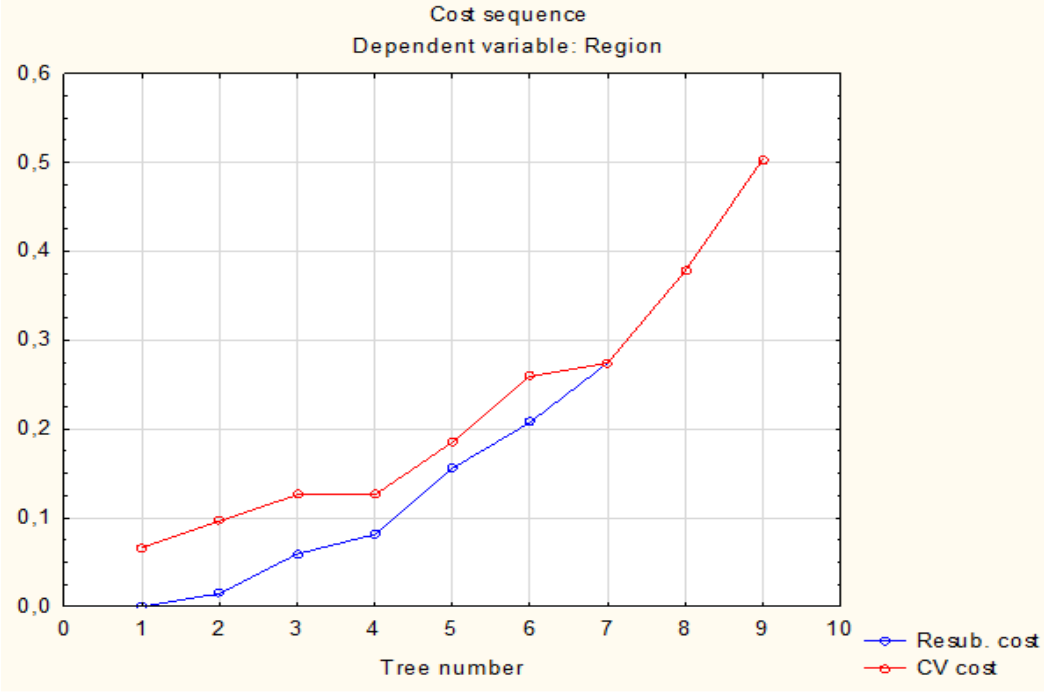


Рис.2.1.18

Таблица 2.1.5. Матрица классификации

	Classification matrix 1 (White wines1) Dependent variable: Region Options: Categorical response, Tree number 1, Analysis sample			
	Observed Taman	Observed Anapa	Observed South foothill	Observed Black Sea
Predicted Taman	67,00000			
Predicted Anapa		15,00000		
Predicted South foothill			25,00000	
Predicted Black Sea				28,00000

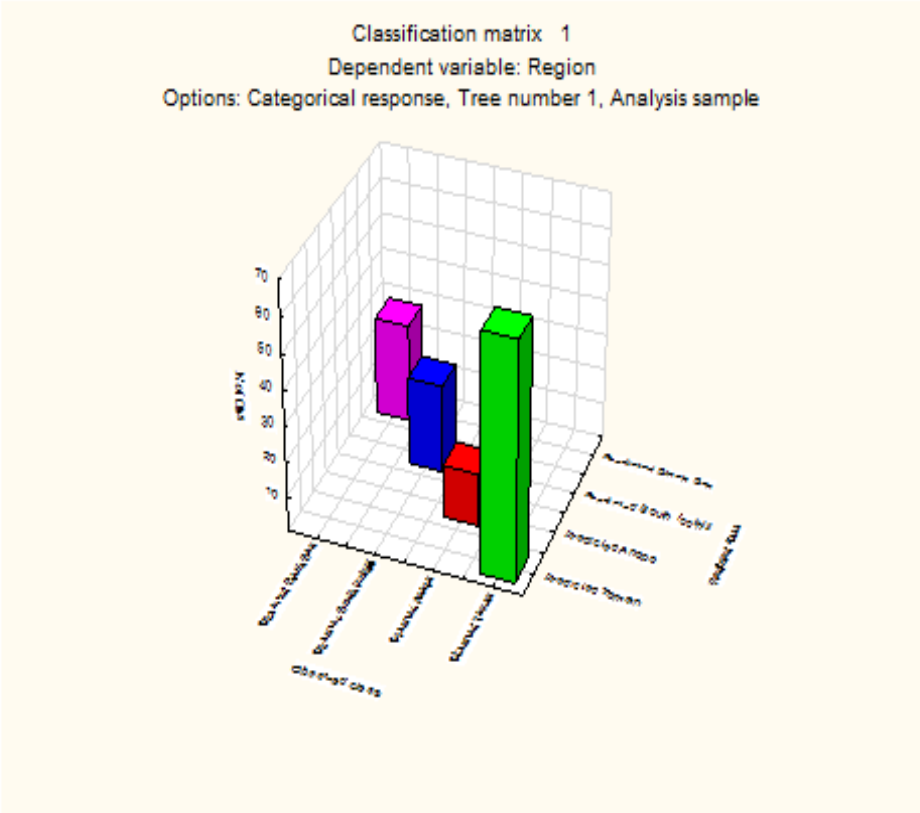


Рис.2.1.19

Таблица 2.1.6. Относительные частоты для обучающей выборки

	Classification matrix 1 (White wines1) Dependent variable: Region Options: Categorical response, Analysis sample					
	Observed	Predicted Taman	Predicted Anapa	Predicted South foothill	Predicted Black Sea	Row Total
Number	Taman	67				67
Column Percentage		100.00%	0.00%	0.00%	0.00%	
Row Percentage		100.00%	0.00%	0.00%	0.00%	
Total Percentage		49.63%	0.00%	0.00%	0.00%	49.63%
Number	Anapa		15			15
Column Percentage		0.00%	100.00%	0.00%	0.00%	
Row Percentage		0.00%	100.00%	0.00%		
Total Percentage		0.00%	11.11%	0.00%	0.00%	11.11%
Number	South foothill			25		25
Column Percentage		0.00%	0.00%	100.00%	0.00%	
Row Percentage		0.00%	0.00%	100.00%	0.00%	
Total Percentage		0.00%	0.00%	18.52%	0.00%	18.52%
Number	Black Sea				28	28
Column Percentage		0.00%	0.00%	0.00%	100.00%	
Row Percentage		0.00%	0.00%	0.00%	100.00%	
Total Percentage		0.00%	0.00%	0.00%	20.74%	20.74%
Count	All Groups	67	15	25	28	135
Total Percent		49.63%	11.11%	18.52%	20.74%	

Если выделить опцию Test set и щелкнуть по кнопке Predicted vs. observed by classes, программа построит аналогичные таблицы (табл.2.1.7, 2.1.8) и график (рис.2.1.20) для тестовой выборки

Таблица 2.1.7. Матрица классификации тестовой выборки

	Classification matrix 1 (White wines1) Dependent variable: Region Options: Categorical response, Tree number 1, Test sample			
	Observed Taman	Observed Anapa	Observed South foothill	Observed Black Sea
Predicted Taman	6,000000		1,000000	
Predicted Anapa		2,000000		
Predicted South foothill			4,000000	
Predicted Black Sea		1,000000		4,000000

Таблица 2.1.8. Относительные частоты для тестовой выборки

	Classification matrix 1 (White wines1) Dependent variable: Region Options: Categorical response, Test sample					
	Observed	Predicted Taman	Predicted Anapa	Predicted South foothill	Predicted Black Sea	Row Total
Number	Taman	6				6
Column Percentage		85.71%	0.00%	0.00%	0.00%	
Row Percentage		100.00%	0.00%	0.00%	0.00%	
Total Percentage		33.33%	0.00%	0.00%	0.00%	33.33%
Number	Anapa		2		1	3
Column Percentage		0.00%	100.00%	0.00%	20.00%	
Row Percentage		0.00%	66.67%	0.00%	33.33%	
Total Percentage		0.00%	11.11%	0.00%	5.56%	16.67%
Number	South foothill	1		4		5
Column Percentage		14.29%	0.00%	100.00%	0.00%	
Row Percentage		20.00%	0.00%	80.00%	0.00%	
Total Percentage		5.56%	0.00%	22.22%	0.00%	27.78%
Number	Black Sea				4	4
Column Percentage		0.00%	0.00%	0.00%	80.00%	
Row Percentage		0.00%	0.00%	0.00%	100.00%	
Total Percentage		0.00%	0.00%	0.00%	22.22%	22.22%
Count	All Groups	7	2	4	5	18
Total Percent		38.89%	11.11%	22.22%	27.78%	

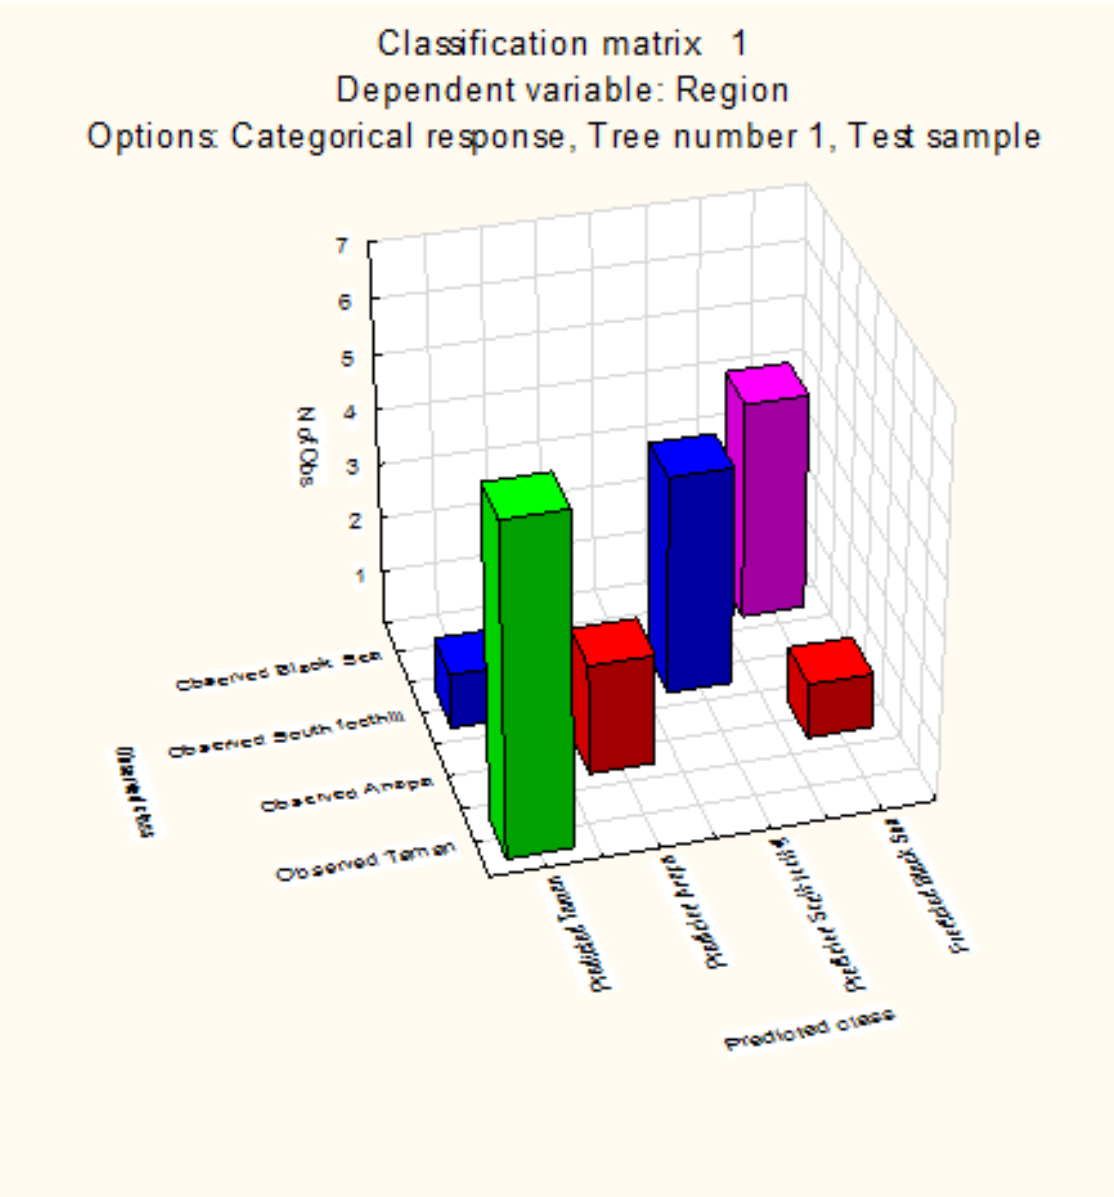

Classification matrix 1
Dependent variable: Region
Options: Categorical response, Tree number 1, Test sample
7
6
5
4
3
2
1
Observed Black Sea
Observed South Foothills
Observed Aneppa
Observed Taman
Predicted Taman
Predicted Aneppa
Predicted Steppe Hills
Predicted Black Sea
Predicted class

Рис.2.1.20

Как видно из представленной информации тестовая выборка содержит 2 ошибочные классификации – 1 образец вина из Южно-Предгороной зоны ошибочно отнесен к Таманской и, 1 образец из Анапской зоны ошибочно отнесен к Черноморской зоне. Общая точность прогноза для тестовой выборки составила ≈ 89%. Варьирование параметров остановки в окне на рис.2.1.9 не привело к улучшению прогностических свойств деревьев решений.

Попытаемся улучшить дерево решений, введя в качестве предикторов только те переменные, которые участвуют в ветвлении дерева и приведены в табл.2.1.3: Li, Al, Mg, Sr, Zn, K, Rb, Ti, Sort. Как видно из табл.2.1.9 цена кросс-проверки не изменилась, но вдвое уменьшилась цена тестовой выборки. При этом, как и следовало ожидать, количество ошибочных классификаций тестовой выборки также сократилось вдвое (табл.2.1.10) – один образец вина из Южно-Предгороной зоны ошибочно отнесен к Таманской зоне. Общая доля правильно идентифицированных вин тестовой выборки составила ≈ 94,4%

Таблица 2.1.9. Параметры последовательности нового дерева

	Tree sequence (White wines1) Dependent variable: Region Optimal tree denoted by *					
	Terminal nodes	CV cost	CV std. error	Resubstitution cost	Node complexity	Test set cost
*Tree 1	13	0,066667	0,021469	0,000000	0,000000	0,037037
Tree 2	11	0,103704	0,026240	0,014815	0,007407	0,111111
Tree 3	8	0,125926	0,028554	0,059259	0,014815	0,162963
Tree 4	7	0,125926	0,028554	0,081481	0,022222	0,162963
Tree 5	5	0,185185	0,033432	0,155556	0,037037	0,162963
Tree 6	4	0,259259	0,037717	0,207407	0,051852	0,162963
Tree 7	3	0,274074	0,038390	0,274074	0,066667	0,318519
Tree 8	2	0,377778	0,041728	0,377778	0,103704	0,355556
Tree 9	1	0,503704	0,043032	0,503704	0,125926	0,503704

Таблица 2.1.10. Матрица классификации тестовой выборки новым деревом

	Classification matrix 1 (White wines1) Dependent variable: Region Options: Categorical response, Tree number 1, Test sample			
	Observed Taman	Observed Anapa	Observed South foothill	Observed Black Sea
Predicted Taman	6,000000		1,000000	
Predicted Anapa		3,000000		
Predicted South foothill			4,000000	
Predicted Black Sea				4,000000

Для сохранения алгоритма классификации в одном из возможных программных кодов следует воспользоваться вкладкой Report (рис.2.1.21) и щелкнуть кнопкой Code generator и соответственно выбрать язык программирования.

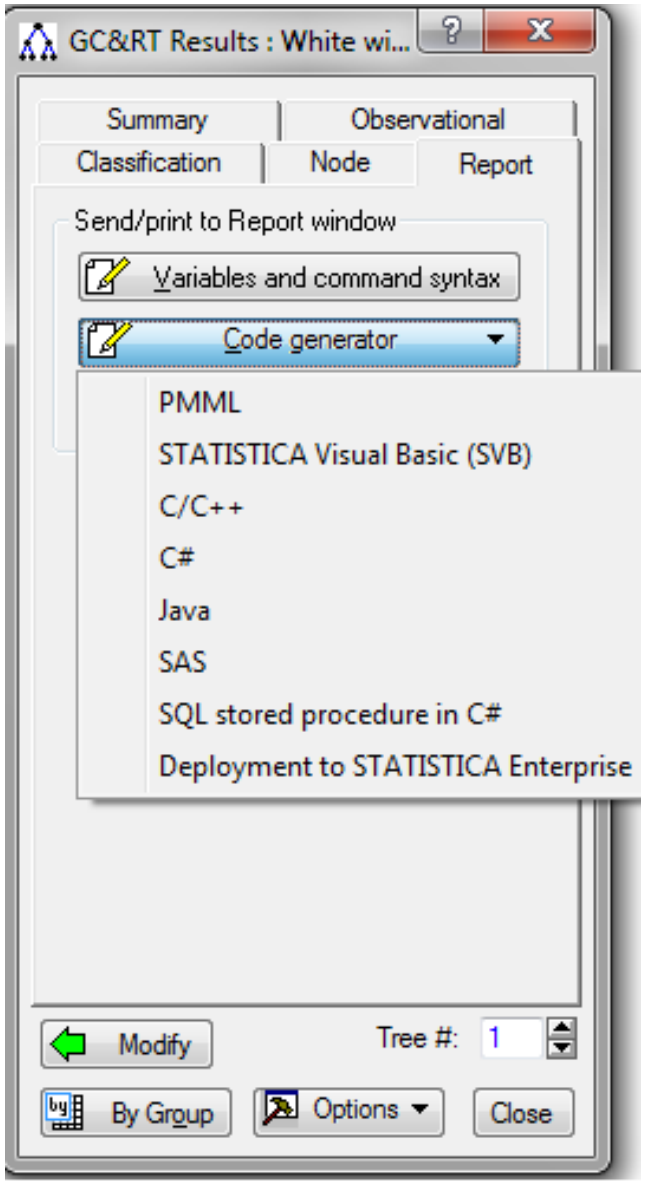


Рис.2.1.21

ЛИТЕРАТУРА

1. http://statsoft.ru/products/STATISTICA_Data_Miner/modules-statistica-data-miner.php
2. http://statsoft.ru/home/textbook/modules/stgrowtrees.html
3. https://stat-lab.ru/











