Лекция 3. CHAID модели

CHAID – Chi-square automatic interaction detection, в переводе означает «**Автоматическое обнаружение взаимодействия Хи-квадрат**» – метод построения деревьев решений, использующий многострочное разбиение (расщепление, разветвление). Это один из старейших методов деревьев классификации, название алгоритма отражает его базовую идею, которая служит отличием CHAID от других алгоритмов построения деревьев решений.

Идея, лежащая в основе алгоритма – это поиск взаимодействий, т.е. подбор предикторов и их сочетаний, которые на каждом шаге ветвления в наибольшей степени определяют зависимую переменную. В моделях, созданных с его помощью, **узлы могут иметь более чем два разветвления**, в силу чего алгоритму CHAID свойственно «выращивать» достаточно раскидистые деревья. Данный класс алгоритмов заслужил популярность благодаря своему **быстродействию** в сравнении со стандартными алгоритмами C&RT при больших объемах данных. **Если при использовании стандартных методов в алгоритмах C&RT всё дерево строится целиком, а потом при необходимости усекается, в случае его чрезмерной ветвистости, то алгоритмы класса CHAID стремятся сразу избежать переобученности, поэтому прекращают свою работу по достижению определённой точности в вершинах**. Это преимущество в полной мере проявляет себя на данных больших объёмов, для которых C&RT оказывается слишком медленным. Однако на выборках небольших размеров он чаще всего строит не совсем корректную модель.

Другим отличием CHAID является то, что дерево может быть менее глубоким, так как вершины дерева могут иметь более двух разветвлений.

Еще раз повторим, что в отличие от других алгоритмов, опирающихся на информационные критерии при расщеплении выборки в узлах деревьев, CHAID использует статистический критерий **Хи-квадрат**. Данная особенность отражается на построении решения следующим образом: алгоритмы класса CHAID **максимизируют взаимосвязь между независимыми переменными и откликом**, в то время как другие методы ориентированы на **достижение однородности в узлах дерева, которое контролируется долей, или количеством ошибочных классификаций в узле.** Метод будет эффективным также при классификации переменной категориального отклика со **многими категориями**, если есть также категориальные предикторы (факторы) со **многими категориями (много классовые задачи)**.

Поэтому метод CHAID особенно популярен в маркетинговых исследованиях в контексте исследования сегментации рынка. Кроме умеренного быстродействия даже для больших выборок данных, CHAID не имеет ограничений на типы переменных в силу того, что он основан на критерии Хи-квадрат для определения наилучшего следующего расщепления узла на каждом шаге. **Также как и метод C&RT применим для решения задач регрессионного типа, но в этом случае вычисляет значение F-критерия (Фишера)**.

Недостатком метода является то, что он **не очень хорош для работы с выборками небольшого объема**.

Алгоритм CHAID работает следующим образом. **Создаются категориальные предикторы из любых непрерывных предикторов, делением диапазона их изменения на несколько с примерно равным количеством наблюдений. Каждому диапазону соответствует категория – новое значение образованной категориальной переменной. Для категориальных предикторов классы (категории) априори заданы.**

Далее алгоритм будет циклически проходить через уже категориальные предикторы, чтобы определить для каждого предиктора **пару категорий**, которые наименее значимо взаимодействуют с зависимой переменной. Как уже было выше замечено, для задач классификации, где зависимая переменная также является категориальной, программа вычислит критерий Хи-квадрат, для задач регрессии, где зависимая переменная является непрерывной, программа вычислит **F-критерий**. Если соответствующий критерий для данной пары категорий предиктора **не является статистически значимым**, в соответствии с заданным *уровнем значимости объединения* (уровень значимости **больше заданного p**), то программа объединит соответствующие категории предикторов и повторит этот шаг (то есть найдет следующую пару категорий, которая теперь может включать ранее объединенные категории).

После реализации выше описанной процедуры программа вычислит для всех предикторов скорректированное по Бонферрони значение уровня значимости p, характеризующую статистическую значимость взаимосвязи предикторов с откликом. Далее алгоритм выберет для разделения вершины переменную предиктора с наименьшим скорректированным значением p.

Если наименьшее скорректированное значение уровня значимости p окажется больше заданного *уровня значимости расщепления*, то дальнейшие расщепления не выполняются, и соответствующий узел станет терминальным. Если окажется меньше, то будет произведено расщепление узла. Этот процесс продолжается до тех пор, пока никакие дальнейшие расщепления не могут быть выполнены, учитывая заданные *уровни значимости объединения* и *расщепления.*

Так как критерий Хи-квадрат плохо работает в узлах, содержащих малое количество данных, следует быть осторожным при задании минимального числа наблюдений в узлах: **его следует выбирать не слишком малым и соотносящимся с общим размером выборки**.

В методе CHAID, также как и в методе C&RT для построения деревьев решений с высокими прогностическими свойствами предусмотрена сплит-валидация и V-кратная кросс-проверка.

Перейдем к практической работе с модулем [7]. Модуль называется General CHAID Models, в меню раздела Data Mining расположен следом за модулем General Classification and Regression Trees (рис.2.1.2). Если кликнуть по названию модуля откроется окно, представленное на рис.2. 2.1, в котором пользователю предлагается выбрать тип анализа и метод. Нас интересует Standard CHAID. Если выбрать CHAID with coded design, то кнопка Between effects на вкладке Quick (2.1.5) станет активной и пользователь сможет строить ANOVA/ANCOVA-подобные дизайны для предикторных переменных, т.е. строить их произвольные комбинации.

Вкладка Quick стартового окна полностью идентична одноименной вкладке метода C&RT на рис.2.1.5.

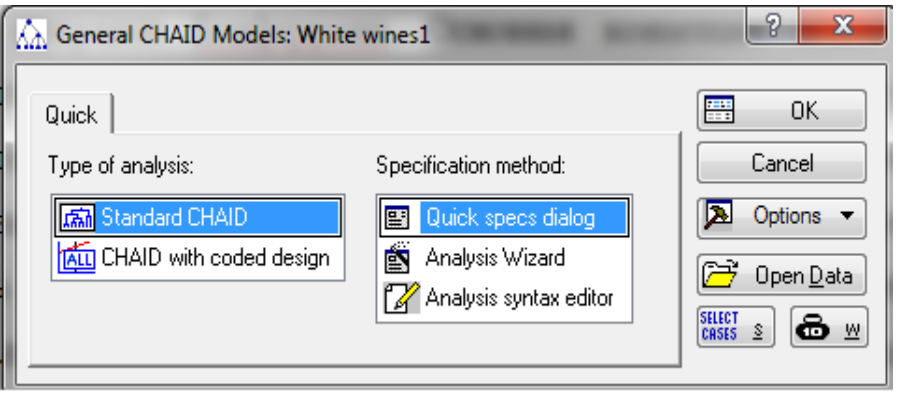
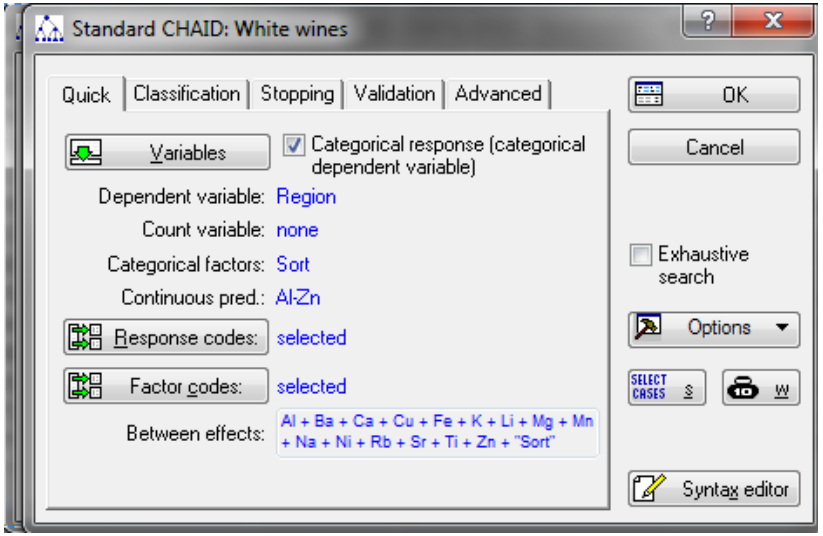
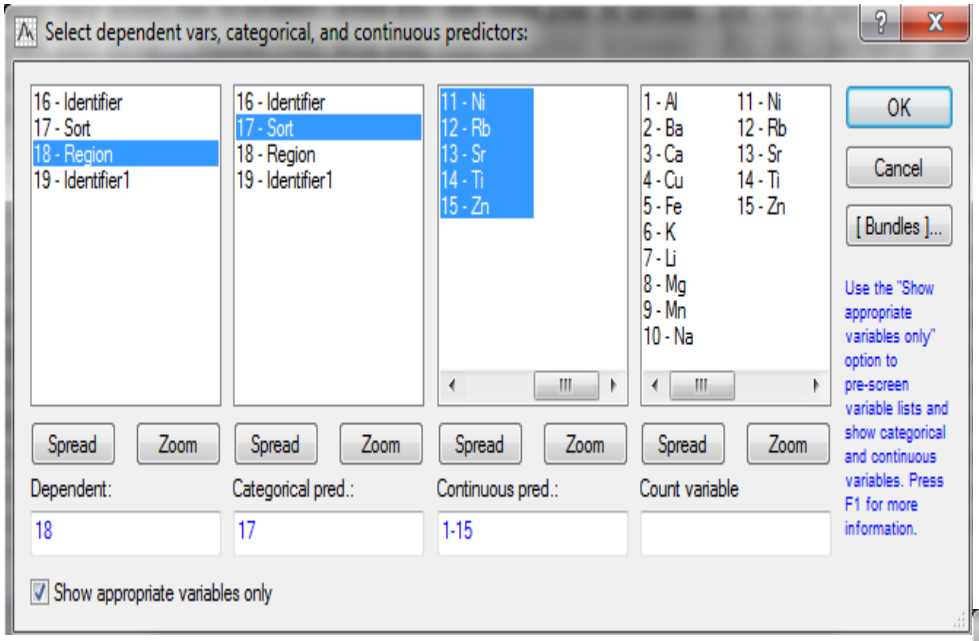
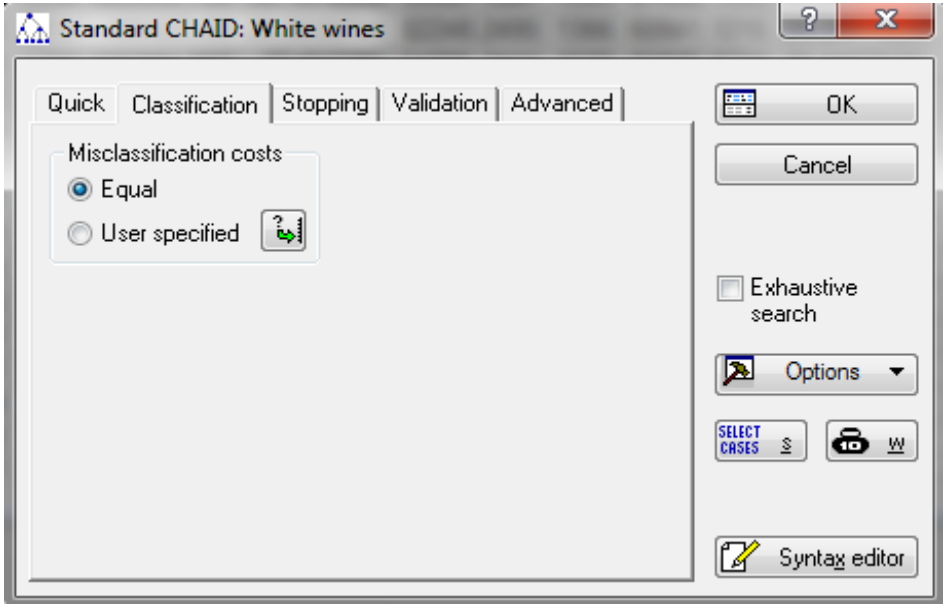


Рис.2.2.1



Несколько отличаются другие вкладки. Вкладка Classification (рис.2.2.2) содержит только рамку Misclassification Costs, в которой, напомним, при помощи опции User spec можно задать цену ошибок классификации для каждого класса, в нашем случае региона произрастания винограда, либо, выделив опцию Equal, назначить равные цены.





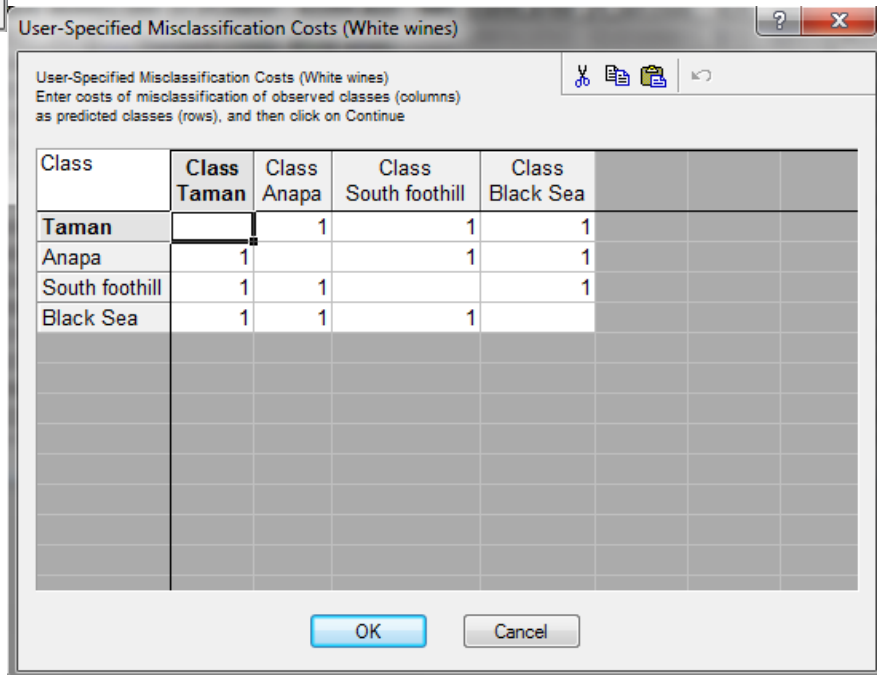


Рис.2.2.2

На вкладке Stopping (рис.2.2.3) реализовано только одно правило определяющее размер дерева, поэтому, присутствует только рамка Stopping parameters, которая является ключевой для выбора подходящего размера дерева. Остановимся на этой вкладке подробнее. Первый параметр рамки – это Minimum n, который, как и в методе C&RT регламентирует дальнейшее расщепление узла – если количество наблюдений в узле меньше этого значения, то дальнейшее расщепление наблюдений в узле не будет. Параметр Maximum n nodes контролирует общее количество узлов в дереве. По умолчанию заданы *уровни значимости расщепления* (Prob. for splitting) и *объединения* (Prob. for merging), равные 0,05. К сожалению, отсутствуют какие либо рекомендации по выбору значений этих уровней значимости, которые могут произвольным образом и независимо друг от друга варьироваться в диапазоне от 0 до 1.

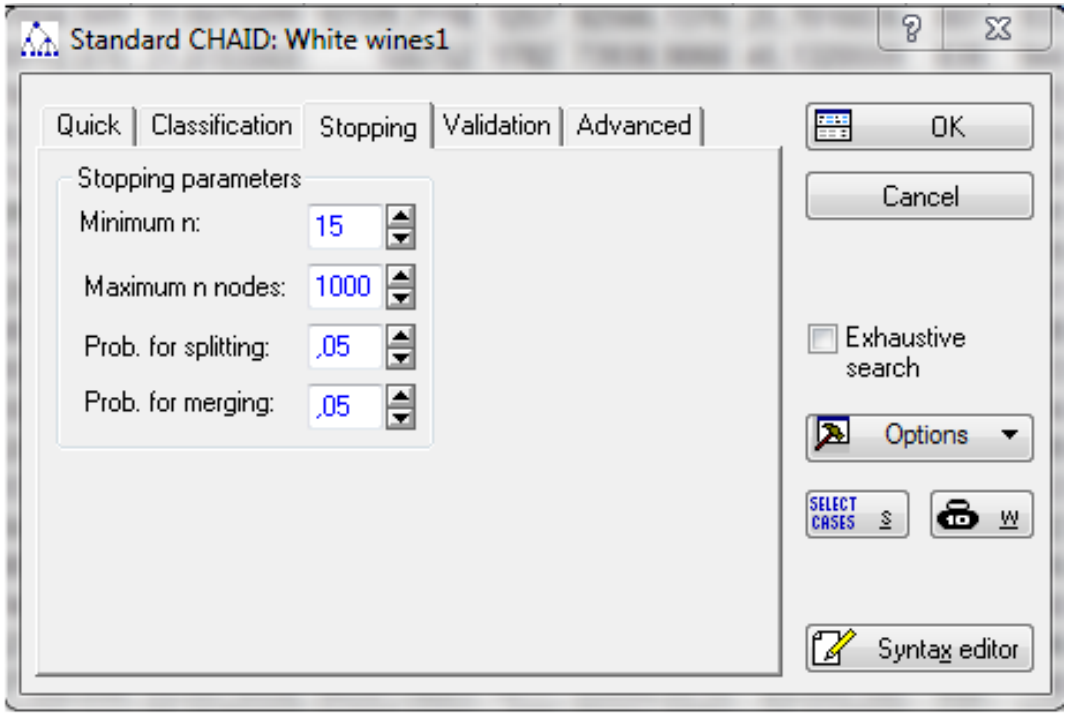


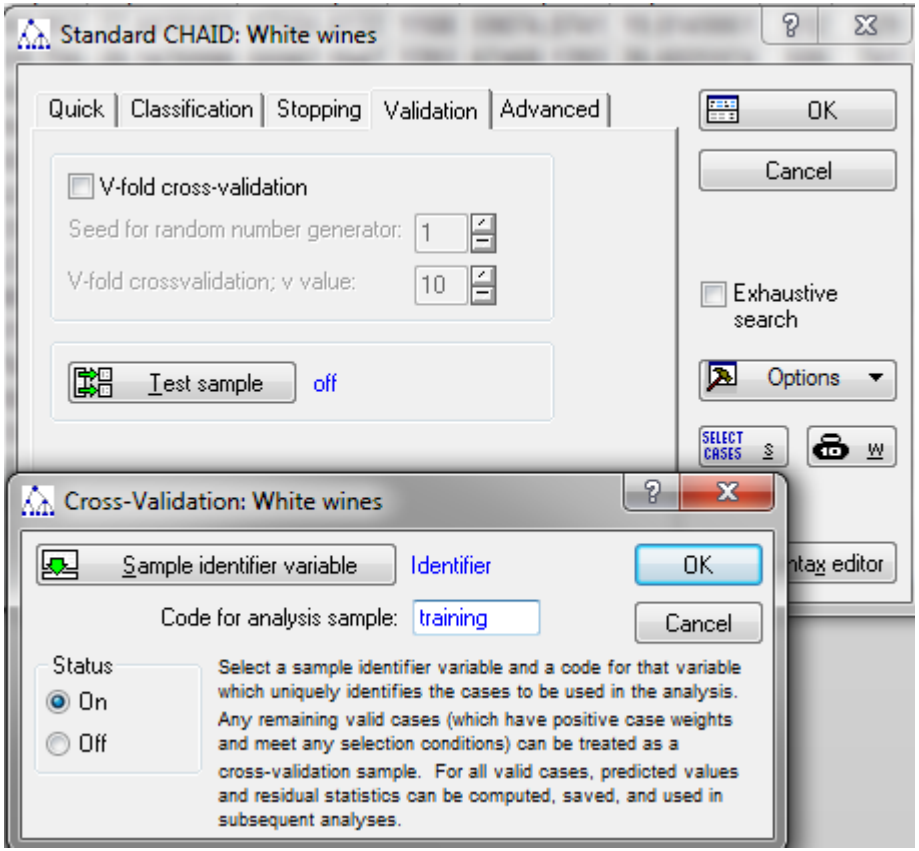
Рис.2.2.3

Вкладка Validation, задающая по желанию пользователя сплит-валидацию при помощи тестовой выборки и V-кратную кросс-проверку полностью идентична вкладке метода C&RT (2.1.10).

Вкладка Advanced (рис.2.2.4) также содержит опцию Sigma-restricted parameterization for categorical predictors для применения сигма-ограниченной параметризации, если пользователь в окне на рис.2.2.1 выбрал тип анализа CHAID with coded design.

Опция Splitting merged categories (разделение объединенных категорий) применяется, чтобы, если было проведено объединение категорий, то их разделить для оптимального выбора категорий. Для расщепления узла метод находит предиктор с наименьшим уровнем значимости p, т.е. предиктор с наибольшей статистической значимостью.

Опция Bonferroni adjusted (поправка Бонферрони) корректирует значения p.



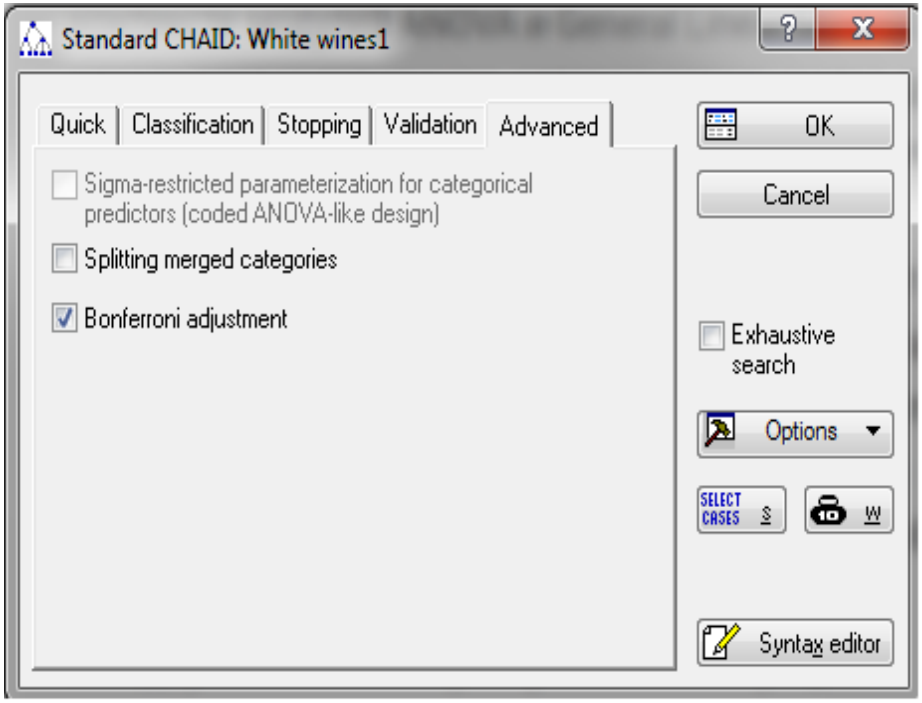


Рис.2.2.4

При опциях, выбранных по умолчанию, без кросс-проверки построенное дерево содержало 16 вершин, 10 терминальных, с 26 ошибочными классификациями.

Для выбора дерева с наилучшими прогностическими свойствами по методу CHAID были проведены многочисленные эксперименты с целью подбора параметров, регламентирующих размер дерева. При уменьшении Minimum n в окне на рис.2.2.3 до 1, количество ошибочных классификаций снизилось до 14, число терминальных вершин возросло до 17 при 6 нетерминальных.

При уменьшении уровней значимости p до 0,01 в окне на рис.2.2.3, количество ошибок снизилось до 10, число вершин составило 27, из них 18 терминальных.

Назначение тестовой выборки привело к резкому уменьшению размеров дерева до 14 вершин, из которых 10 терминальных. При этом число ошибочных классификаций в обучающей выборке составило 18, в тестовой – 4, т.е. как и следовало ожидать, уменьшение размеров дерева привело к увеличению общего числа ошибочных классификаций. Кросс-проверка не привела к улучшению прогностических способностей метода.

Увеличение размеров дерева до 30 вершин, из них 20 терминальных, сопровождающееся повышением точности классификации, удалось достигнуть при p = 0,8, Minimum n =1, исключении поправки Бонферрони (рис.2.2.5, 2.2.6), выключением кросс-проверки.

Точность в 100% на тестовой выборке можно достичь при p =0,45; 0,5… Не показывать студентам

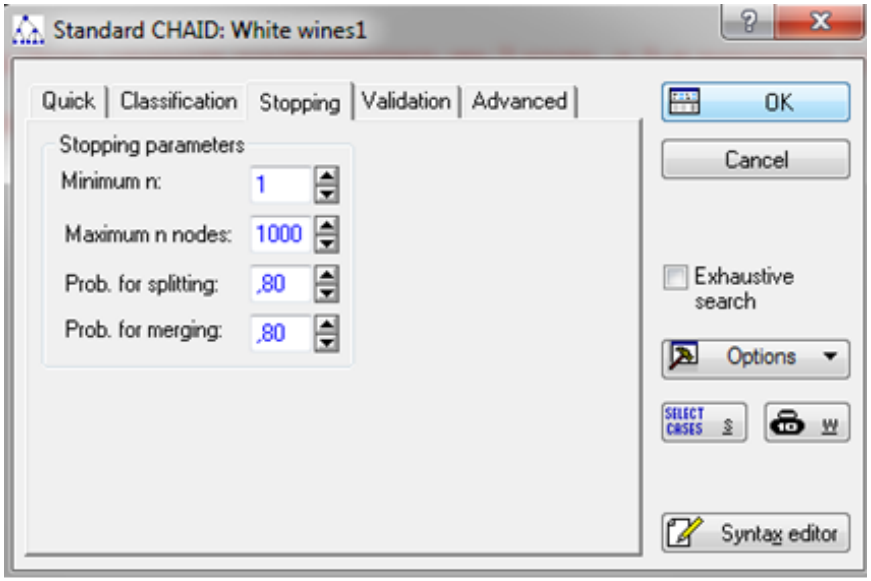


Рис.2.2.5

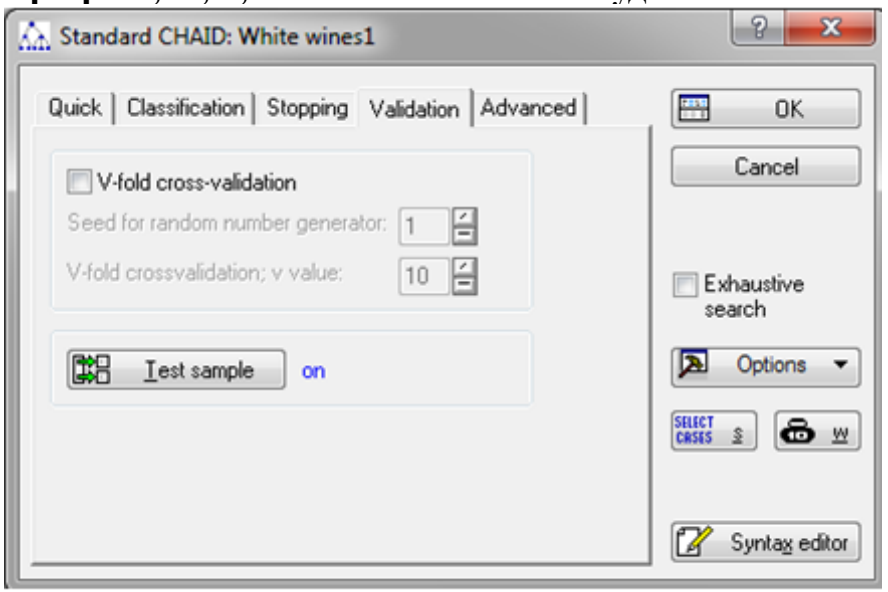


Рис.2.2.6

Из графа дерева, построенного по обучающей выборке и доступного после нажатия кнопки Tree graph (рис.2.2.7), видно (рис.2.2.8), что в отличие от метода C&RT дерево не бинарное, например, вершина дерева расщепилась на 9 дочерних вершин. Вершины 2, 4, 6, 7, 8, 10 в свою очередь расщепились на 2 узла, а вершины 5 и 9 на 3 узла. Дерево получилось раскидистое четырехуровневое.

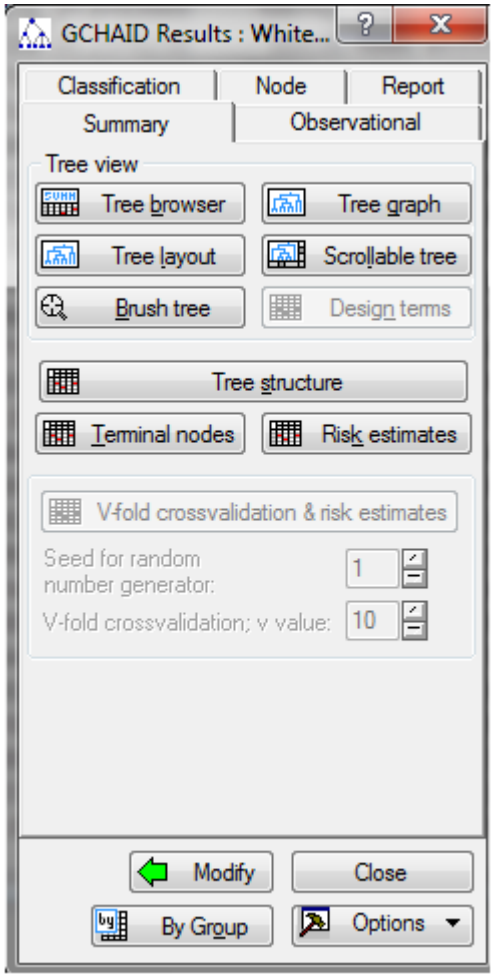


Рис.2.2.7

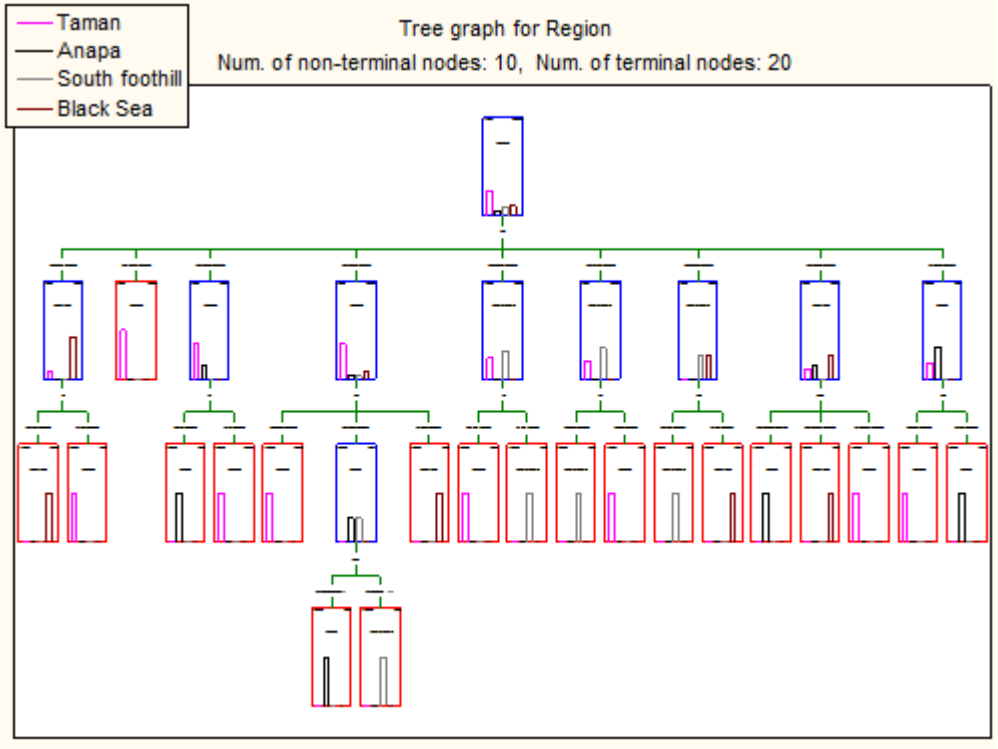


Рис.2.2.8

Если перейти на вкладку Classification и воспользоваться кнопкой Predicted vs. observed by classes, последовательно выделив опции Test и Analysis, увидим, что за счет увеличения размеров дерева произошло существенное повышение ее прогностических свойств – одна ошибка в тестовой выборке (табл.2.2.1), и ни одной в обучающей выборке (табл.2.2.2). На результат не влияет крос-проверка

Таблица 2. 2.1. Матрица классификации для тестовой выборки

	Classification matrix (White wines1) Dependent variable: Region Options: Categorical response, Test sample			
	Observed Taman	Observed Anapa	Observed South foothill	Observed Black Sea
Predicted Taman	5,000000			
Predicted Anapa		3,000000		
Predicted South foothill	1,000000		5,000000	
Predicted Black Sea				4,000000

Таблица 2. 2.2. Матрица классификации для обучающей выборки

	Classification matrix (White wines1) Dependent variable: Region Options: Categorical response, Analysis sample			
	Observed Taman	Observed Anapa	Observed South foothill	Observed Black Sea
Predicted Taman	67,00000			
Predicted Anapa		15,00000		
Predicted South foothill			25,00000	
Predicted Black Sea				28,00000

На вкладке Summary (Итоги), если использована переменная Идентификатор, т.е. выборка разделена на тестовую и обучающую, все таблицы и графики соответствуют обучающей выборке!

Как было отмечено в предыдущем параграфе, при помощи кнопки Tree Scrollable (Прокрутить дерево) можно визуализировать дерево с детальным описанием его структуры. Альтернативой является табл.2.2.3, которую **легко** построить, воспользовавшись кнопкой Tree structure (Структура дерева).

В первом столбце таблицы (без имени) указаны номера вершин. Во втором столбце Number of node отображено количество дочерних вершин, на которые расщепляется данная вершина. В столбце Size of node приведено число образцов вин в данной вершине. В последующих 4 столбцах указан количественный состав вин по регионам. В столбце Selected category приведено название условного региона классификации образцов вин, содержащихся в вершине. Столбец Split variable содержит имя переменной, по которой осуществляется расщепление вершины на дочерние узлы. В следующих 9 столбцах содержатся условия расщепления на дочерние вершины с **порядковыми** номерами потомков (не совпадают с номерами вершин) 1,…, 9. В оставшихся 9 столбцах как раз и указаны номера **дочерних вершин** узлов дерева решений, приведенных в первом столбце.

Таблица 2. 2.3. Структура построенного методом CHAID дерева решений

	Number of node	Size of node	N in class Taman	N in class Anapa	N in class South foothill	N in class Black Sea	Selected category	Split variable	Criterion for child 1	Criterion for child 2	Criterion for child 3
1	9	135	67	15	25	28	Taman	Fe	x <= 848,1506	848,150 < x <= 1732,552	1732,552 < x <= 2487,074
2	2	14	2	0	0	12	Black Sea	Li	x <= 23,8696	x > 23,8696	
11		12	0	0	0	12	Black Sea				
12		2	2	0	0	0	Taman				
3		28	28	0	0	0	Taman				
4	2	14	10	4	0	0	Taman	Li	x <= 9,2466	x > 9,2466	
13		4	0	4	0	0	Anapa				
14		10	10	0	0	0	Taman				
5	3	14	10	1	1	2	Taman	Sr	x <= 823,6517	823,6517 < x <= 907,0829	x > 907,0829
15		10	10	0	0	0	Taman				
16	2	2	0	1	1	0	Anapa	Sort	Chardonnay	Muscat	
29		1	0	1	0	0	Anapa				
30		1	0	0	1	0	South foothill				
17		2	0	0	0	2	Black Sea				
6	2	14	6	0	8	0	South foothill	Ti	x <= 13,1162	x > 13,1162	
18		6	6	0	0	0	Taman				
19		8	0	0	8	0	South foothill				
7	2	14	5	0	9	0	South foothill	Ni	x <= 44,8050	x > 44,8050	
20		9	0	0	9	0	South foothill				
21		5	5	0	0	0	Taman				
8	2	14	0	0	7	7	South foothill	Cu	x <= 73,3289	x > 73,3289	
22		7	0	0	7	0	South foothill				
23		7	0	0	0	7	Black Sea				
9	3	14	3	4	0	7	Black Sea	Mg	x <= 52940,6021	52940,6021 < x <= 78901,9283	x > 78901,9283
24		4	0	4	0	0	Anapa				
25		7	0	0	0	7	Black Sea				
26		3	3	0	0	0	Taman				
10	2	9	3	6	0	0	Anapa	Ba	x <= 62,5369	x > 62,5369	
27		3	3	0	0	0	Taman				
28		6	0	6	0	0	Anapa				

Продолжение табл.2.2.3

	Criterion for child 4	Criterion for child 5	Criterion for child 6	Criterion for child 7	Criterion for child 8	Criterion for child 9	Child node 1	Child node 2	Child node 3	....	Child node 9
1	2487,0748 < x <= 3429,5943	3429,5943 < x <= 4594,3382	4594,3382 < x <= 5114,9197	5114,9197 < x <= 6124,0711	6124,0711 < x <= 7488,6667	x > 7488,66	2	3	4	...	10
2							11	12			
11											
12											
3											
4							13	14			
13											
14											
5							15	16	17		
15											
16							29	30			
29											
30											
17											
6							18	19			
18											
19											
7							20	21			
20											
21											
8							22	23			
22											
23											
9							24	25	26		
24											
25											
26											
10							27	28			
27											
28											

Как пример, приведем несколько правил расщепления вершины 1, содержащих все 135 образцов обучающей выборки и условно методом отнесенных к Таманской зоне:

– если Fe ≤ 848,1506, то переходим к потомку 1 (дочерней вершине 2);

– если 848,150 < Fe <= 1732,552, то переходим к потомку 2 (**дочерней вершине 3**) и т.д., вплоть до потомка 9 (**дочерней вершины 10**).

(см. табл. 2.2.3 или рис.2.2.9 на следующей странице)

Правила расщепления вершины 2, содержащей 2 образца Таманской зоны и 12 образцов Черноморской зоны несколько проще: если Li ≤ 23, 869, то переходим к терминальной вершине 11, в которой 12 образцов Черноморской зоны; если Li >23, 869, то переходим к терминальной вершине 12, в которой 2 образца Таманской зоны.

Все образцы вин, содержащиеся в вершине 2, методом условно отнесены к Черноморской зоне.

Дерево содержит одно расщепление вершины по категориальному предиктору Sort. Так, если в вершине 16, содержащей по 1 образцу Анапской и Южно-предгорной зоны, образец сорта Шардоне, то переходим к терминальной вершине 29 и образец принадлежит Анапской зоне; если образец сорта Мускат, то переходим к терминальной вершине 30 и образец принадлежит Южно-предгорной зоне (см. табл. 2.2.3 или рис.2.2.9 на следующей странице).

Если в диалоговом окне на рис.2.2.7 нажать на кнопку Scrollable то появится окно с прокруткой для лучшей и более подробной визуализации дерева (рис.2.29)

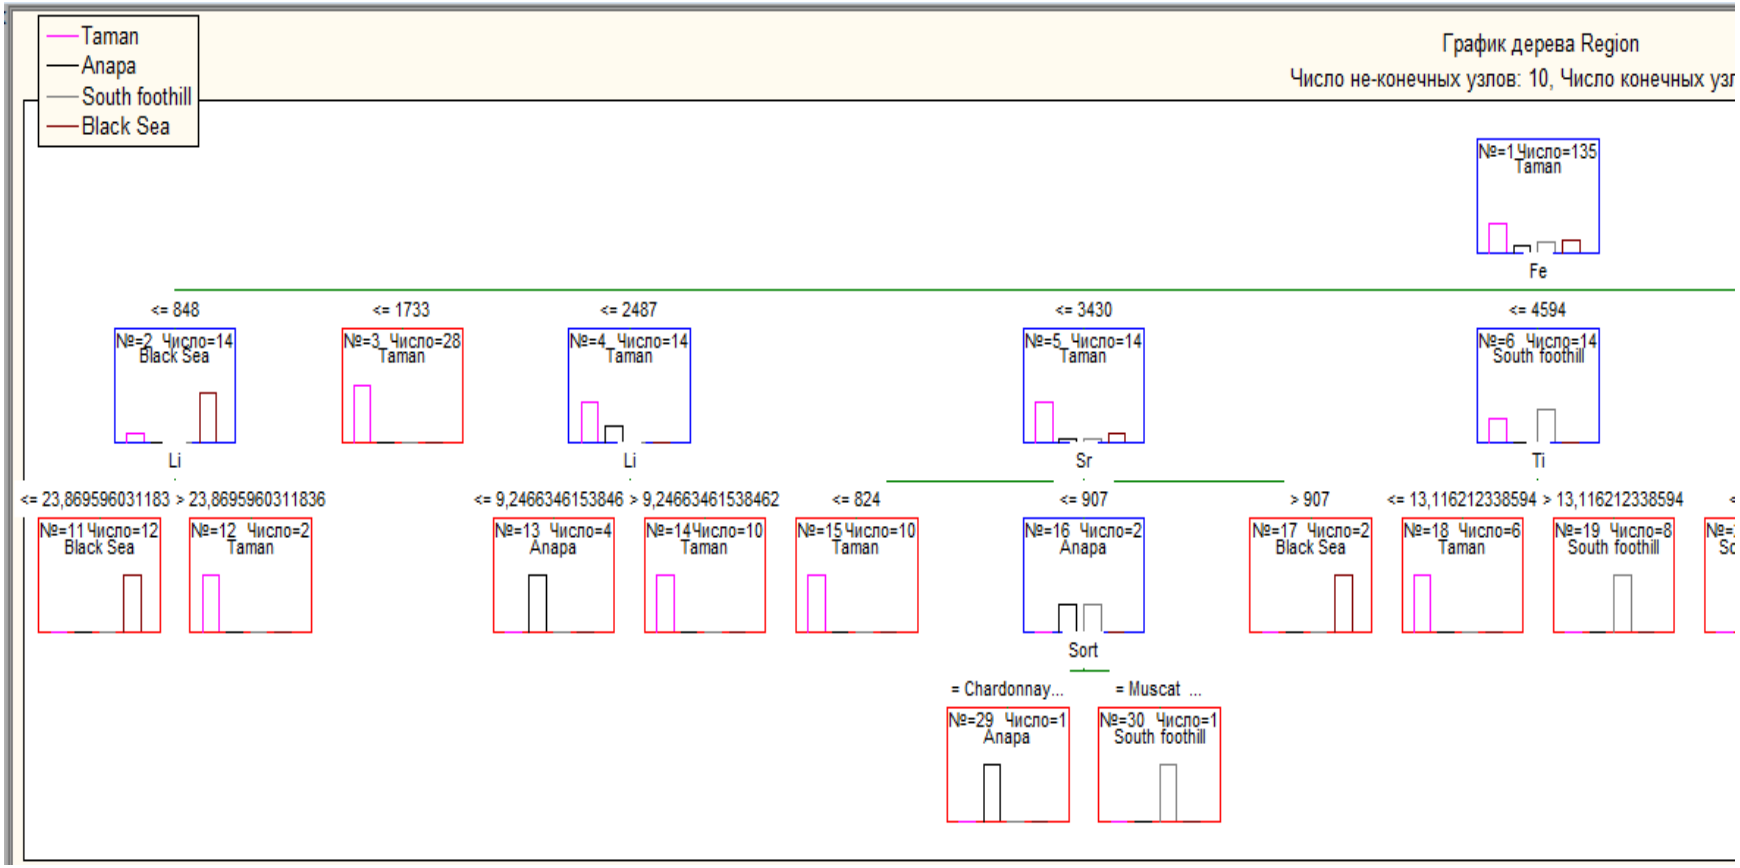
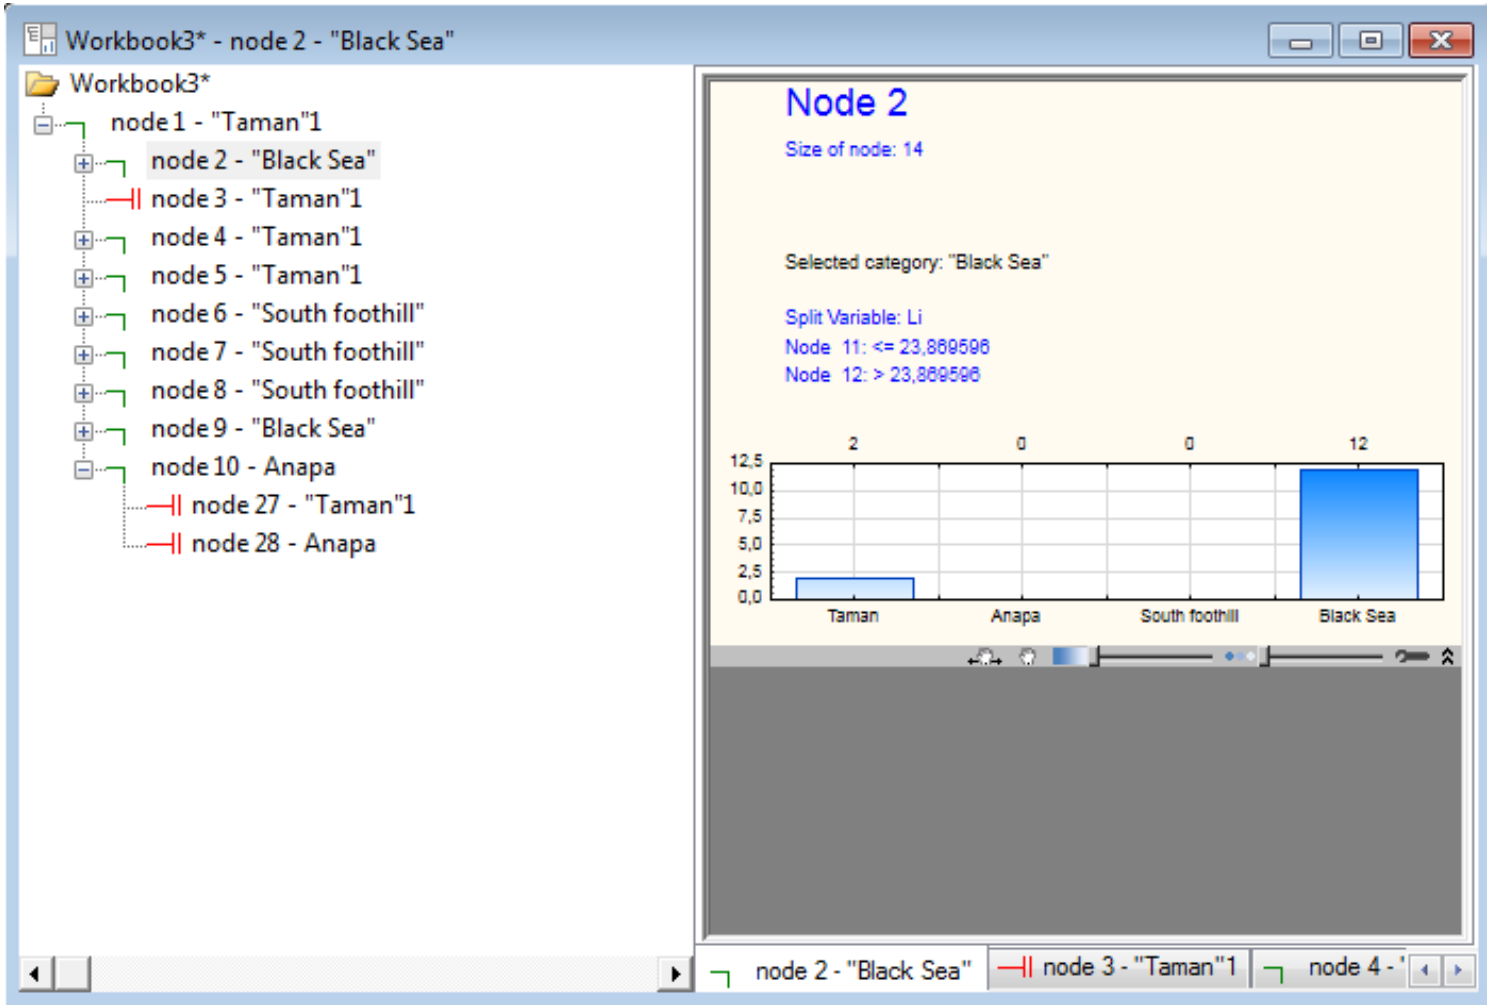
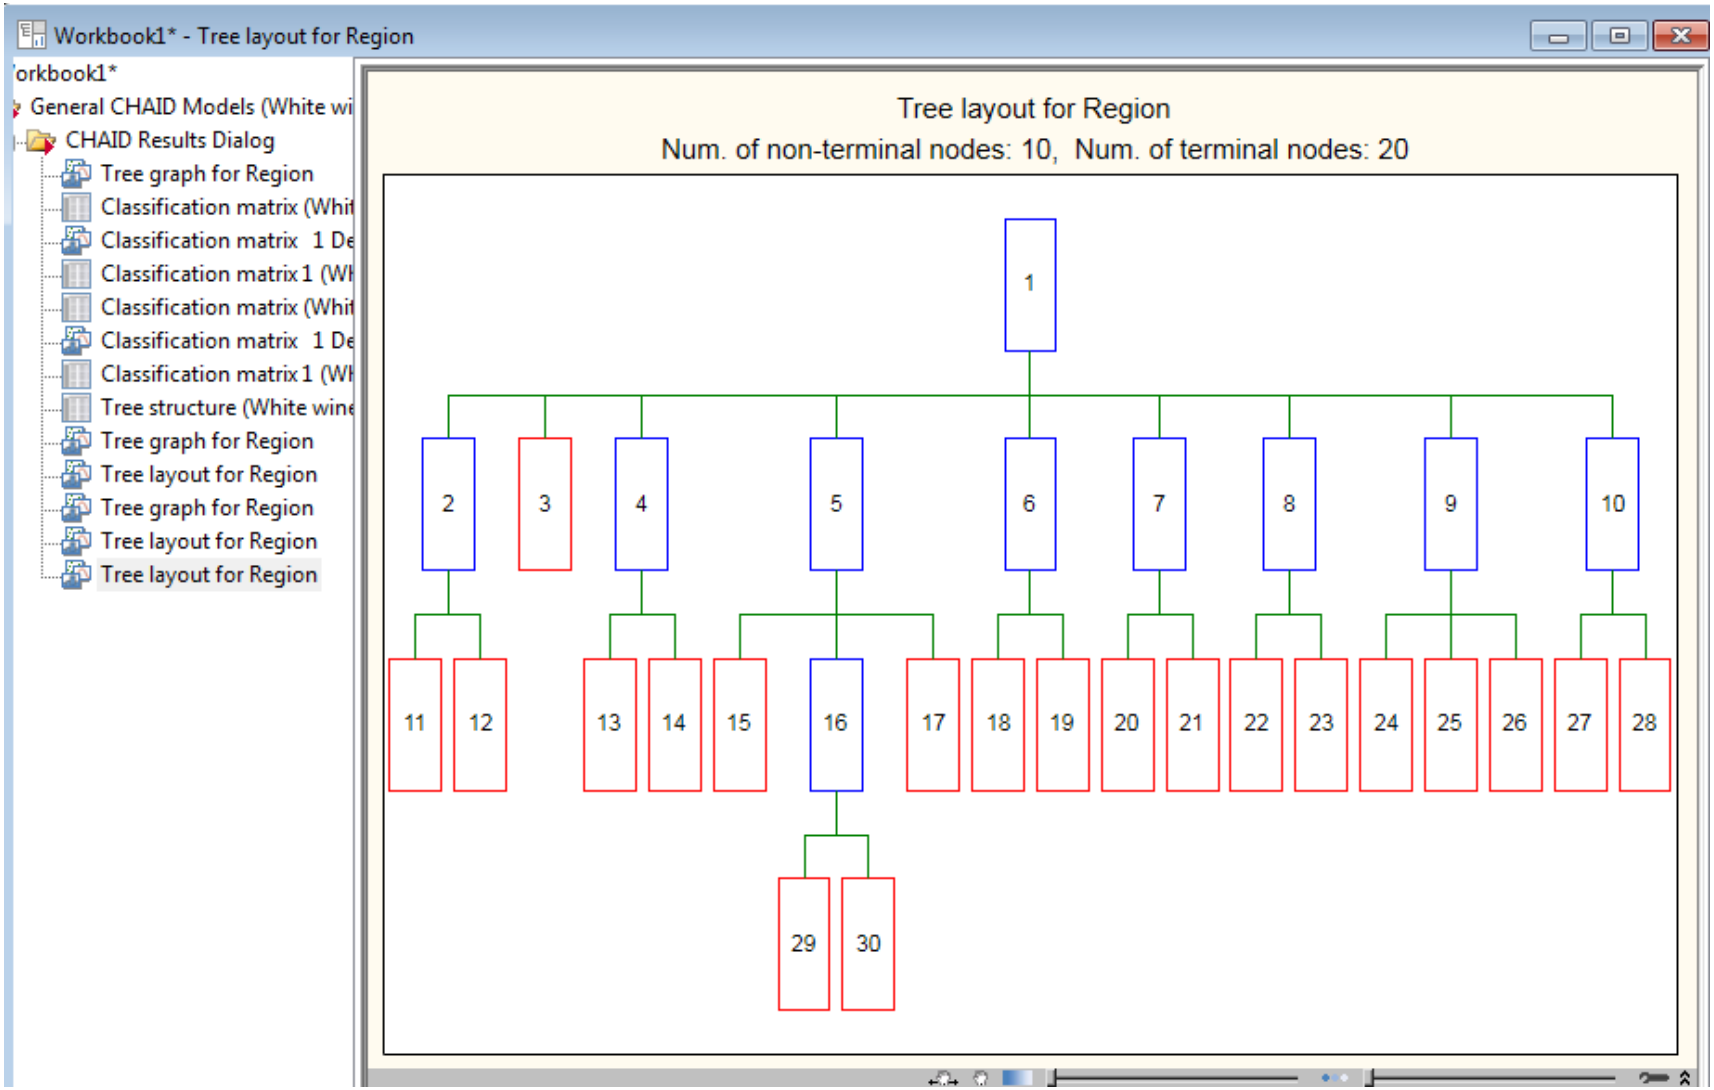


Рис.2.2.9

Если в диалоговом окне на рис.2.2.7 нажать на кнопку Tree browser, то появится структурное представление всех вершин с детальным описанием условий перехода к ним при помощи вертикальной и горизонтальной прокрутки. Например, на рисунке изображена информация по высвеченной слева вершине 2. В ней 14 образцов, из гистограммы видно, что 2 образца из Таманской, 12 из Черноморской зоны. Над гистограммой приведены условия расщепления на 11 и 12 вершины по Li.



Если в диалоговом окне на рис.2.2.7 нажать на кнопку Tree Layout в рабочей книге появится рисунок с изображением структуры нумерации вершин дерева



По табл.2.2.4 можно судить о количественном региональном составе образцов в терминальных вершинах. Так в вершине 11 все 12 образцов Черноморской зоны, в вершине 12 оба образца Таманской зоны, в вершине 3 – все 28 образцов также Таманской зоны и т.д. В последнем столбце Gain приведено общее количество образцов вин в вершинах. Во всех терминальных вершинах образцы отнесены к одному какому-либо региону, это объясняется тем, что в обучающей выборке нет ошибочных классификаций.

При подключении к процедуре построения дерева V-кратной кросс-проверки не произошли изменения ни в структуре дерева, ни в результатах классификации. Если выключить проверку на тестовой выборке, сохранив кросс-проверку, в обучающей выборке, состоящей из всех 153 образцов вин, ошибочных классификаций не будет.

Таким образом, мы рассмотрели технологию работы с модулем General CHAID Models и установили, что метод CHAID, несмотря на ориентацию обработки больших объемов данных все же успешно решил задачу классификации с небольшим количеством наблюдений.

Таблица 2.2.4. Терминальные вершины

	Results for terminal nodes (White wines1) Dependent variable: Region Options: Categorical response				
	Class Taman	Class Anapa	Class South foothill	Class Black Sea	Gain
11	0	0	0	12	12,00000
12	2	0	0	0	2,00000
3	28	0	0	0	28,00000
13	0	4	0	0	4,00000
14	10	0	0	0	10,00000
15	10	0	0	0	10,00000
29	0	1	0	0	1,00000
30	0	0	1	0	1,00000
17	0	0	0	2	2,00000
18	6	0	0	0	6,00000
19	0	0	8	0	8,00000
20	0	0	9	0	9,00000
21	5	0	0	0	5,00000
22	0	0	7	0	7,00000
23	0	0	0	7	7,00000
24	0	4	0	0	4,00000
25	0	0	0	7	7,00000
26	3	0	0	0	3,00000
27	3	0	0	0	3,00000
28	0	6	0	0	6,00000

Метод Интерактивные деревья

Модуль Interactive Trees (C&RT, CHAID) строит деревья классификации и регрессии C&RT, или CHAID на основе их алгоритмических методов и определяемых пользователем правил и критериев, либо их комбинации, задаваемые через высокоинтерактивный графический пользовательский интерфейс. Цель модуля – предоставить высокоинтерактивную среду для построения деревьев классификации или регрессии, чтобы пользователи самостоятельно могли опробовать различные предикторы и критерии разделения в сочетании с почти всеми функциями автоматического построения дерева, предусмотренными в методах C&RT или CHAID программы STATISTICA.

Если в меню окна на рис.2.1.2 щелкнуть по названию модуля, то откроется окно Interactive Trees (рис.2.3.1), в левой части которого можно выбрать тип анализа – классификационный анализ, или регрессионный анализ. В правой части указаны методы – C&RT, CHAID и Exhaustive CHAID (общий CHAID). В последнем методе реализованы опции, аналогичные модулю CHAID with coded design.

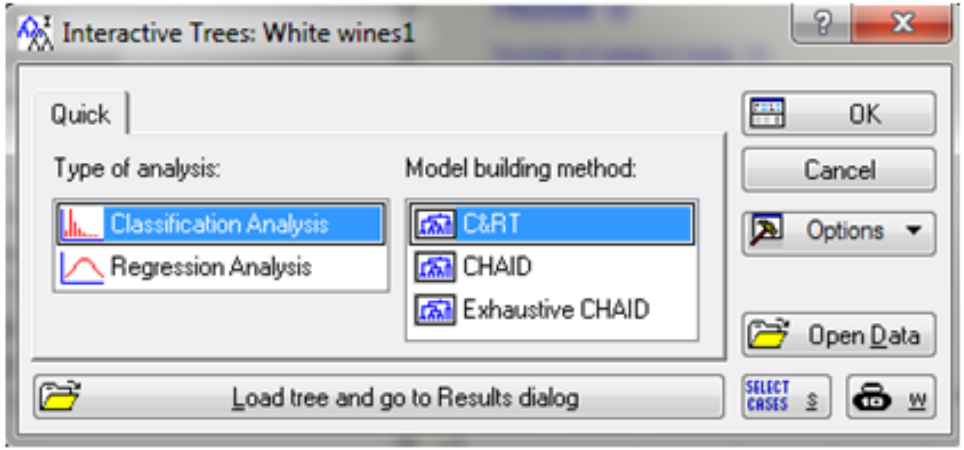


Рис.2.3.1

Основное отличие программной реализации данного модуля от выше названных методов в наличии вкладки Manager (рис.2.3.2), в котором реализован весь интерактивный функционал – многочисленные параметры «роста» (grow) и «обрезки», или усечения (prune) дерева, просмотра дерева и просмотра вершин (узлов) текущего дерева [7]. Рост, или усечение можно выбрать посредством рамки Tree (grow, prune) в верхней части окна. Чтобы вырастить отдельные ветви, начиная с определенного узла, следует выбрать параметры в рамке Node/branch (узел/ветвь). Рассмотрим функционал процедур (кнопок) в указанных рамках.

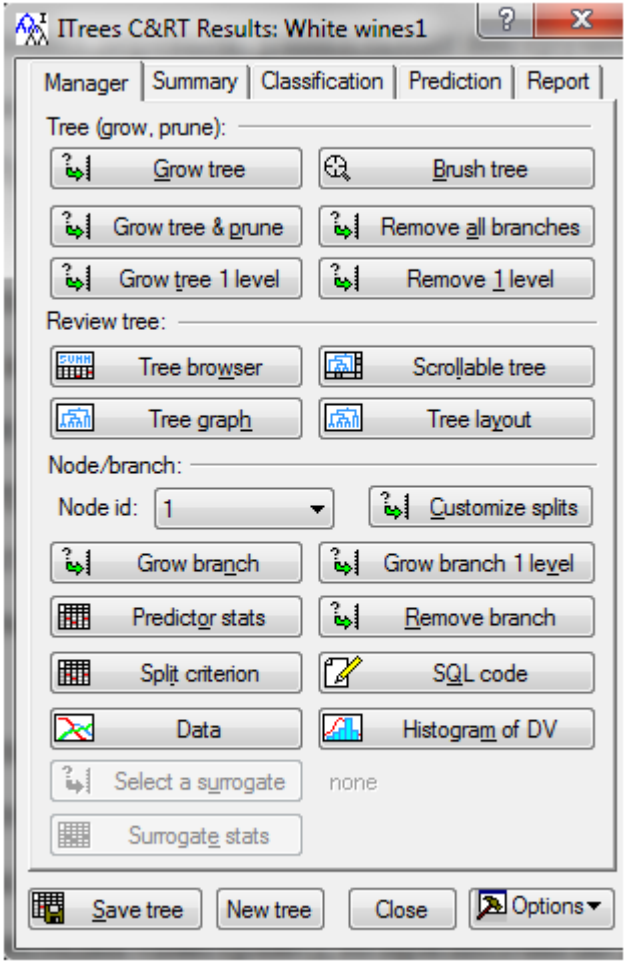


Рис.2.3.2

Grow tree (выращивайте дерево) автоматически увеличивает текущее дерево, используя все текущие настройки. После выращивания дерева можно его визуализировать и проанализировать, используя средства просмотра, заданные в рамке Review tree.

При помощи **Grow tree & prune** можно вырастить дерево и подрезать (усечь), чтобы выбрать дерево нужного размера с учетом критериев усечения, указанных на вкладке Stopping. Этот параметр доступен только для деревьев классификации и регрессии метода C&RT. В деревьях классификации и регрессии после автоматического выращивания дерева целесообразно его обрезать до меньшего размера, чтобы избежать переобучения и получить дерево с хорошей прогностической достоверностью.

Grow tree 1 level позволяет вырастить дерево на один уровень ниже от каждого из текущих терминальных узлов. Новые ветви будут расти с использованием всех заданных текущих настроек.

Brush tree (кисть дерева) является одним из средств отображения и интерактивной чистки текущего дерева.

Remove all branches удаляет все ветки и позволяет пользователю начать строить новое дерево после удаления всех ранее выросших ветвей.

Remove 1 level удаляет из дерева один уровень или набор ветвей, соединяющихся с терминальными узлами.

Tree browser позволяет, как описывали ранее, получить полное представление о дереве, подобно рабочей книге STATISTICA, где каждый узел представлен графиком, содержащим соответствующее правило разделения (если соответствующий узел не является конечным узлом) и различные сводные статистические данные. Промежуточные и конечные узлы будут отображаться в браузере разными символами:

Denotes a split node – обозначает разделенный узел; Denotes a terminal node – конечный узел.

Как выше было замечено, параметры рамки **Node/branch** предназначены для просмотра отдельных вершин, чтобы точно указать, как вырастить ветви от выбранного узла.

Node id обозначает номер (идентификатор) вершины. Из предлагающегося списка следует выбрать номер вершины, для которого будут отображаться соответствующие результаты, выбранные из опций, описанных в рамке **Node/branch**.

Customize splits отображает диалоговое окно выбора предиктора и назначение условия ветвления. Эта опция дает пользователю полный контроль над тем, как выращивать ветви дерева. Точный вид диалогового окна будет зависеть от метода построения модели, выбранного на панели запуска интерактивных деревьев. Для C&RT, где разрешено только бинарное расщепление, можно точно указать, как разделить соответствующие непрерывные и/или категориальные предикторы для получения двух ветвей. Например, если в появившемся окне при помощи опции Select predictor выбрана непрерывная переменная (Sr) (рис.2.3.3), то при помощи прокрутки Split criterion for continuous predictor, или окна справа, можно указать значение предиктора в соответствии с которым, будет происходить рост дерева. Например, если Sr < 806,99, то переходим к левой ветви, в противном случае – к правой ветви.

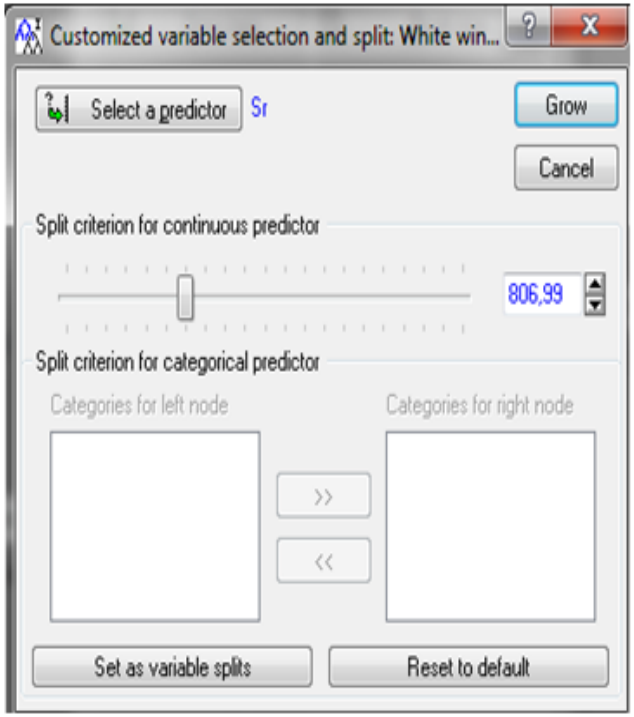


Рис.2.3.3

Если в окне Select predictor выбрана категориальная переменная, например Sort, то станет активной рамка **Split criterion for categorical predictor** (рис.2.3.4), в которой следует указать значение сорта для перехода по левой ветви (Muscat) и правой (Chardonnay, Riesling).

Для деревьев CHAID, где каждый узел может вырасти в более двух ветвей, можно указать количество расщеплений и способ их создания для каждой непрерывной и/или категориальной переменной.

Grow branch (расти ветвь) в отличие от **Grow tree** выращивает ветвь от выбранного узла, как указано в поле Node ID, при необходимости увеличивает дочерние ветви в соответствии с установками принятыми на вкладках модуля. Если при этих настройках дальнейшее разбиение невозможно, то нажатие этой кнопки не приведет к изменению дерева.

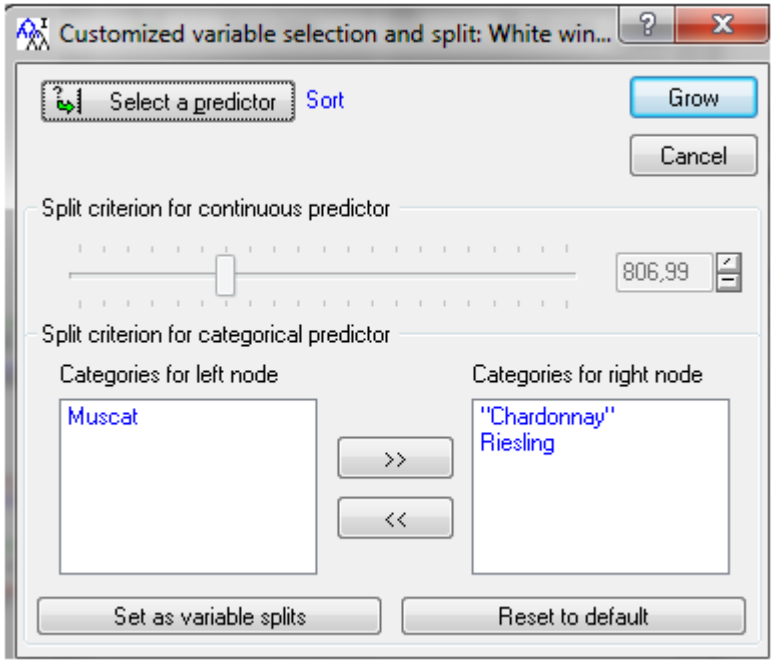


Рис.2.3.4

Grow branch 1 level выращивает ветвь на один уровень от узла, указанного в поле Node ID. В отличие от опции Grow branch, описанной выше, эта опция создаст только одно разбиение, то есть вырастет дерево из выбранного узла только на один уровень в соответствии с установками принятыми на вкладках модуля. Если при этих настройках дальнейшее разбиение невозможно, то нажатие этой кнопки не приведет к изменению дерева.

Remove branch удаляет все ветки, исходящие от узла, указанного в поле Node ID.

Predictor stats отображает электронную таблицу со статистикой предикторов для текущего узла. В каждом узле может быть вычислена конкретная статистика, чтобы оценить, какой предиктор даст наилучшее разбиение или наибольшее улучшение общего соответствия модели. Конкретная статистика, которая будет выводиться, зависит от метода построения модели (C&RT/CHAID/ Exhaustive CHAID), а также от типа анализа – классификационный, или регрессионный анализ.

Split criterion отображает сводную таблицу результатов с информацией о точном разбиении на узле указанном в поле ID узла. Эта таблица покажет в зависимости от того категориальный, или непрерывный предиктор используется в этом узле, категории или условие расщепления.

SQL Code генерирует правила для классификации наблюдений по узлу, выбранному в поле Node ID в форме кода SQL. Чтобы сгенерировать код SQL для всех оконечных узлов, следует использовать аналогичную команду на вкладке Report.

Data отображает электронную таблицу, содержащую все данные по предикторам наблюдений, принадлежащих узлу, выбранному в поле Node ID. Одновременно с этим для выбранного узла будет создан график, показывающий набор значений по переменным-предикторам для наблюдений, принадлежащих этому узлу.

Histogram of DV строит гистограмму, характеризующую количественный состав классов в данном узле.

Для визуализации дерева, после каких либо действий по «обрезке», или «росту» дерева, следует воспользоваться средствами визуализации, предусмотренными на данной вкладке – кнопками **Tree graph**, **Scrollable tree**, **Tree layout**.