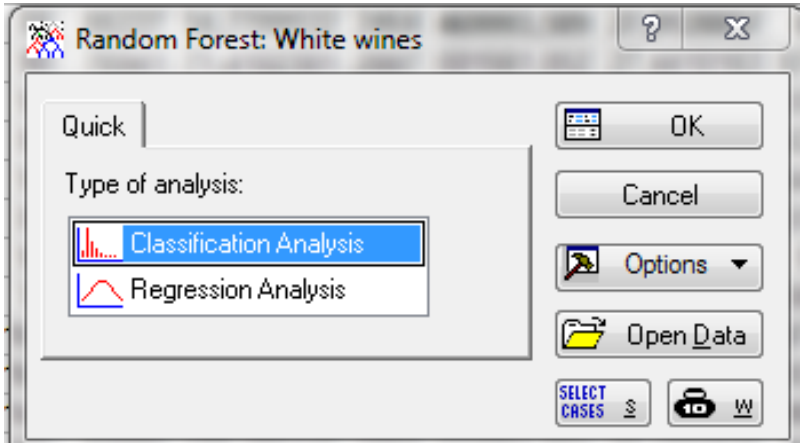
Лекция 5. Случайный лес (*Random Forest*) регрессии и классификации

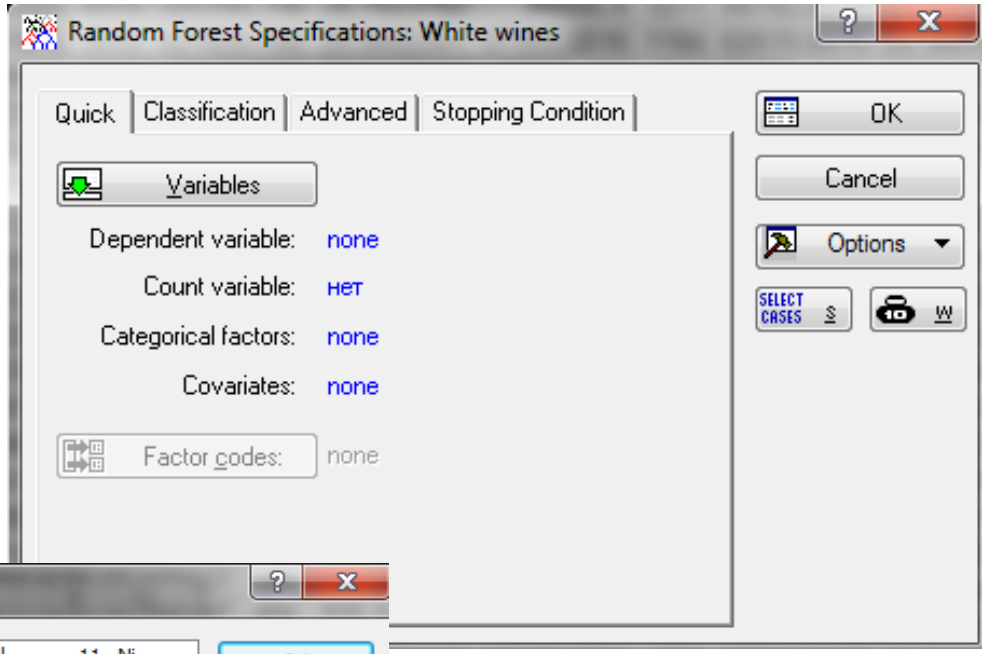
Метод ***Random Forest***, как ***Boosted Trees*** является ансамблевым, но использует технику бэггинга, которая предполагает построение простых независимых моделей и усреднение их решений за счет, например вычисления среднего арифметического в задаче регрессии, или голосования в задаче классификации. Для задач классификации этот ответ принимает форму принадлежности к классу, которая связывает набор значений предикторов с одной из категорий, присутствующих в категориальной зависимой переменной. В качестве альтернативы для задач регрессии ответ дерева представляет собой оценку зависимой переменной – непрерывного отклика с учетом значений предикторов. Особенность метода в том, что решение каждого дерева зависит от случайного набора **значений предикторов**, выбранных независимо и с одинаковым распределением для всех деревьев в лесу, который является подмножеством значений предикторов исходного набора данных. Основной принцип построения деревьев случайным лесом в **независимости моделей друг от друга**. Если вновь для лучшего понимания вернуться к футболу, то построение деревьев соответствовало бы игре при условии, что каждый случайно выбранный игрок (**аналог случайного набора предикторов**) самостоятельно без помощи других игроков команды решает задачу забивания мяча в ворота противника. Модуль STATISTICA ***Random Forest*** представляет собой реализацию алгоритма *Random Forest*, разработанного Брейманом. У пользователя есть **полный контроль** над всеми ключевыми аспектами процедуры оценки и параметрами модели.

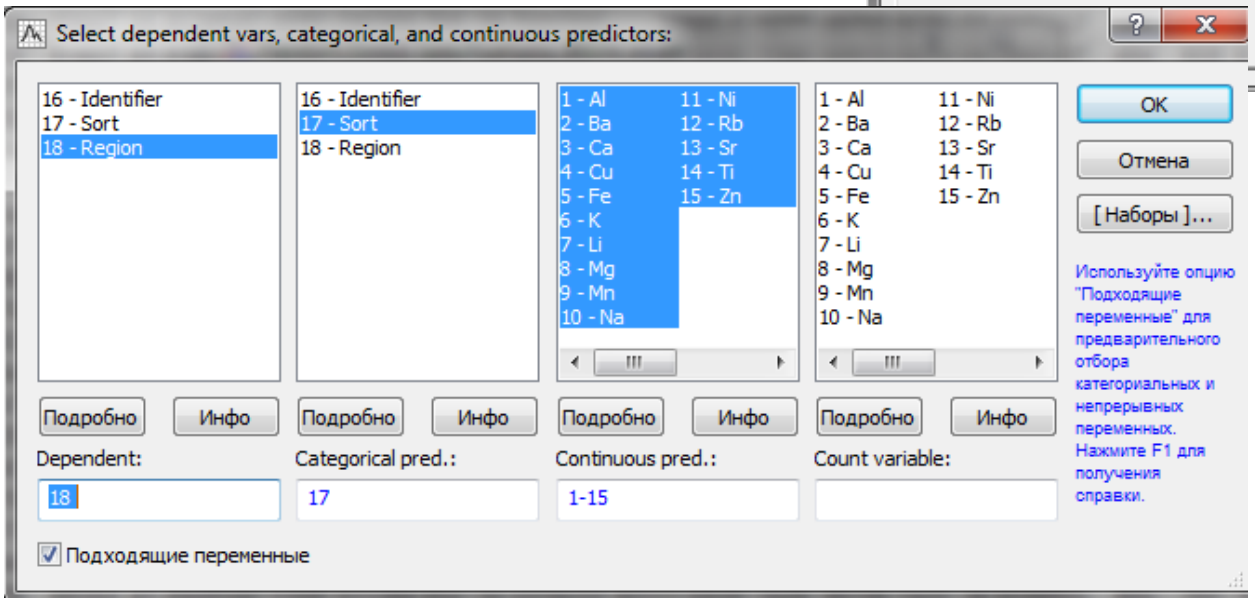
Это и **сложность деревьев**, подогнанных под данные, **максимальное количество деревьев** в лесу, контроль над тем, **как остановить алгоритм ветвления** при достижении удовлетворительных результатов, и т. д.

Пользователь также, как и в предыдущем методе может указать **независимую выборку** для тестирования, чтобы оценить прогностическую достоверность построенной модели. Если пользователь не указал тестовую выборку, программа самостоятельно произведет разбиение на обучающую и тестовую выборки по умолчанию в соотношении 70% и 30%.

Перейдем к практической реализации метода. В меню Data Mining выберем модуль Random Forest for Regression and Classification. Опции вкладки Quick и Classification совпадают с опциями тех же вкладок модуля Boosted Tree Classifies and Regression на рис.2.4.1, 2.4.2. Непосредственно со структурой и спецификой метода связаны две другие вкладки – Advanced и Stopping Condition, хотя установочные параметры на вкладке Advanced также во многом совпадают. Опишем те, которые имеют функциональные отличия.







На вкладке Advanced в рамке Random Forest options предусмотрена возможность назначения параметров случайного леса. На рис.2.5.1 показаны рекомендуемые модулем параметры по умолчанию:

– Number of predictors определяет количество случайно выбранных предикторов в строящемся лесе деревьев. В модуле оптимальный размер подмножества переменных предикторов определяется как $\log_2$ M+1, где M – количество предикторов в исходных данных. В нашем случае M=16, следовательно, $\log_2 16+1 = 5$. Модуль при выращивании леса придерживается этого количества, если другие параметры также приняты по умолчанию, в частности Minimum n in Child node = 5. Если мы хотим достичь лучших прогностических свойств леса и уменьшим, то программа вынуждена привлечь большее количество предикторов для построения деревьев леса;

– Number of trees обозначает количество простых деревьев классификации, которые будут строиться на последовательных этапах выращивания леса;

– Random test data proportion задает долю случайно выбранных наблюдений, которая будет служить в качестве тестовой выборки. Опция применима только в том случае, если кнопка Test sample установлена в режиме off;

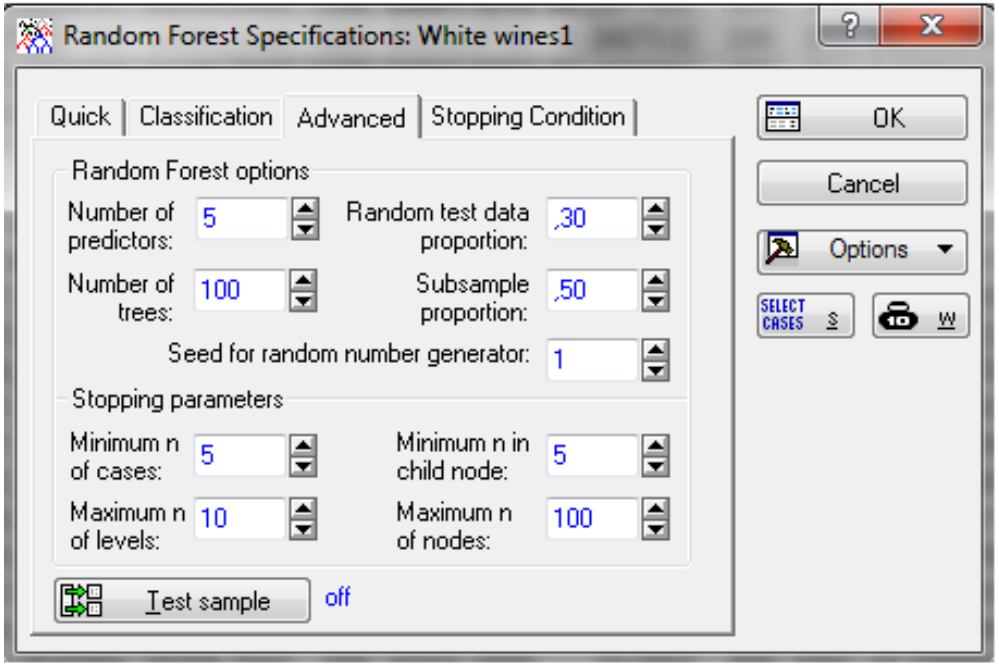


Рис.2.5.1

– Subsample proportion определяет долю выборки, которая будет использоваться при построении случайных обучающих выборок для последовательных шагов роста деревьев леса.

– Minimum n of cases (минимум n случаев) один из способов управления расщеплением, который разрешает продолжение расщепление до тех пор, **пока вершины дерева классификации содержат более чем заданное минимальное число наблюдений,** по умолчанию – 5;

– Maximum n of levels (максимум n уровней) используется для остановки на основе количества уровней в дереве. Каждый раз, когда родительский узел расщепляется, проверяется общее количество уровней, т.е. глубина дерева, измеренная от корневого узла, и разбиение останавливается, если это число превышает число, указанное в данном поле, по умолчанию 10;

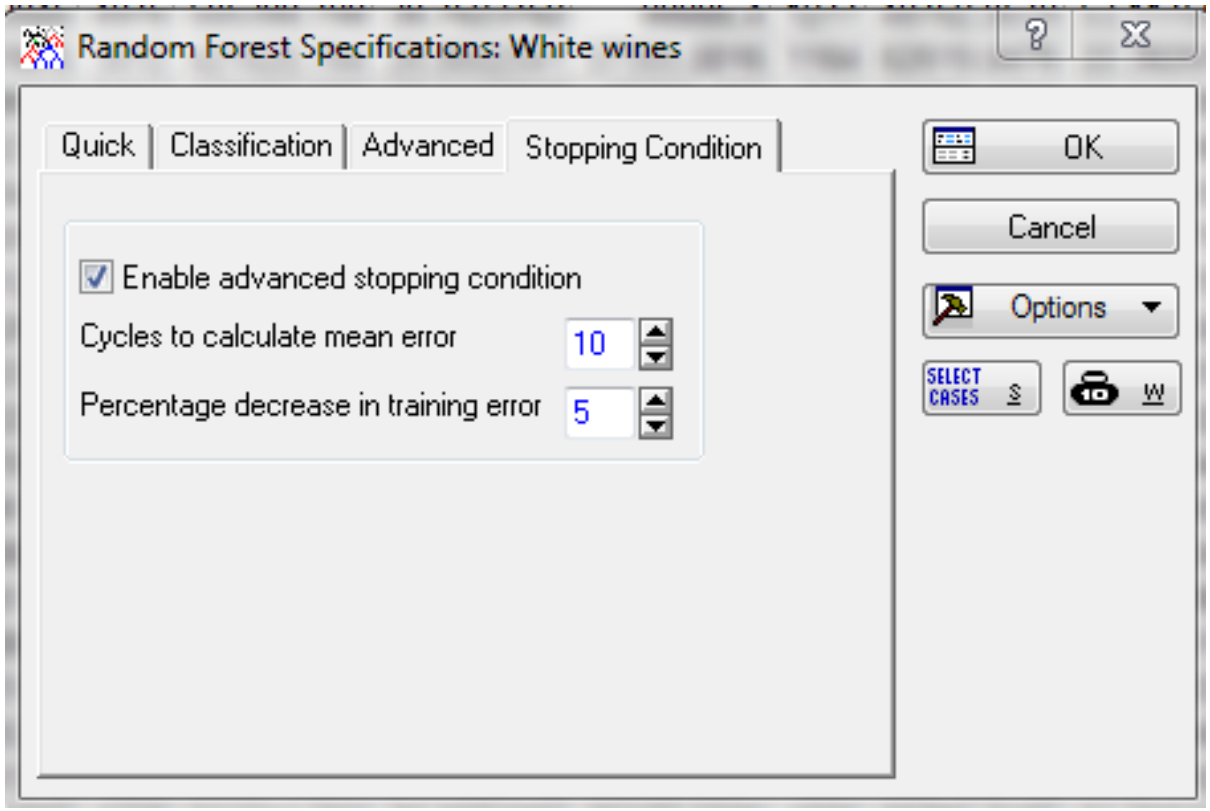
– Minimum n in child node (минимум n в дочернем узле). Как выше замечено программа строит случайный лес из простых деревьев с небольшим количеством узлов, но если лес не обеспечивает хорошие прогностические свойства, то целесообразно увеличить число ветвлений дерева. Одним из способов является уменьшение параметра n, принятого по умолчанию равным 5. **Заметим, что увеличение сложности простых деревьев может привести к автоматическому уменьшению количества построенных деревьев.**

Функциональные возможности кнопки Test sample идентичны одноименной кнопке модуля Boosted Tree Classifies and Regression.

Опция *Циклы для вычисления средней квадратичной ошибки* определяет количество циклов, в течение которых должно наблюдаться улучшение прогностических свойств леса, т.е. уменьшаться ошибка. Обучение останавливается в том случае, если ошибка не уменьшилась в течение указанного количества циклов.

Опция *Процентное уменьшение ошибки обучения* указывает минимальный процент улучшения, т.е. снижения ошибки, который необходимо сделать, чтобы программа решила, что произошло уменьшение ошибки. Если процент улучшения падает ниже этого уровня, обучение прекращается.

Оставим дополнительные параметры остановки без изменения и щелкнем по ОК.



Воспользовавшись установками параметров выращивания леса по умолчанию, в соответствии с диалогом на рис.2.5.1, щелкнем по кнопке ОК. Вкладка Quick диалога Random Forest Results имеет вид, представленный на рис.2.5.2. Для визуализации доли ошибочной классификации (Misclassification rate) для всех 100 выращенных деревьев леса воспользуемся кнопкой Summary.

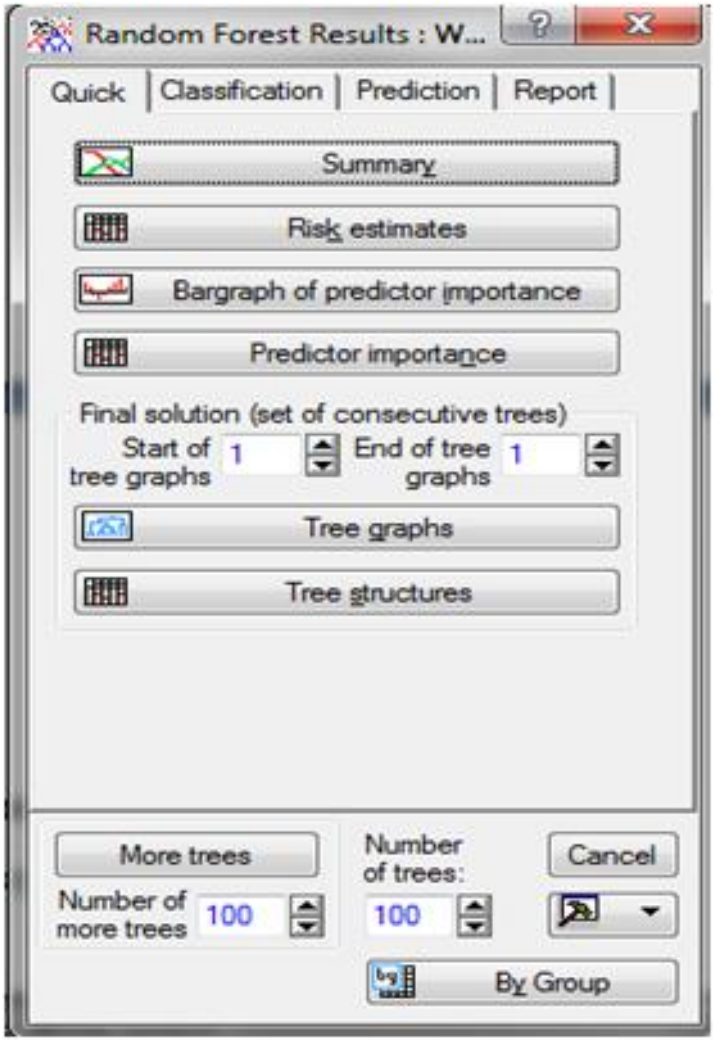


Рис.2.5.2

Из графика на рис.2.5.3 видно, что с увеличением номеров деревьев с 1 до 13 доли ошибочной классификации ансамбля уменьшаются, далее возрастают примерно до 20 дерева, стабилизируясь на определенном уровне относительно значения 0,25 для тестовой выборки и 0,11 для обучающей выборки. При этом наилучшими прогностическими свойствами обладает ансамбль из 13 деревьев. Оценки риска для обучающей и тестовой выборки приведены в табл.2.5.1. Они равны доле ошибочной классификации тестовой и обучающей выборок (рис.2.5.3) случайного леса из 100 деревьев. Напомним, что выбор категорий классификации каждому объекту определяется голосованием по всему ансамблю (лесу деревьев).

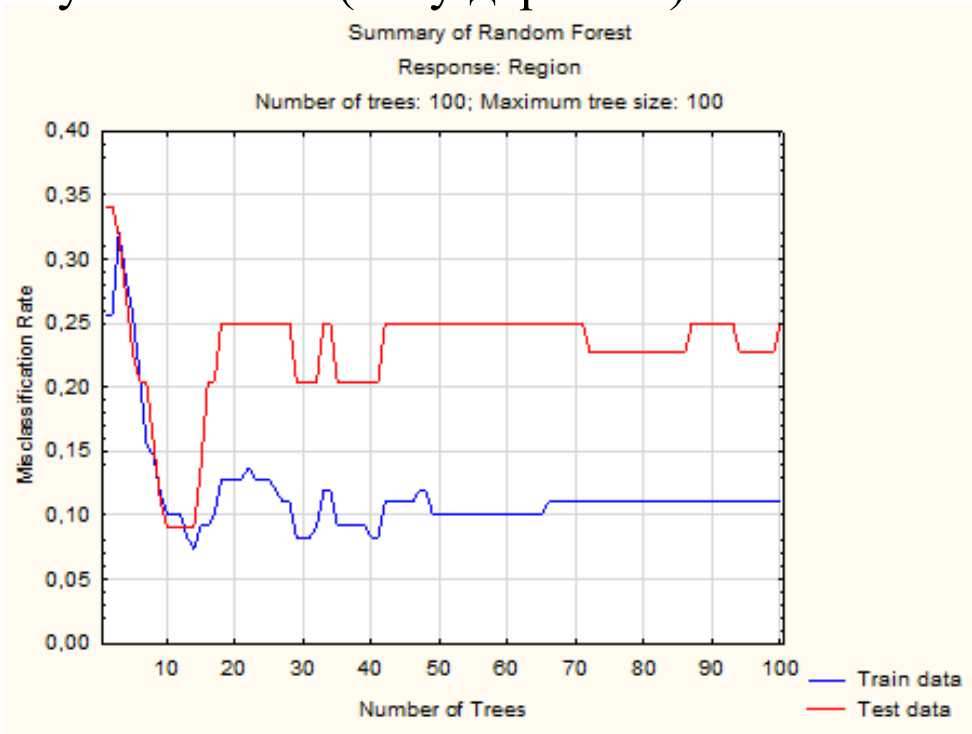


Рис.2.5.3

В окнах на рис.2.5.2, регламентирующих номера деревьев для их графического представления оставим значения 1 без изменения и нажмем на кнопку Tree graphs. Как видим (рис.2.5.4) **изображено** достаточно простое четырехуровневое бинарное дерево классификации с числом вершин, равным 9, из которых 5 терминальные. В дереве задействовано всего 4 предиктора. Следует обратить внимание, что в соответствие с установкой Minimum n in child node =5, во всех дочерних вершинах, включая терминальные вершины, **кроме вершины 9,** количество образцов вин больше 5. **Обратите внимание, что дерево строилось по 51 образцу вин (правый верхний угол корневой вершины), что соответствует примерно 50% из автоматически выделенной обучающей выборки в 109 образцов (см. следующий слайд)**

Таблица 2.5.1. Оценки риска для обучающей и тестовой выборки

	Risk estimates (White wines1) Response: Region	
	Risk Estimate	Standard error
Train	0,110092	0,029980
Test	0,250000	0,065279

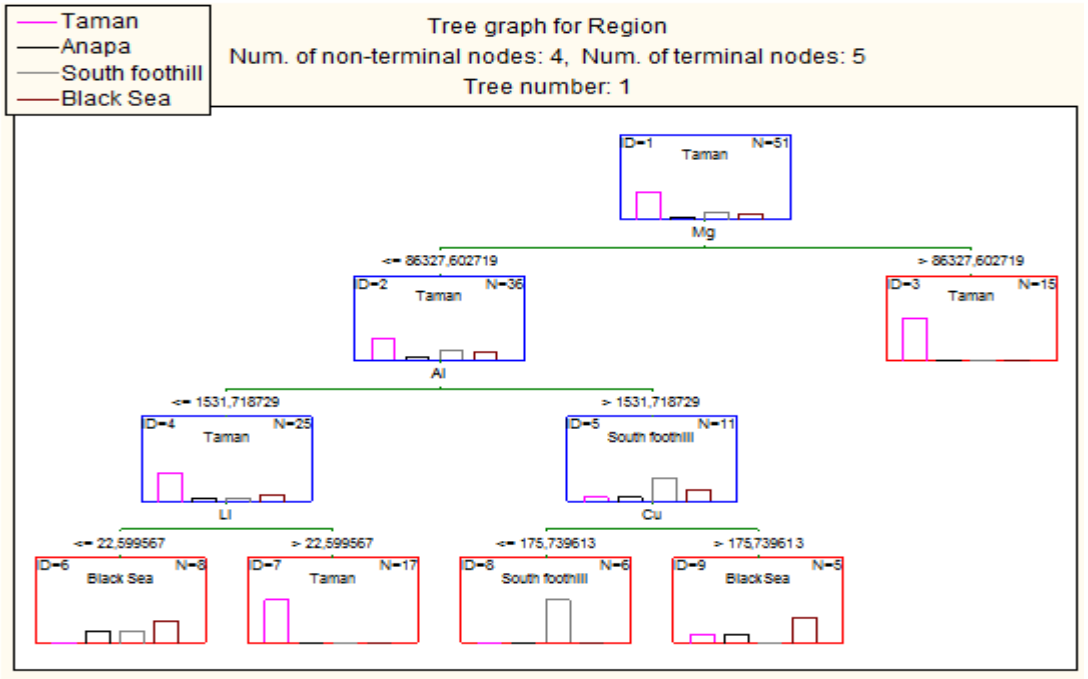


Рис.2.5.4

Оценки риска принимают немалые значения, поэтому не следует ожидать хороших прогностических возможностей леса.

Для анализа результатов классификации перейдем на вкладку Classification, которая полностью идентична одноименной вкладке модуля Boosted Tree Classifies and Regression. В табл.2.5.2, 2.5.3 приведены результаты классификации тестовой (44) и обучающей (109) выборок, **что примерно соответствует 30% и 70% в соответствии с установками на вкладке Advanced рис.2.5.1**. Легко видеть, что в тестовой и обучающей выборке соответственно 11 и 12 ошибочных классификаций.

Доля (цена) ошибочной классификации для обучающей и тестовой выборки составили соответственно величины 11/44 = 0,25 и 12/109 = 0,11, равные рискам.

Таблица 2.5.2. Классификация тестовой выборки леса из 100 деревьев

	Classification matrix (White wines1) Response: Region Test set sample; Number of trees: 100			
	Class Predicted Taman	Class Predicted Anapa	Class Predicted South foothill	Class Predicted Black Sea
Observed Taman	19,00000			
Observed Anapa		4,000000		
Observed South foothill	2,00000		7,000000	
Observed Black Sea	7,00000		2,000000	3,000000

Таблица 2.5.3. Классификация обучающей выборки леса из 100 деревьев

	Classification matrix (White wines1) Response: Region Training set sample; Number of trees: 100			
	Class Predicted Taman	Class Predicted Anapa	Class Predicted South foothill	Class Predicted Black Sea
Observed Taman	54,00000			
Observed Anapa		13,00000	1,00000	
Observed South foothill	3,00000		18,00000	
Observed Black Sea	7,00000		1,00000	12,00000

Как видно из столбчатой диаграммы на рис.2.5.5 и таблицы (кнопки Bargraph of predictor importance и Predictor importance), наиболее важным предиктором для классификации является металл Al, наименее важным – Sort. Если сравнить данную диаграмму с диаграммами важности предикторов, построенными методами стандартный C&RT (рис.2.1.18) и Boosted Tree Classifies and Regression (рис.2.4.6), то можно обнаружить определенные сходства в оценке важности предикторов всеми 3 способами.

Если в диалоге на рис.2.5.1 указать Number of trees =13, то прогностические свойства ансамбля улучшатся, риски на обучающей и тестовой выборке составят 0,09 и 0,11, количество ошибочных классификаций соответственно – 10 и 5.

	Значимость предиктора (White wines) Отклик: Region	
	Перемен. Ранг	Значимость
Al	100	1,000000
Sr	90	0,896437
Li	90	0,895769
Fe	87	0,874289
Mg	86	0,860137
K	74	0,738346
Cu	72	0,719447
Rb	68	0,682108
Na	68	0,679446
Mn	66	0,660442
Zn	63	0,625336
Ni	62	0,621261
Ba	62	0,616638
Ti	60	0,599023
Ca	46	0,463173
Sort	45	0,450533

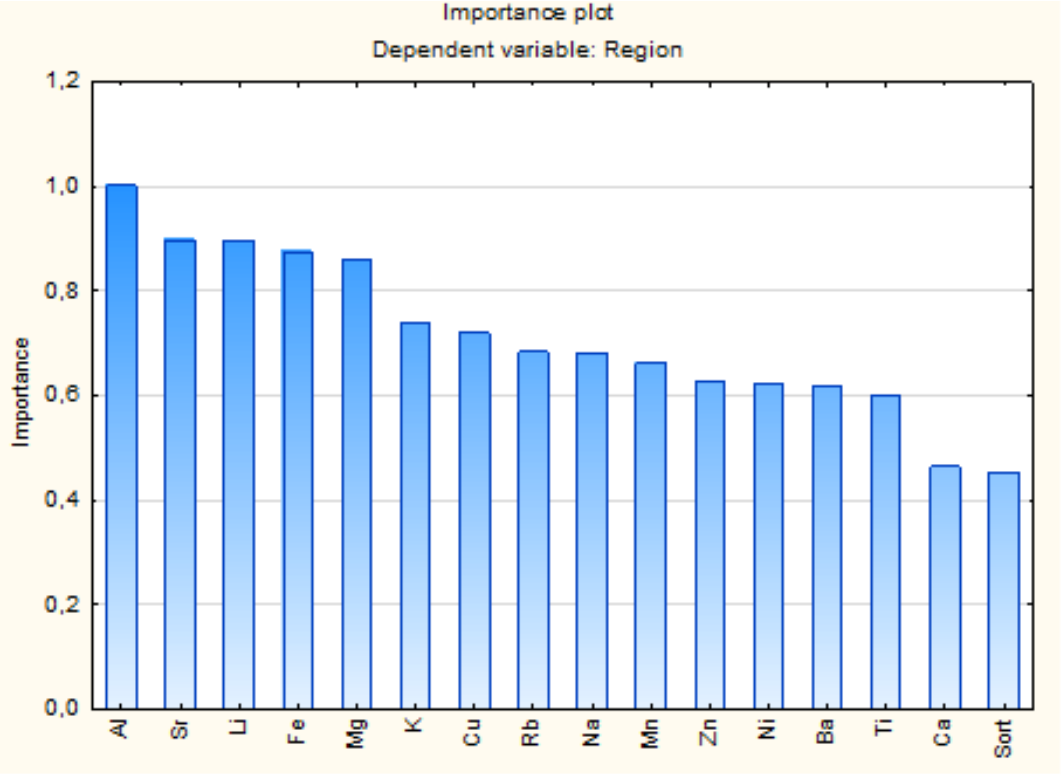


Рис.2.5.5

Попытаемся еще более улучшить предсказательные свойства метода, уменьшив количество наблюдений в поле **Minimum n in child node до 1**, в поле **Minimum n of cases до 1** (рис.2.5.6).

Программа построила лес, состоящий из 40 деревьев со значительно меньшими долями ошибочных классификаций в обучающей и тестовой выборке. Риски для обучающей и тестовой выборки леса из 40 деревьев составили 0 и 0,023.

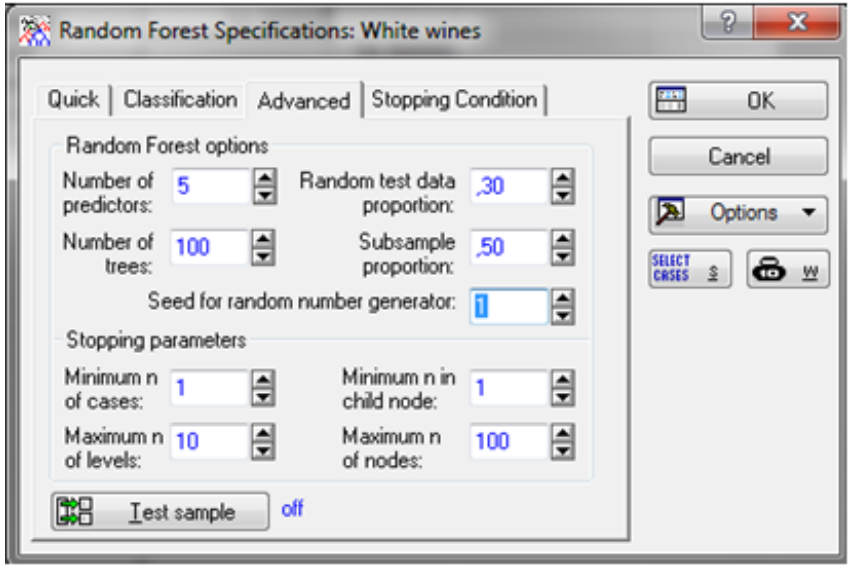
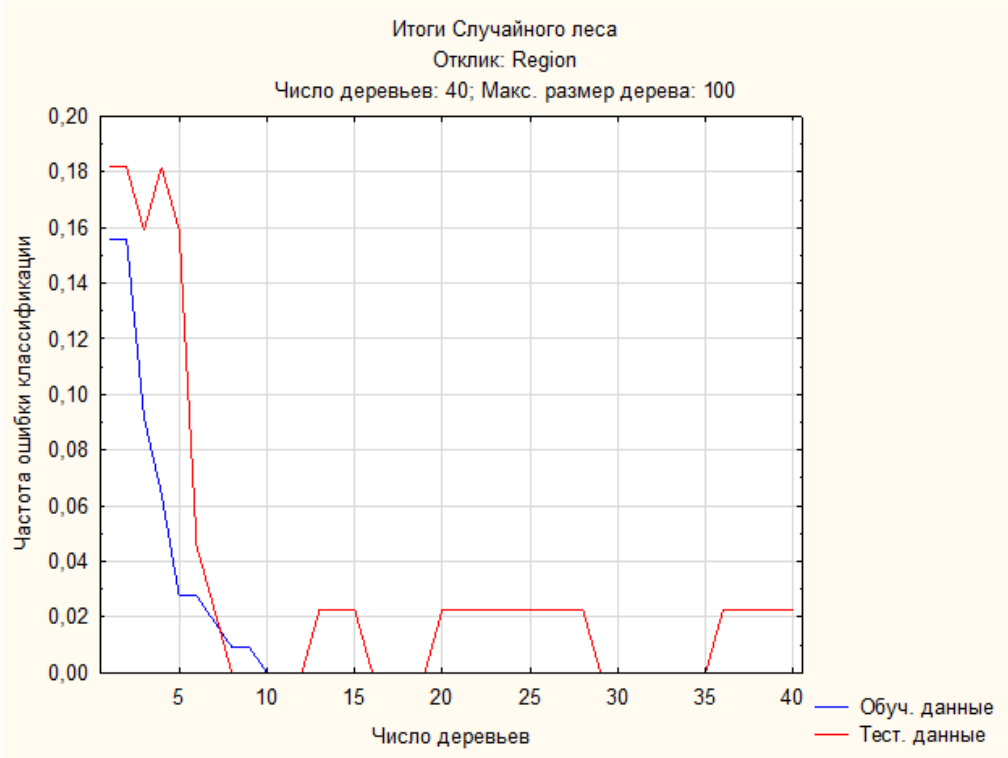
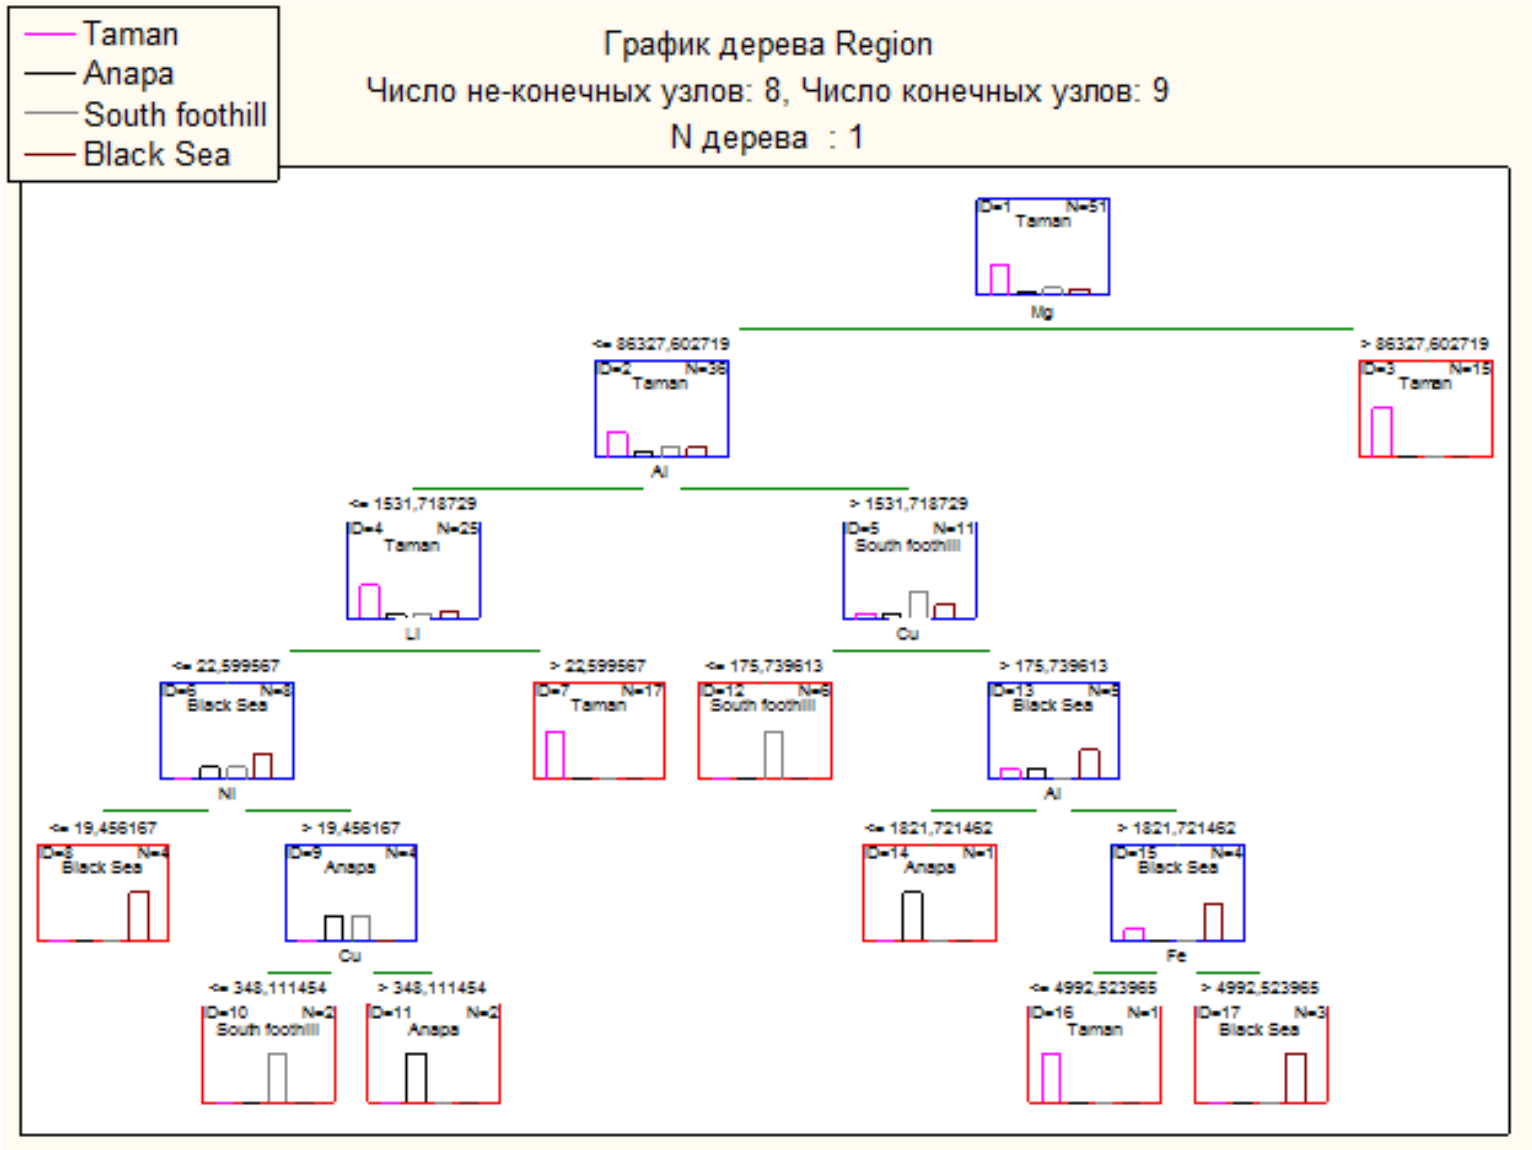


Рис.2.5.6

	Оценки риска (White wines) Отклик: Region	
	Риск Оценка	Станд. ошибка
Обучить	0,000000	0,000000
Крит.	0,022727	0,022468



Существенно изменились размеры построенных деревьев, как пример, на рисунке приведено дерево под номером 1. При этом программа построила не 100 деревьев, а всего 40.



Количество ошибочных классификаций тестовой выборки составило 1, обучающей – 0 (табл.2.5.4, 2.5.5).

Таблица 2.5.4. Классификация тестовой выборки лесом из 40 деревьев

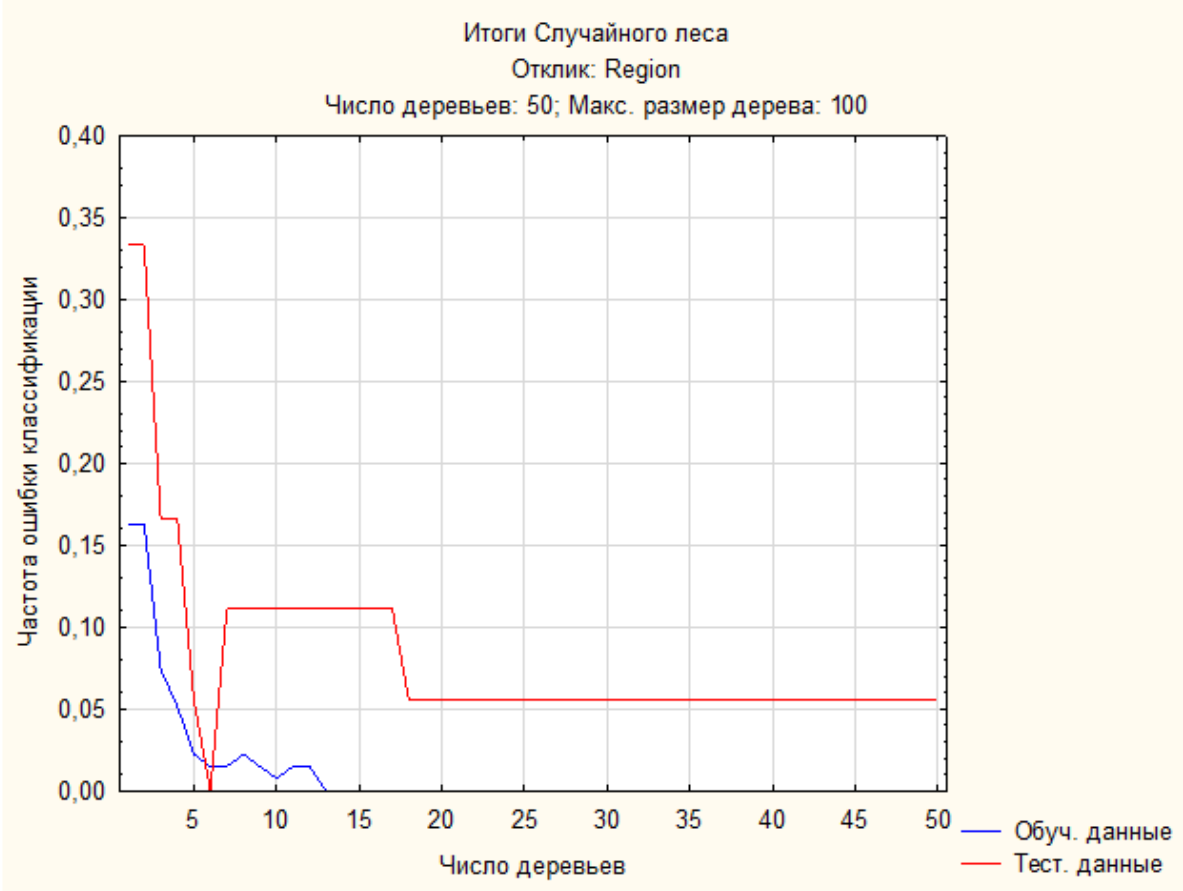
	Матрица классификации (White wines) Отклик: Region Тестовая выборка; Число деревьев: 40			
	Класс Предск. Taman	Класс Предск. Anapa	Класс Предск. South foothill	Класс Предск. Black Sea
Наблюд. Taman	19,00000			
Наблюд. Anapa		4,000000		
Наблюд. South foothill			9,000000	
Наблюд. Black Sea	1,00000			11,00000

Таблица 2.5.5. Классификация обучающей выборки лесом из 40 деревьев

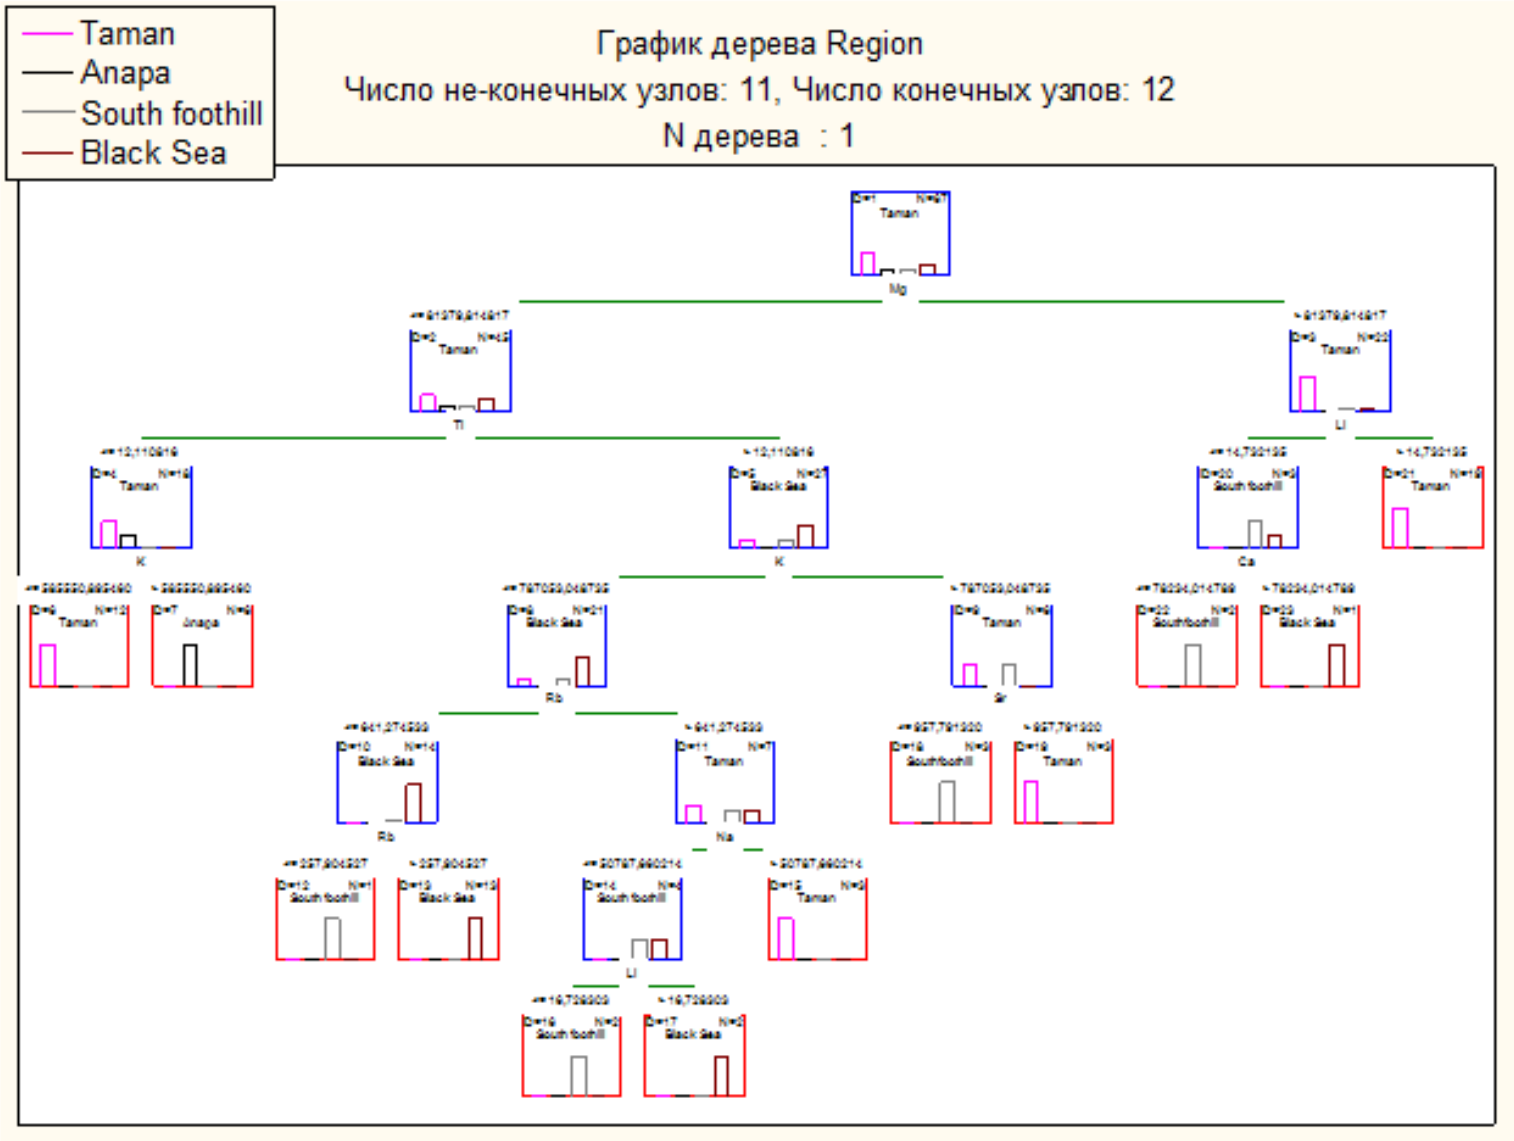
	Матрица классификации (White wines) Отклик: Region Обучающая выборка; Число деревьев: 40			
	Класс Предск. Taman	Класс Предск. Anapa	Класс Предск. South foothill	Класс Предск. Black Sea
Наблюд. Taman	54,00000			
Наблюд. Anapa		14,00000		
Наблюд. South foothill			21,00000	
Наблюд. Black Sea				20,00000

Построенная из 40 деревьев модель классификации сохранила определенную устойчивость при переходе к тестовой выборке, определяемой переменной Identifier, – количество ошибочных классификаций в тестовой и обучающей выборке не изменилось. Но, так как, изменилось количество наблюдений в обучающей (135) и тестовой (18) выборке, то изменились оценки риска обучающей и тестовой выборок. Также изменились и другие результаты анализа

	Оценки риска (White wines) Отклик: Region	
	Риск Оценка	Станд. ошибка
Обучить	0,000000	0,000000
Крит.	0,055556	0,053990

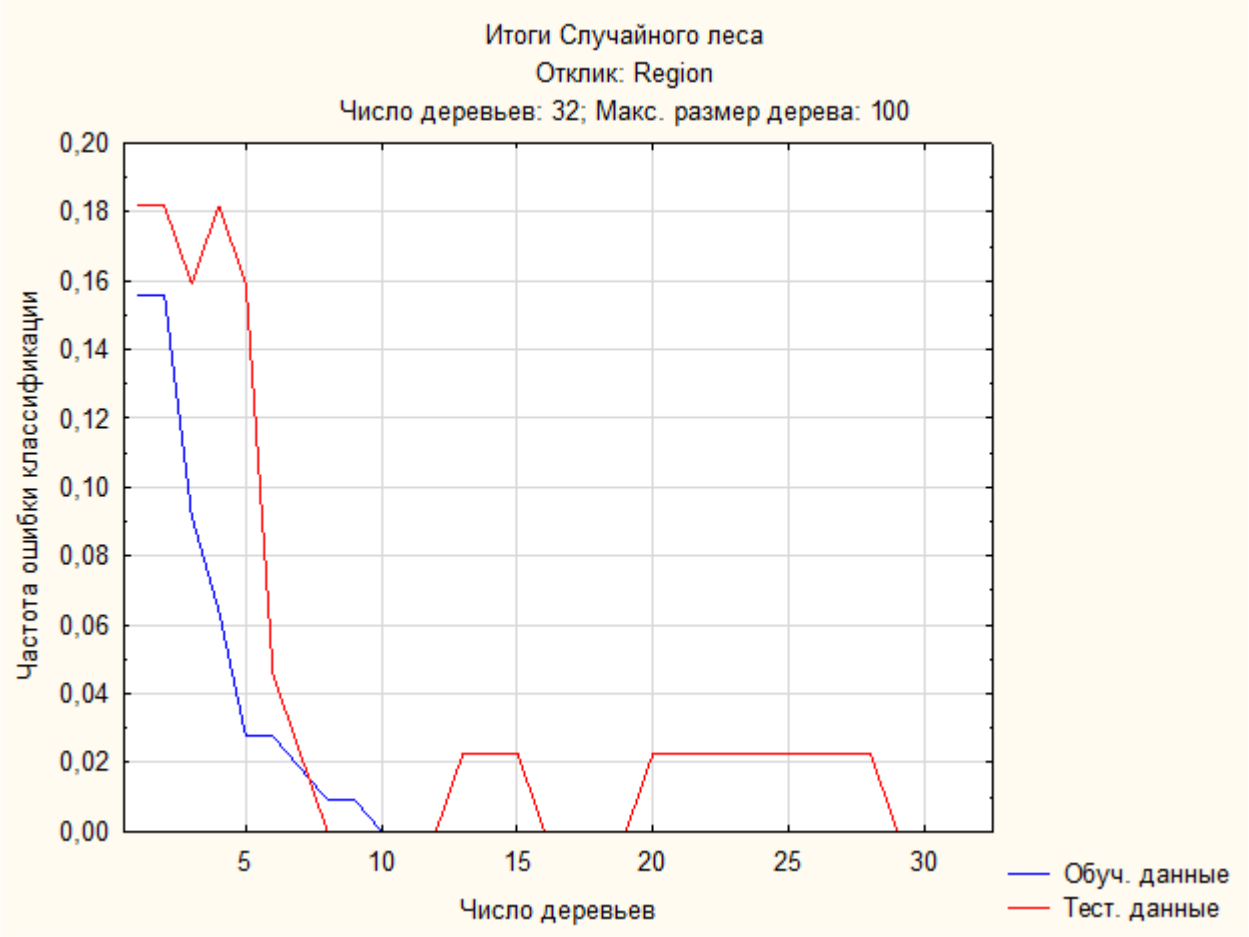


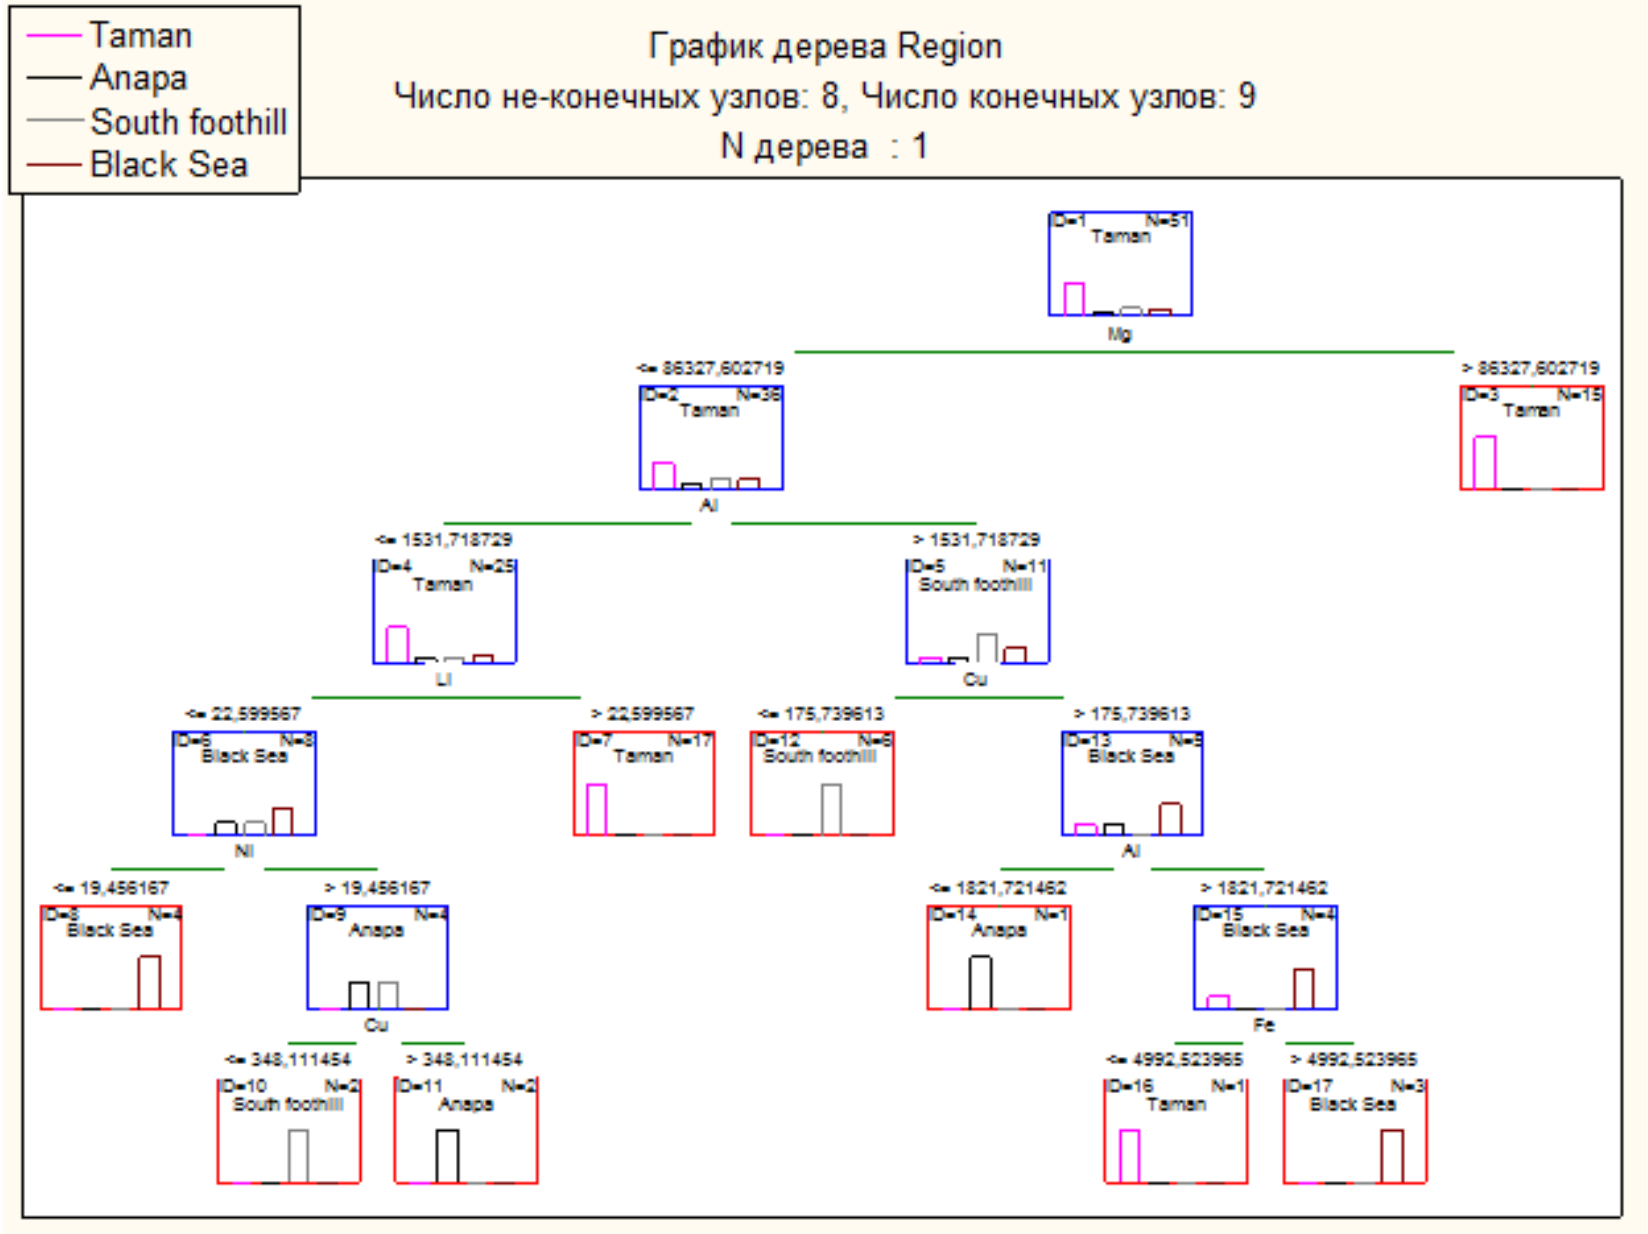
Программа ограничилась построением 40 деревьев за счет усложнения простых деревьев, так дерево 1 состоит из 7 уровней, содержит 23 узла, из которых 12 терминальных



Каждый из параметров на вкладке Advanced (рис.2.5.1) может влиять на прогностические свойства модели, выступая в роли оптимизатора модели. Так, улучшить предсказательные способности случайного леса можно уменьшением количества строящихся деревьев. Если при тех же установках, что и на рис.2.5.6, т.е. выключенной **тестовой выборке** уменьшить количество деревьев в поле Number of trees до 32, то можно добиться снижения количества ошибочных классификаций в тестовой и обучающей выборке до 0.

	Оценки риска (White wines) Отклик: Region	
	Риск Оценка	Станд. ошибка
Обучить	0,00	0,00
Крит.	0,00	0,00

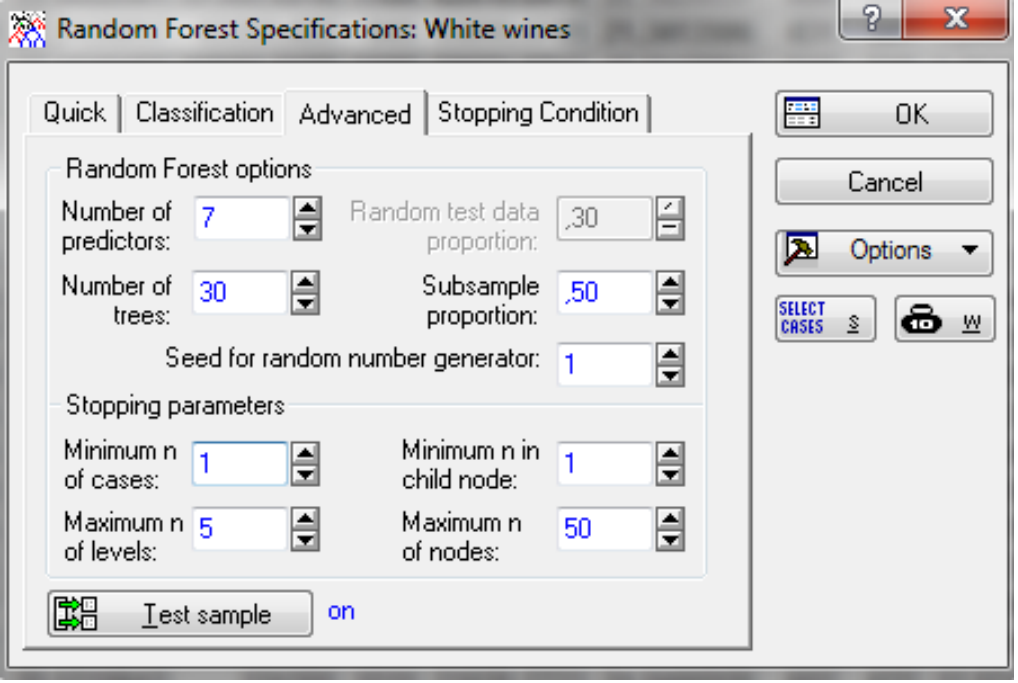


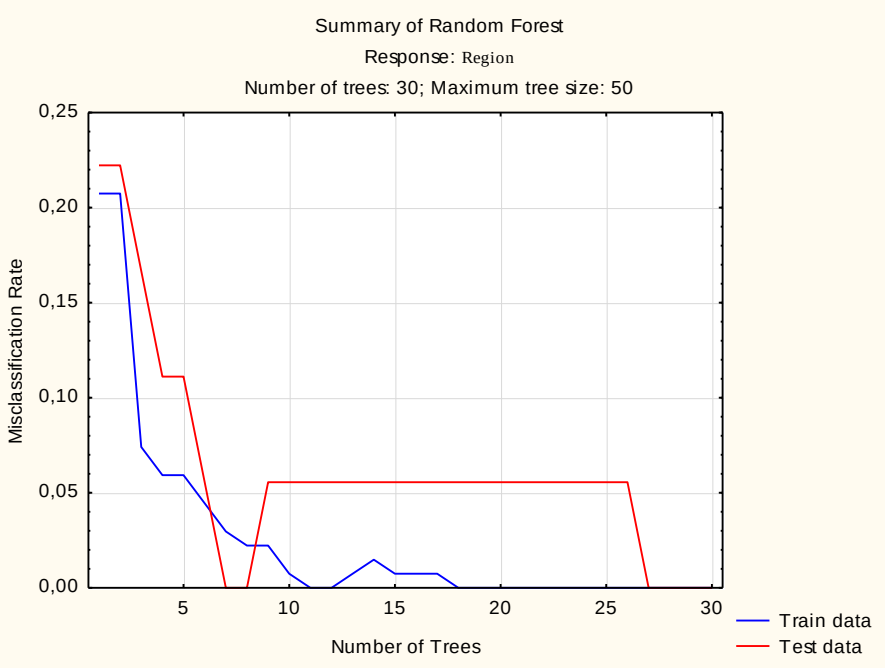

Taman
Anapa
South foothill
Black Sea
График дерева Region
Число не-конечных узлов: 8, Число конечных узлов: 9
N дерева : 1
D=1 N=51
Taman
Mg
<= 86327,602719
D=2 N=36
Taman
> 86327,602719
D=3 N=15
Taman
Al
<= 1531,718729
D=4 N=25
Taman
> 1531,718729
D=5 N=11
South foothill
Li
Cu
<= 22,599567
D=6 N=8
Black Sea
> 22,599567
D=7 N=17
Taman
<= 175,739613
D=12 N=6
South foothill
> 175,739613
D=13 N=5
Black Sea
Ni
Al
<= 19,456167
D=8 N=4
Black Sea
> 19,456167
D=9 N=4
Anapa
<= 1821,721462
D=14 N=1
Anapa
> 1821,721462
D=15 N=4
Black Sea
Cu
Fe
<= 348,111454
D=10 N=2
South foothill
> 348,111454
D=11 N=2
Anapa
<= 4992,523965
D=16 N=1
Taman
> 4992,523965
D=17 N=3
Black Sea

	Матрица классификации (White wines) Отклик: Region Тестовая выборка; Число деревьев: 32			
	Класс Предск. Taman	Класс Предск. Anapa	Класс Предск. South foothill	Класс Предск. Black Sea
Наблюд. Taman	19,00000			
Наблюд. Anapa		4,000000		
Наблюд. South foothill			9,000000	
Наблюд. Black Sea				12,00000

	Матрица классификации (White wines) Отклик: Region Обучающая выборка; Число деревьев: 32			
	Класс Предск. Taman	Класс Предск. Anapa	Класс Предск. South foothill	Класс Предск. Black Sea
Наблюд. Taman	54,00000			
Наблюд. Anapa		14,00000		
Наблюд. South foothill			21,00000	
Наблюд. Black Sea				20,00000

К сожалению при этих установках при включенной тестовой выборке не достигается точность в 100% на тестовой выборке – остается 1 ошибочная классификация. Выйти на 100% удалось при установках, представленных на следующем слайде





	Classification matrix (White wines) Response: Region Test set sample; Number of trees: 30			
	Class Predicted Taman	Class Predicted Anapa	Class Predicted South foothill	Class Predicted Black Sea
Observed Taman	6,000000			
Observed Anapa		3,000000		
Observed South foothill			5,000000	
Observed Black Sea				4,000000

	Classification matrix (White wines) Response: Region Training set sample; Number of trees: 30			
	Class Predicted Taman	Class Predicted Anapa	Class Predicted South foothill	Class Predicted Black Sea
Observed Taman	67,00000			
Observed Anapa		15,00000		
Observed South foothill			25,00000	
Observed Black Sea				28,00000

Если перейти на вкладку Prediction и воспользоваться кнопкой Predicted values, программа построит таблицу с исходными, предсказанными лесом значениями отклика, а также с апостериорными вероятностями принадлежности объектов к каждому прогнозируемому классу. Наблюдение принадлежит к тому классу, которому соответствует наибольшая апостериорная вероятность. По этой таблице можно установить наблюдения с ошибочными классификациями.

Спрогн. значения (White wines)
Отклик: Region
Тестовая выборка; Число деревьев: 32

	Наблюд. значение	Предск. значение	Вероятность для Taman	Вероятность для Anapa	Вероятность для South foothill	Вероятность для Black Sea
4	Taman	Taman	0,875000	0,000000	0,093750	0,031250
8	Taman	Taman	0,937500	0,000000	0,031250	0,031250
12	Taman	Taman	0,812500	0,000000	0,062500	0,125000
16	Taman	Taman	0,875000	0,000000	0,062500	0,062500
30	Anapa	Anapa	0,031250	0,937500	0,031250	0,000000
32	Anapa	Anapa	0,000000	1,000000	0,000000	0,000000
35	Anapa	Anapa	0,031250	0,968750	0,000000	0,000000
39	South foothill	South foothill	0,187500	0,000000	0,718750	0,093750
44	Black Sea	Black Sea	0,156250	0,125000	0,125000	0,593750
45	Black Sea	Black Sea	0,156250	0,156250	0,187500	0,500000