Лекция 11. Кластерный анализ

Так как кластеризация имеет непосредственное отношение к задачам классификации, а именно является одной из задач классификационного анализа, рассмотрим ее реализацию нейронными сетями в Data mining. Главное назначение кластерного анализа – разбиение множества исследуемых объектов и признаков на однородные группы (кластеры) схожих объектов.

В отличие от классификации, где количество групп объектов фиксировано и заранее определено набором объектов, здесь ни группы и ни их количество заранее не определены и формируются в процессе работы системы исходя из определённой меры близости объектов. В первом случае классификацию называют обучением с учителем, во втором случае – обучением без учителя.

Большое достоинство кластерного анализа в том, что он дает возможность производить разбиение объектов не по одному параметру, а по ряду признаков. Кроме того, кластерный анализ в отличие от большинства математико-статистических методов не накладывает никаких ограничений на вид рассматриваемых объектов и позволяет исследовать множество исходных данных практически произвольной природы [4].

В отличие от модуля Cluster Analysis из меню Statistics пакета STATISTICA метод, реализованный в Automated Neural Networks – искусственная нейронная сеть Кохонена или самоорганизующаяся карта признаков [9], позволяет осуществлять кластеризацию объектов по количественным и **категориальным** признакам.

Искусственная нейронная сеть Кохонена [1] была предложена финским исследователем Тойво Кохоненом в начале 1980-х годов. Она представляет собой двухслойную сеть (рис.5.2.1). Каждый нейрон первого – распределительного слоя *X* соединен со всеми нейронами второго – выходного слоя *Y*. Слои расположены в виде двухмерной решетки. Нейроны первого слоя ассоциируются с параметрами объектов кластеризации, нейроны выходного слоя, ассоциируясь с кластерами, называются кластерными элементами, их число определят максимальное количество групп, на которые система может разделить входные данные. Увеличивая количество нейронов второго слоя можно увеличивать детализацию результатов процесса кластеризации.

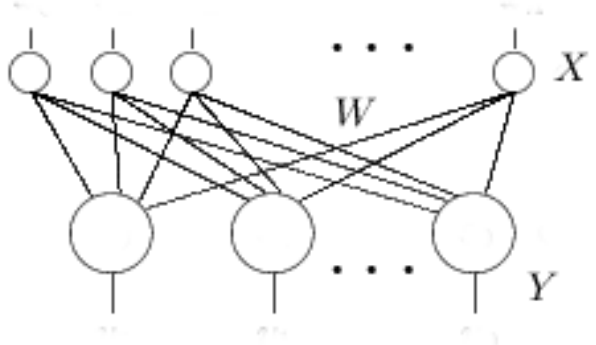


Рис.5.2.1.

Система работает по принципу соревнования [10] – нейроны второго слоя соревнуются друг с другом за право наилучшим образом сочетаться с входным вектором сигналов, побеждает тот нейрон, чей вектор весов ближе всего к вектору входного нейрона. Меру близости двух векторов можно оценить квадратом расстояния Евклида. Таким образом, каждый входной вектор соотносится к некоторому кластеру. На каждом шаге обучения из исходного набора данных случайно выбирается один вектор. Затем производится поиск нейрона выходного слоя, для которого расстояние между его вектором весов и входным вектором минимально. **По определённому правилу производится корректировка весов для нейрона-победителя и нейронов из его окрестности, которая задаётся соответствующей функцией окрестности**.

В качестве функции окрестности может использоваться функция Гаусса – плотность нормального распределения, или плотность равномерного распределения. Радиус окрестности должен уменьшаться с увеличением параметра времени обучения.

Применяются следующие критерии остановки процесса обучения:

– количество полных циклов обучения ограничено константой, например, количество циклов равно количеству элементов во входном множестве;

– выход сети стабилизируется, т.е. входные вектора не переходят между кластерными элементами;

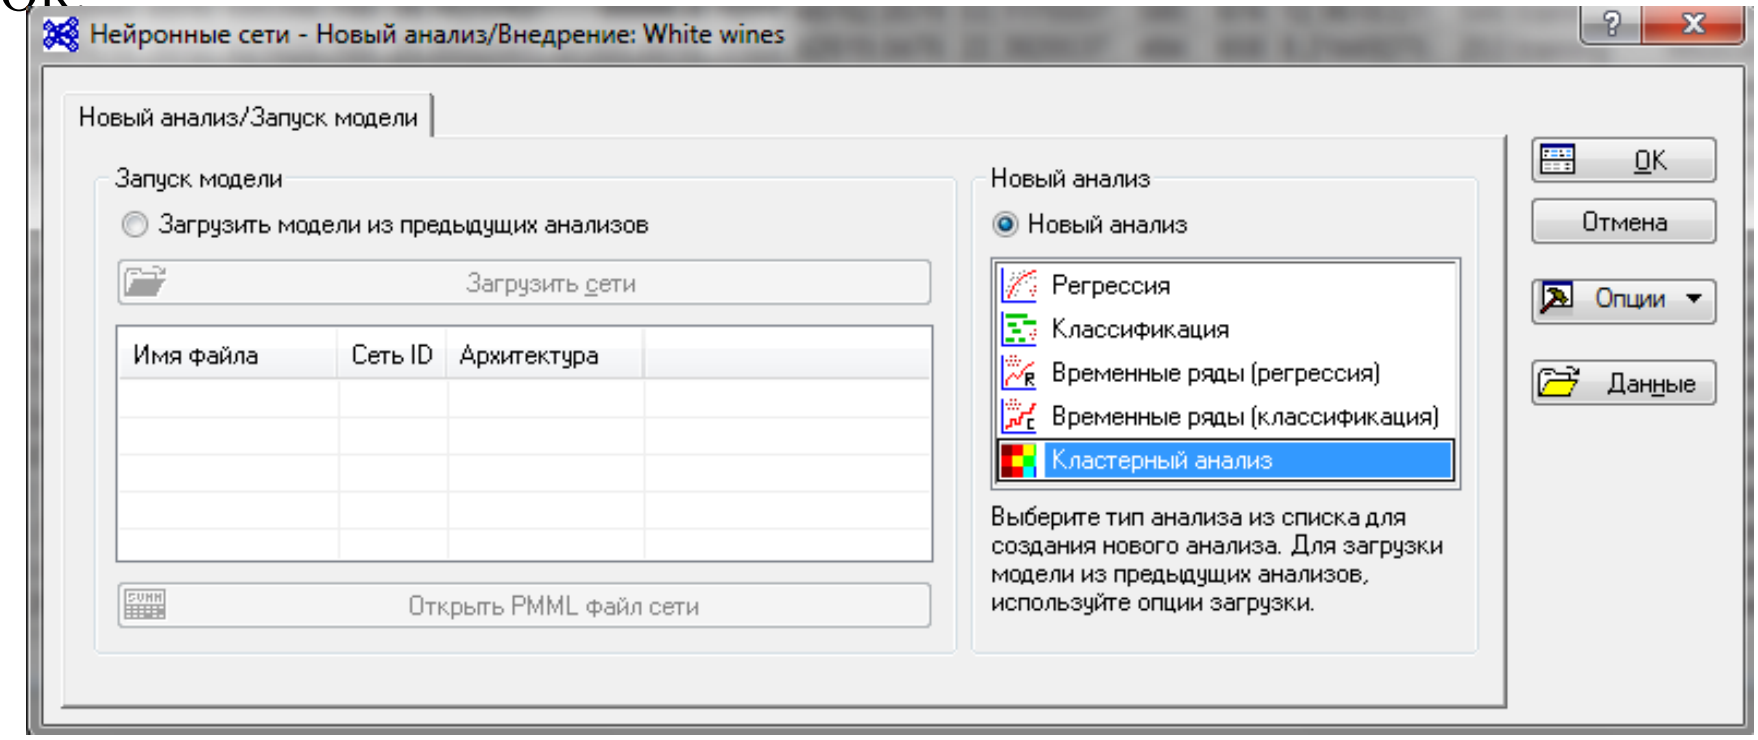
– изменения весов становятся незначительными, не больше заданного уровня.

Функция оценки Q качества работы кластеризатора нейронной сети Кохонена имеет вид:

$$Q = c \cdot d_i / d_o, \text{ где}$$

c – количество кластеров; d_i – среднее внутрикластерное расстояние; d_o – среднее межкластерное расстояние. Поэтому, чем меньше значение Q, т.е. чем ближе к 0, тем качество проведенной кластеризации выше.

Для инициирования процедуры кластеризации в стартовом окне модуля SANN (Нейронные сети) следует высветить Cluster analysis и щелкнуть по ОК.



В появившемся стартовом окне диалога на вкладке быстрый нажать на кнопку Variable (Переменные), выделить переменные и диалог примет вид, представленный на рис.5.2.3

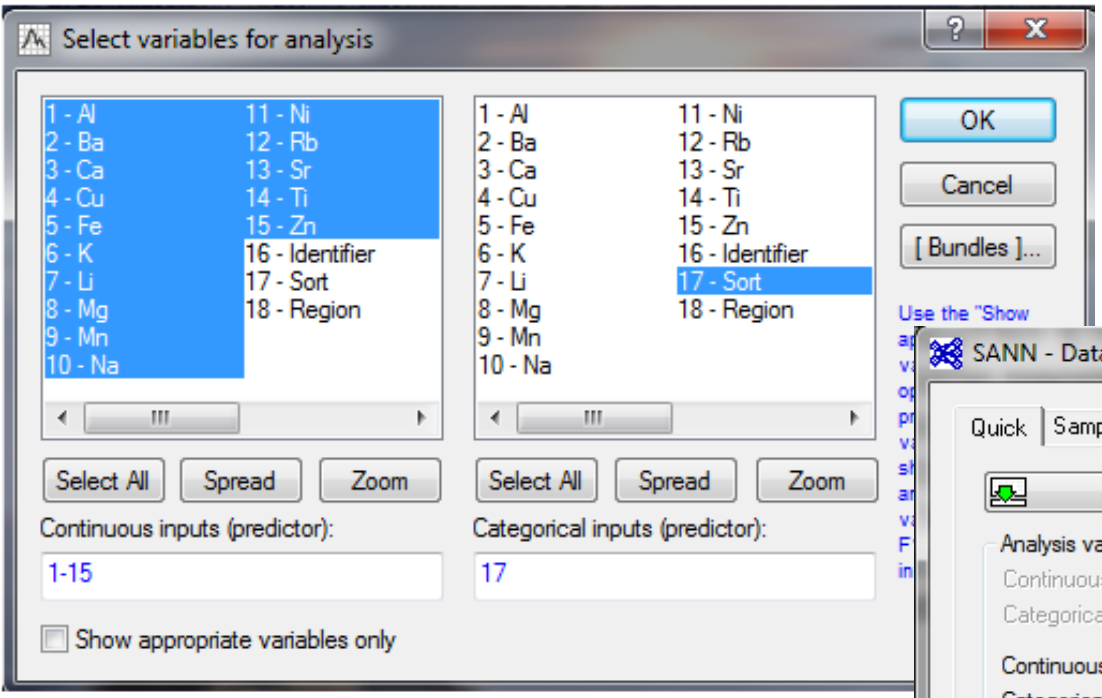


Рис.5.2.2

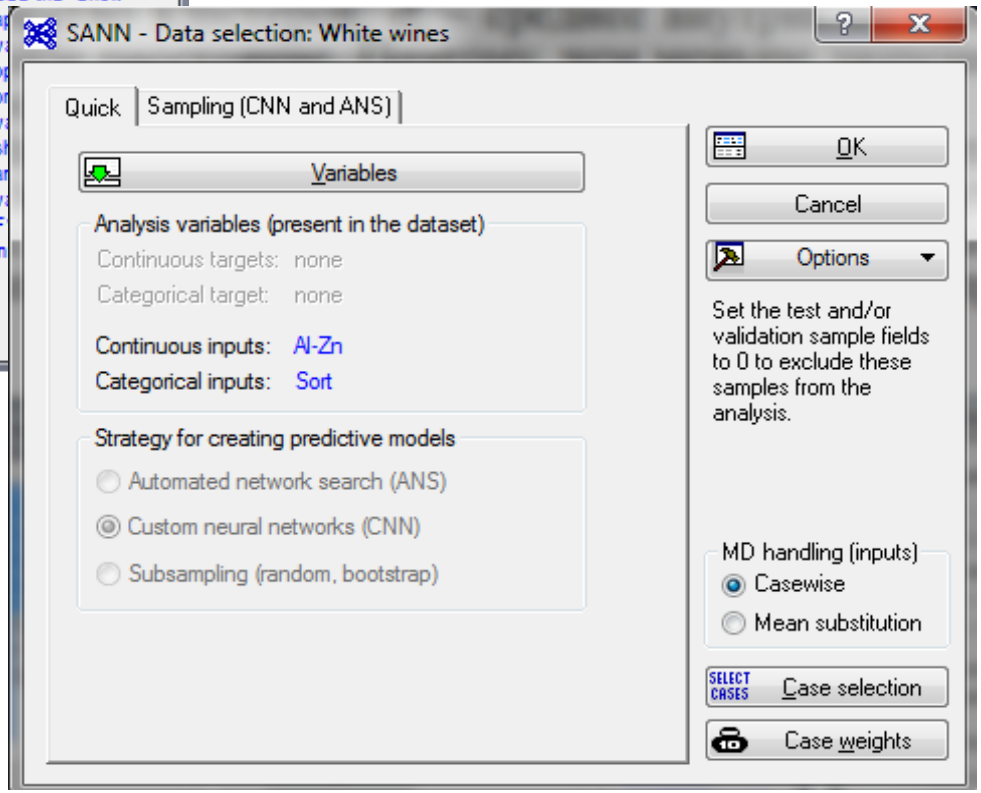
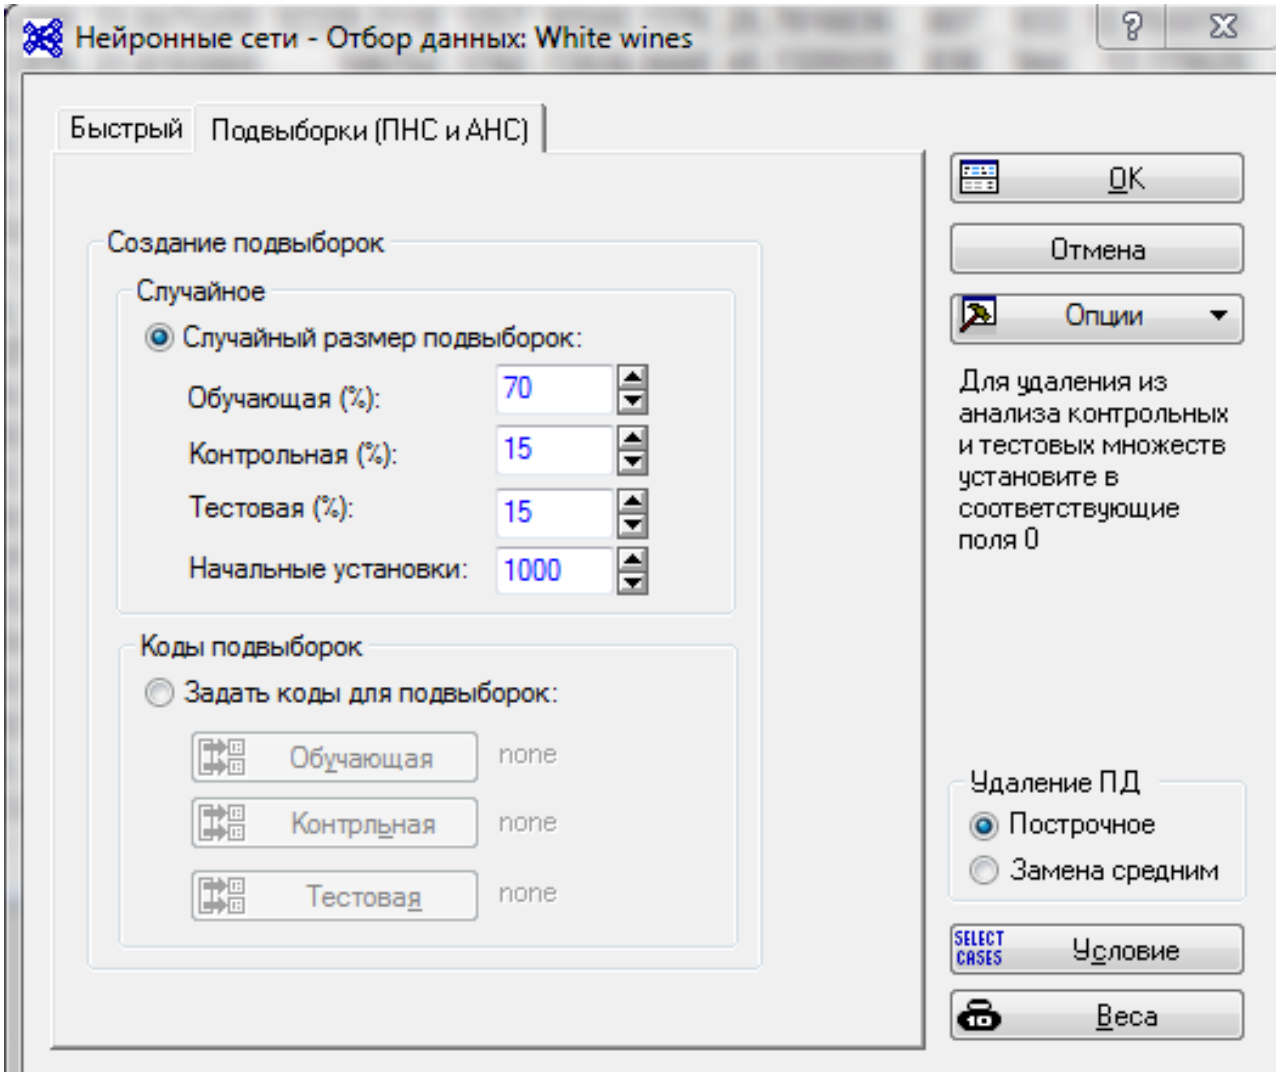


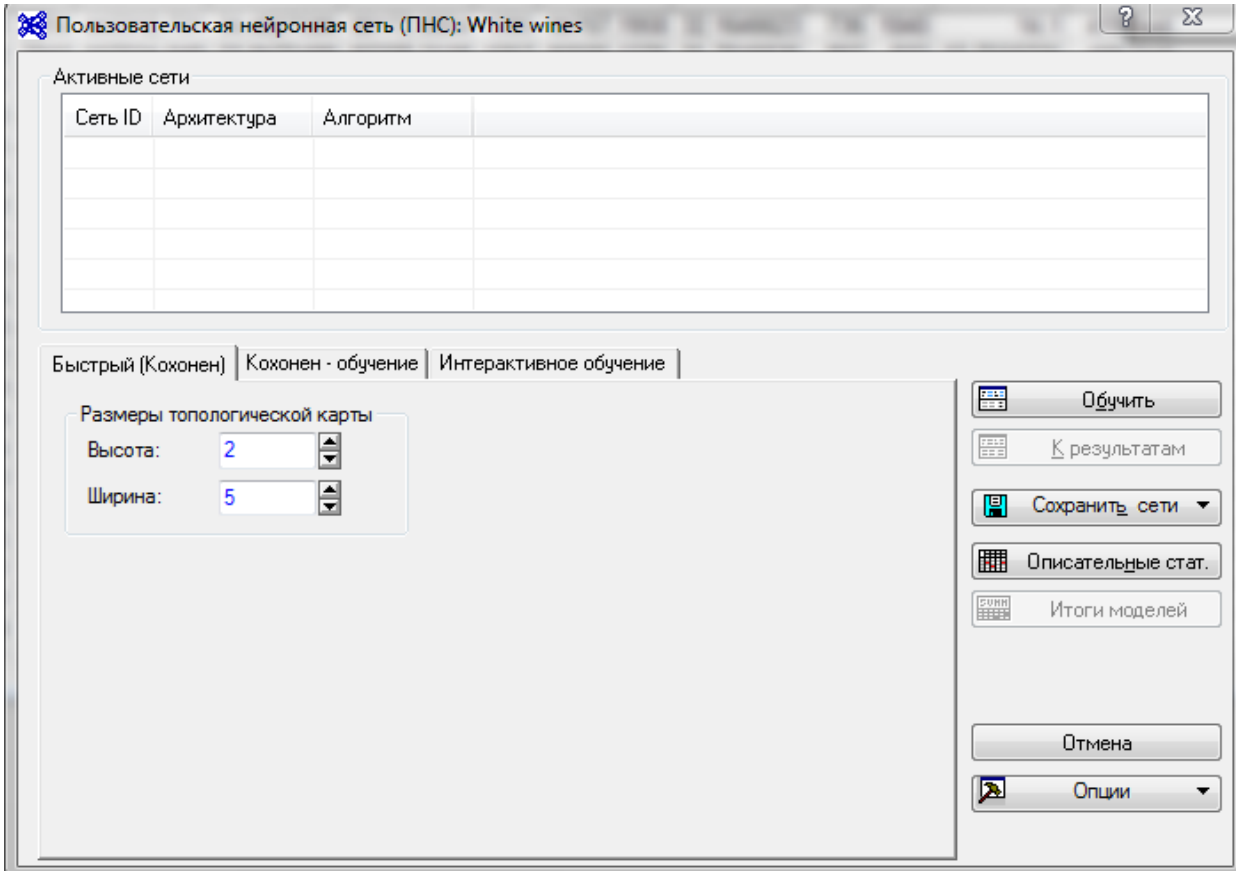
Рис.5.2.3

Вкладку подвыборки оставляем без изменения.



Если щелкнуть по ОК, откроется диалоговое окно SANN - Custom Neural Network на вкладке Quick (Kohonen) (рис.5.2.4).

Вкладка обеспечивает доступ пользователя к размерам (Dimensions) топологической карты – выходного слоя сети, которая представлена в виде прямоугольной решетки высотой по умолчанию – Topological height = 2, и шириной – Topological width = 5. Произведение высоты и ширины (2 x 5 = 10) регламентирует максимально возможное количество выделенных кластеров.



На следующей вкладке Kohonen Training представлены параметры обучения сети (рис.5.2.5). В рамке Training пользователь может указать параметры для алгоритма обучения Кохонена:

– Training cycles (циклы обучения) определяет количество используемых сетью тренировочных циклов, по умолчанию назначено 1000;

– Learning rates (скорость обучения) изменяется линейно от первого до последнего тренировочного цикла. Предусмотрено назначение начального (Start) и конечного значения (End), которые по умолчанию составляют: Start = 0,1; End = 0,02;

– Neighborhoods (окрестность) задается радиусом окружности с центром выигравшего нейрона. По умолчанию уменьшается от 3 до 0.

Скорость обучения нейронной сети (Learning Rate) — это ключевой параметр, который определяет размер шага при корректировке весов модели во время обучения, контролируя, насколько сильно сеть «реагирует» на ошибку. Высокая скорость обучения ускоряет процесс, но может пропустить минимум функции потерь; низкая скорость обеспечивает точность, но замедляет обучение и может привести к застреванию

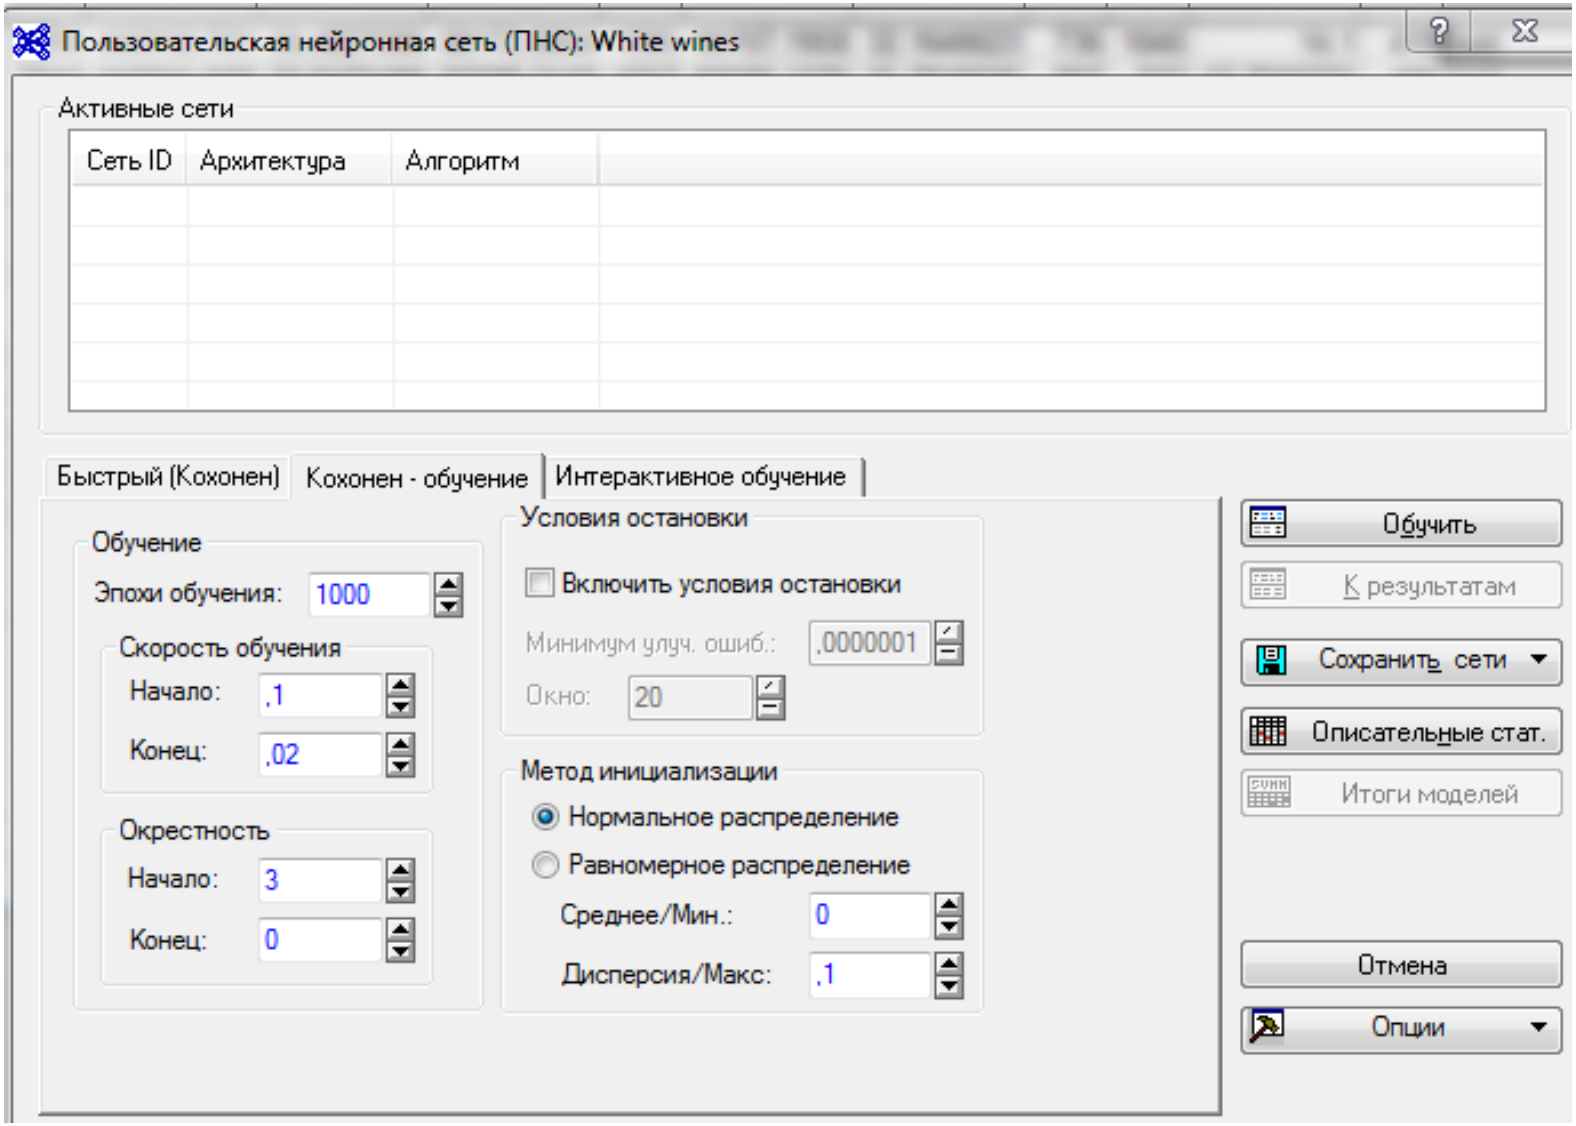

Пользовательская нейронная сеть (ПНС): White wines
Активные сети
Сеть ID
Архитектура
Алгоритм
Быстрый (Кохонен)
Кохонен - обучение
Интерактивное обучение
Обучение
Эпохи обучения:
1000
Скорость обучения
Начало:
,1
Конец:
,02
Окрестность
Начало:
3
Конец:
0
Условия остановки
Включить условия остановки
Минимум улуч. ошиб.:
,0000001
Окно:
20
Метод инициализации
Нормальное распределение
Равномерное распределение
Среднее/Мин.:
0
Дисперсия/Макс:
,1
Обучить
К результатам
Сохранить сети
Описательные стат.
Итоги моделей
Отмена
Опции

Рис.5.2.5

В рамке Stopping conditions (Условия остановки) можно воспользоваться ранней остановкой обучения сети. Если установить флажок на Enable stopping conditions (Включить условия остановки), то ранняя остановка будет применена, когда алгоритм обучения выполнит одно из двух условий:

1. Change in error (изменение по ошибке) – обучение сети завершится, если среднее улучшение сетевой ошибки за указанное количество циклов обучения в Окне (Window) будет меньше, чем значение изменения ошибки, указанное в поле Change in error = 0,0000001(по умолчанию);

2. В Window указывается количество циклов обучения, в течение которых среднее улучшение сетевой ошибки должно быть меньше указанного изменения в ошибке. По умолчанию = 20. Когда не выбрана ни одна тестовая выборка SANN по умолчанию использует обучающий набор для ранней остановки.

Для получения начальных значений весов выходных нейронов рамка Network randomization (Сетевая рандомизация – Метод инициализации) предлагает сделать выбор функции окрестности 2 законов распределения – Gaussian randomization (рандомизация по Гауссу), или Uniform randomization (равномерная рандомизация). После выбора распределения пользователю нужно указать параметры распределения: для нормального распределения – среднее и стандартное отклонение, равномерного – минимальное и максимальное значение. По умолчанию указано нормальное распределение.

Вкладка Real time training graph (Интерактивное обучение) (рис.5.2.6) предусмотрена для построения графика обучения сети в реальном времени, а также вывода ошибки обучения и тестирования. Для его реализации следует установить флажок на Отобразить график обучения для: и выбрать то, что мы хотим отобразить на графике, можно одновременно указать и ошибку на обучающей выборке и ошибку на контрольной выборке

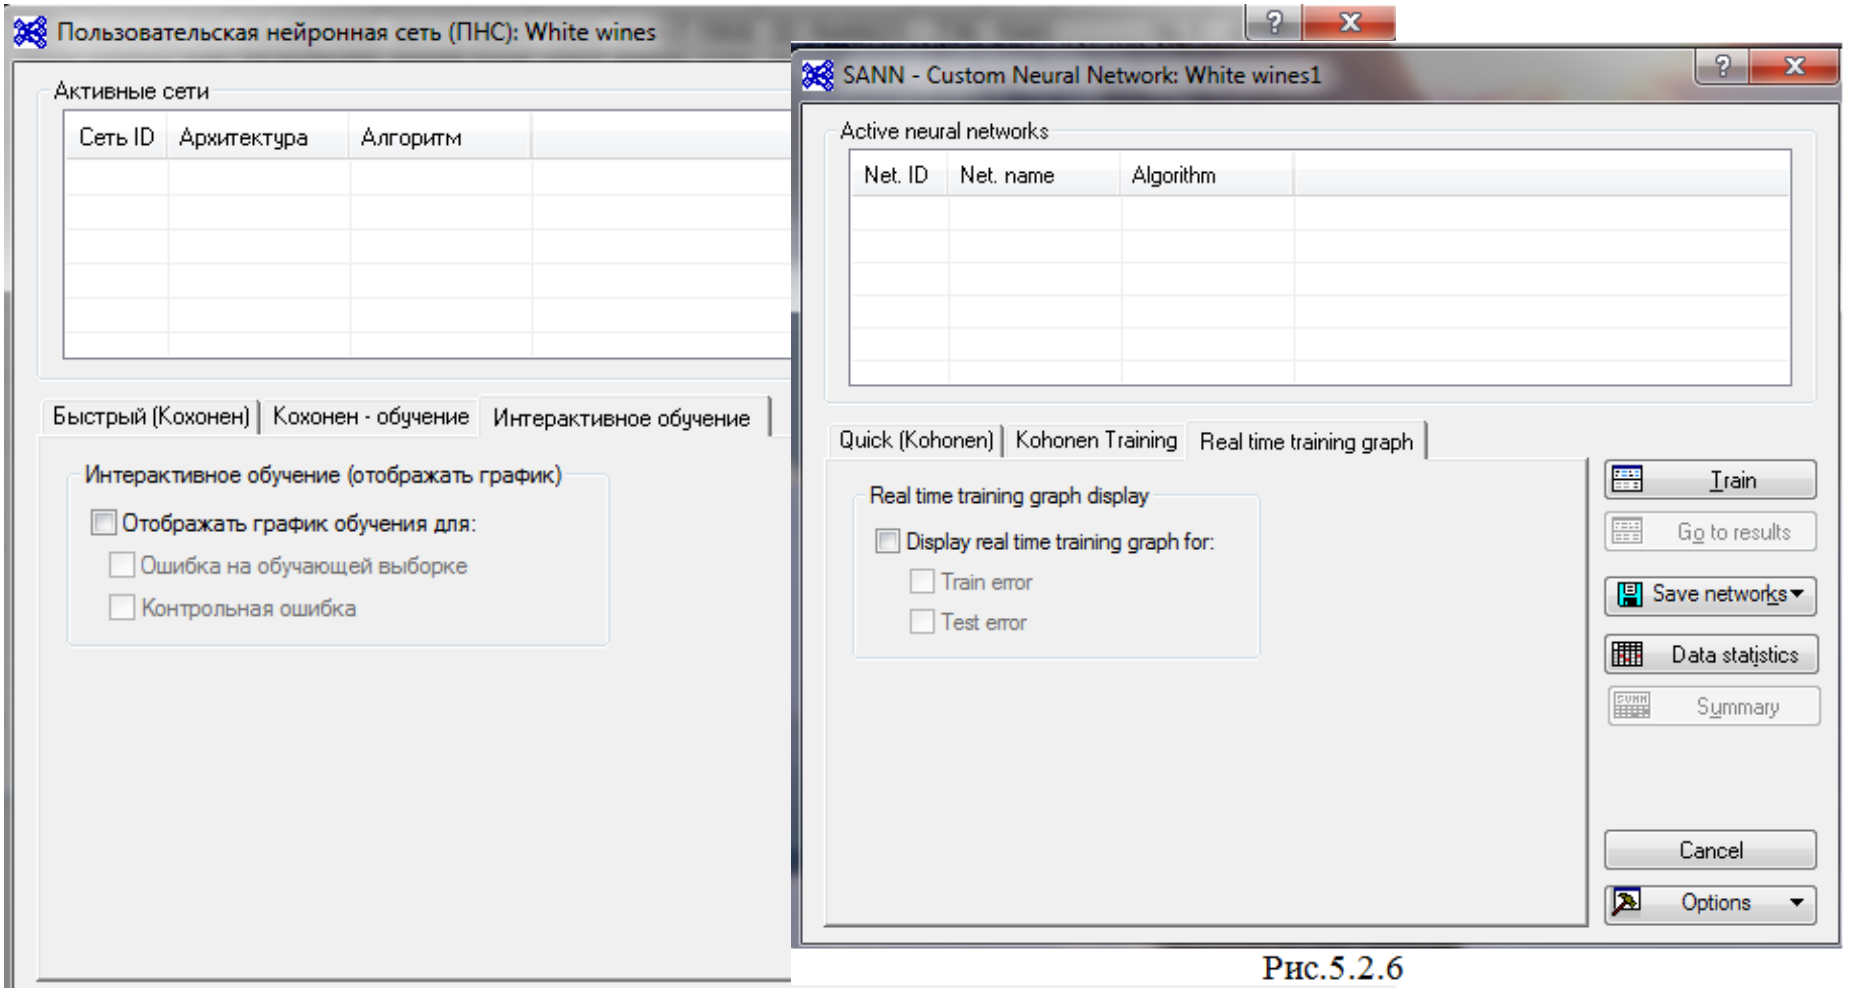


Рис.5.2.6

Если нажать на кнопку Train (Обучить), появится окно SANN – Results (рис.5.2.7) с результатами кластеризации. Рассмотрим сначала функционал вкладки Predictions (Kohonen). В рамке Predictions spreadsheet обозначены параметры сети для дополнительного включения в таблицу прогнозов:

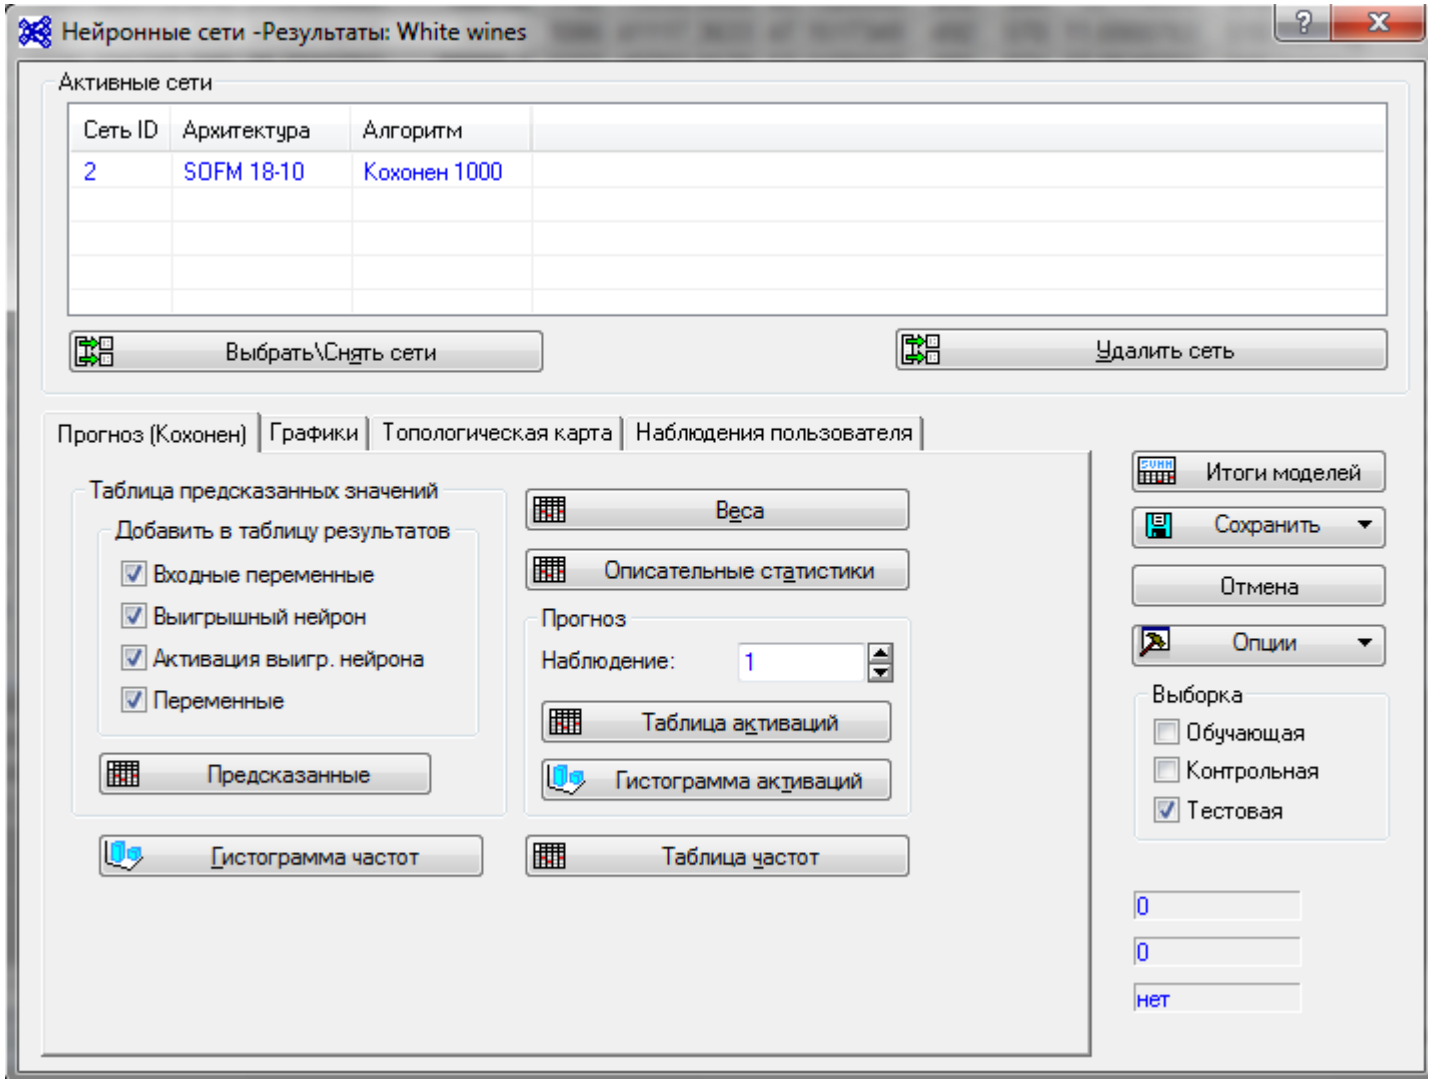


Рис.5.2.7

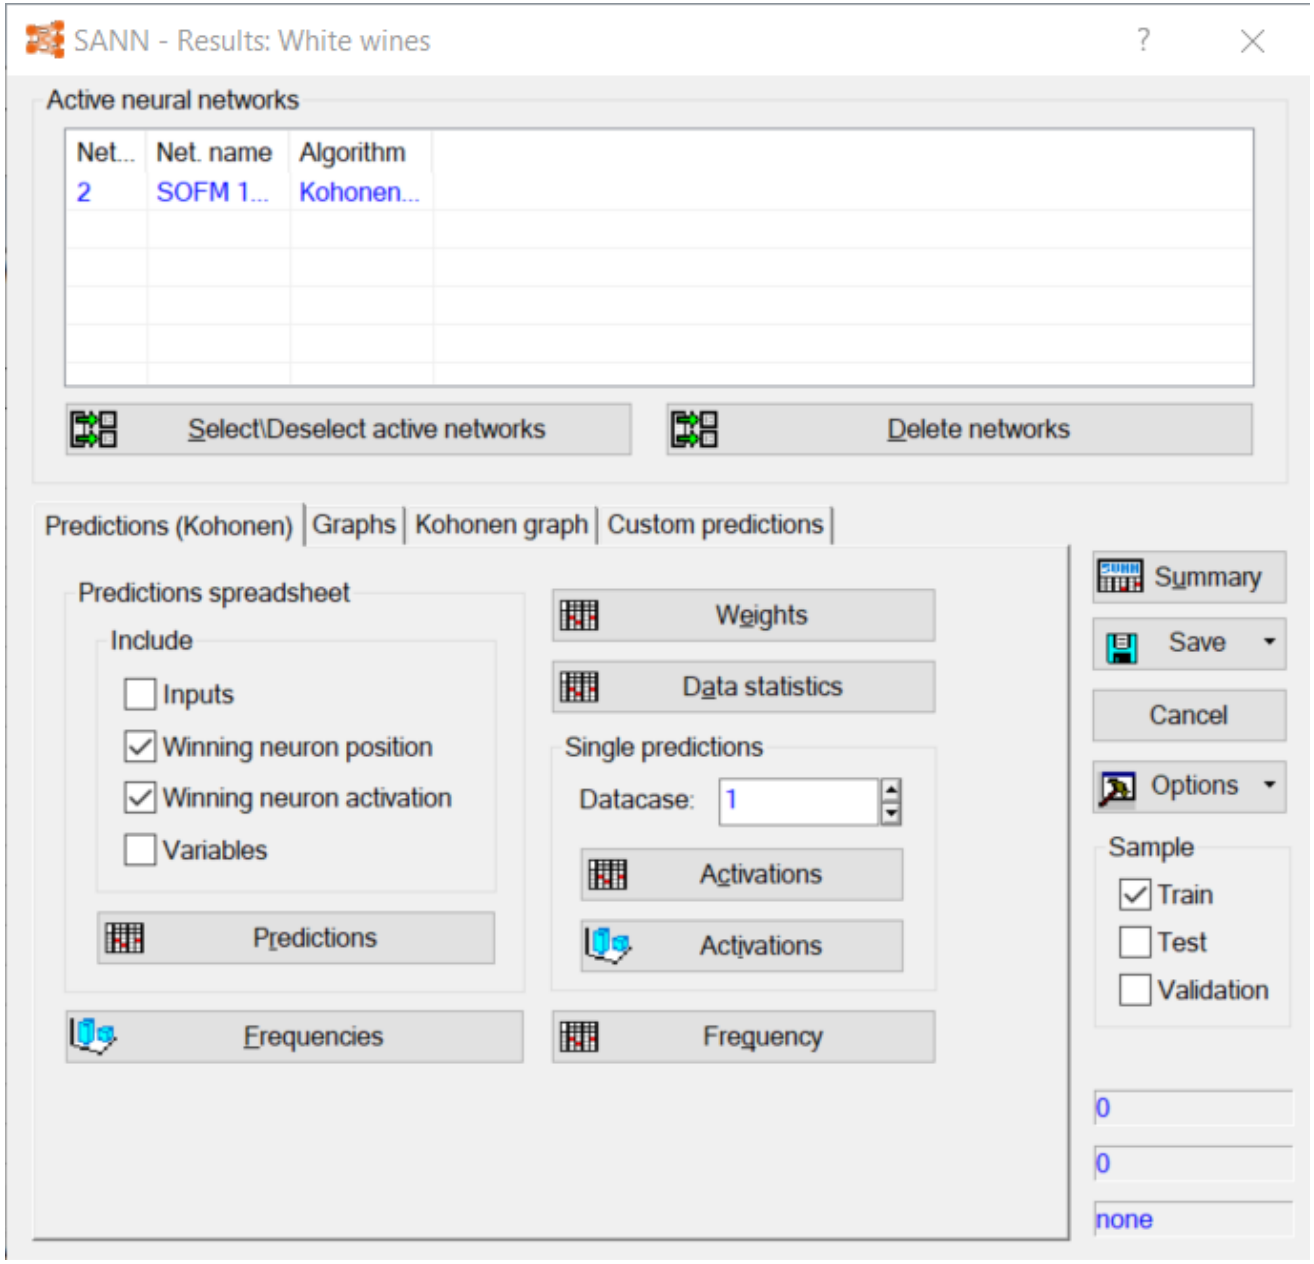

SANN - Results: White wines
Active neural networks
Net...
Net. name
Algorithm
2
SOFM 1...
Kohonen...
Select\Deselect active networks
Delete networks
Predictions (Kohonen)
Graphs
Kohonen graph
Custom predictions
Predictions spreadsheet
Include
Inputs
Winning neuron position
Winning neuron activation
Variables
Predictions
Frequencies
Weights
Data statistics
Single predictions
Datacase:
1
Activations
Activations
Frequency
Summary
Save
Cancel
Options
Sample
Train
Test
Validation
0
0
none

Рис.5.2.7

– Inputs – входные переменные;

– Winning neuron position – выигрышный нейрон;

– Winning neuron activation – активация выигрышного нейронов;

– Variables – выделенные переменные из набора данных. После нажатия на кнопку Predictions (Предсказанные), когда этот флажок установлен, отобразится диалоговое окно выбора переменных, в котором можно указать дополнительные переменные для включения в электронную таблицу. Этот флажок активен, только если в наборе данных есть переменные, которые не использовались в анализе, высветим, например, Region (рис.5.2.8).

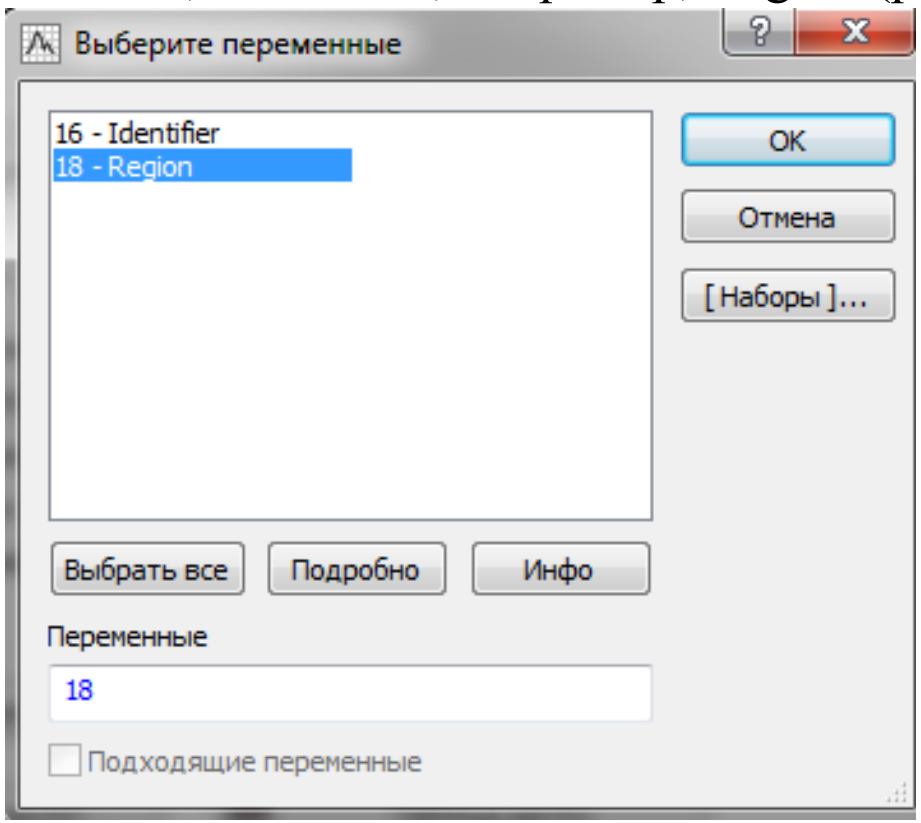


Рис.5.2.8

Если установить флажки на все опции в рамке Добавить в таблицу результатов и нажать на кнопку Predictions, отобразится таблица прогнозов для каждой активной сети, прописанной в верхней части окна в поле Active neural networks, в нашем случае сети Кохонена с идентификатором SDFM 18-10. В таблице удалены столбцы со значениями концентраций микроэлементов, т.е. 15 столбцов. Прогнозы отображаются для выборки, обозначенной в рамке Sample (Test).

В столбце Case name приведены номера образцов вин, которые попали в тестовую выборку, в столбце Neuron ID указаны номера нейронов выходного слоя, в столбце Position – координаты (позиции) образцов вин в топологической карте, в столбце Activations – выигрышная (наименьшая) активация нейрона.

Смысл столбца Position станет более понятен, если перейти на вкладку Kohonen graph (рис.5.2.9), на которой представлена топологическая карта для тестовой выборки.

В таблице представлены наблюдения контрольной выборки для русифицированной программы

Таблица 5.2.1. Таблица прогноза сетью SOFM 18-10 для тестовой выбор

Case name	Predictions spreadsheet (White wines1), Network: 1.SOFM 18-10, Samples: Test				
	Sort Input	Neuron ID	Position	Activations	Region
2	Muscat	10,00000	(2, 5)	0,667575	Taman
5	Muscat	10,00000	(2, 5)	0,407185	Taman
17	Muscat	10,00000	(2, 5)	0,291832	Taman
23	Muscat	10,00000	(2, 5)	0,263333	Taman
25	Muscat	10,00000	(2, 5)	0,859999	Taman
26	Muscat	5,00000	(1, 5)	0,636993	Anapa
29	Muscat	5,00000	(1, 5)	0,475478	Anapa
40	Muscat	10,00000	(2, 5)	0,532801	South foothill
44	Muscat	5,00000	(1, 5)	1,048585	Black Sea
52	Riesling	1,00000	(1, 1)	0,462961	Taman
63	Riesling	1,00000	(1, 1)	1,129618	Taman
64	Riesling	1,00000	(1, 1)	1,214874	Taman
77	Riesling	6,00000	(2, 1)	0,852049	South foothill
84	Riesling	1,00000	(1, 1)	0,357607	Black Sea
97	Riesling	6,00000	(2, 1)	0,440781	Black Sea
106	Chardonnay	8,00000	(2, 3)	0,862477	Taman
108	Chardonnay	7,00000	(2, 2)	0,488246	Taman
113	Chardonnay	8,00000	(2, 3)	0,955667	Taman
122	Chardonnay	3,00000	(1, 3)	0,333323	Taman
136	Chardonnay	8,00000	(2, 3)	0,523075	South foothill
147	Chardonnay	2,00000	(1, 2)	0,329455	Black Sea
150	Chardonnay	7,00000	(2, 2)	0,699745	Black Sea

Каждая позиция, указанная в табл.5.2.1 соответствует прямоугольнику (ячейке) топологической карты на вкладке Kohonen graph – первая цифра в позиции обозначает горизонтальный ряд, в котором расположена ячейка, вторая цифра – вертикальный ряд. Каждая ячейка является условным геометрическим представлением области расположения выделенных кластеров объектов. Пронумеруем ячейки слева направо, сверху вниз: 1, 2, …,10.

К сожалению, не все образцы вин хорошо визуализируются на топологической карте – в ячейках 5 (1, 5) и 8 (2, 4) за счет окраски не видны элементы кластеров, в **ячейках 4, 9 нет кластеров**. Поставим в соответствие к выделенным кластерам номера, соответствующие номерам ячеек, в которых они расположены. Таким образом, нейронная сеть выделила 8 кластеров с номерами 1, 2, 3, 5, 6, 7, 8, 10. Из табл.5.2.1 видно, что кластеры имеют определенную привязку к сорту вина и региону произрастания винограда. Так в кластер 1 попали 3 образца сорта Рислинг Таманской зоны, в кластер 10 – 5 образцов Муската также Таманской зоны. Возможно, если бы в качестве категориального предиктора не был указан сорт вина, количество выделенных сетью кластеров было бы меньше.

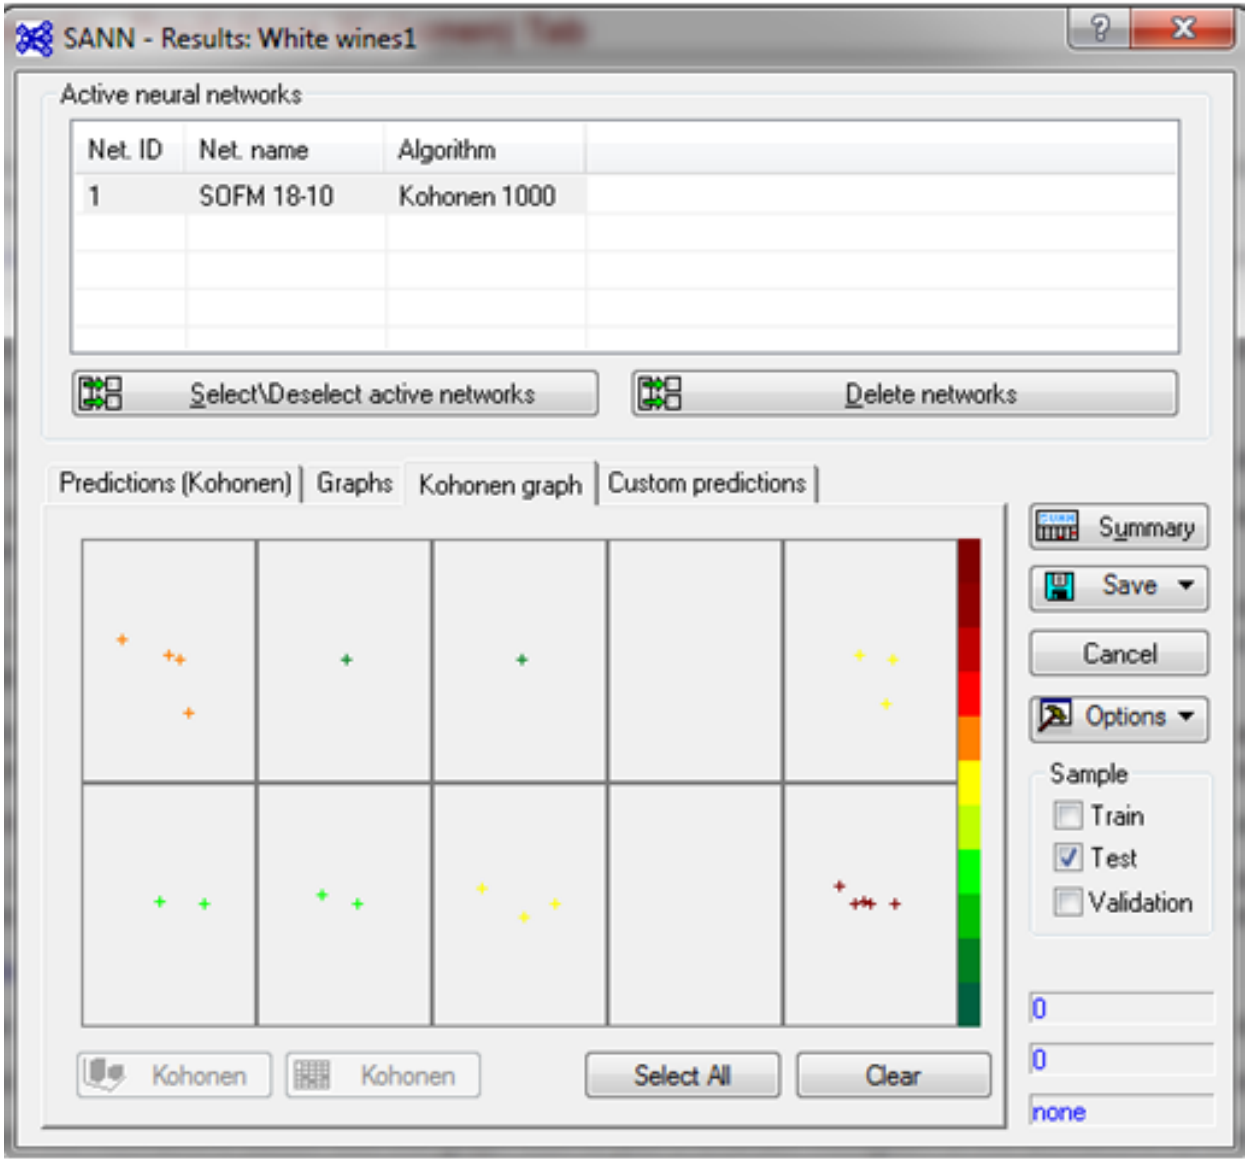

SANN - Results: White wines1
Active neural networks
Net. ID
Net. name
Algorithm
1
SOFM 18-10
Kohonen 1000
Select\Deselect active networks
Delete networks
Predictions (Kohonen)
Graphs
Kohonen graph
Custom predictions
Summary
Save
Cancel
Options
Sample
Train
Test
Validation
Kohonen
Kohonen
Select All
Clear
0
0
none

Рис.5.2.9

На рис.5.2.10, 5.2.11 приведены топологические карты для обучающей и тестовой выборки и всех трех выборок вместе.

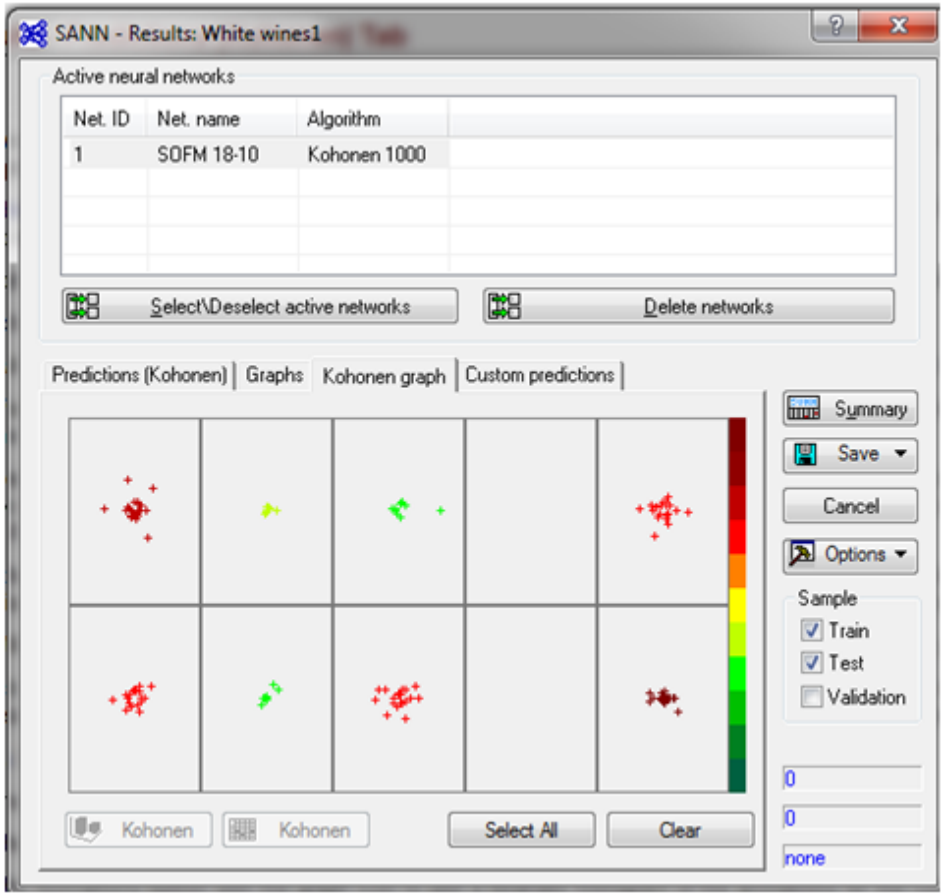


Рис.5.2.10

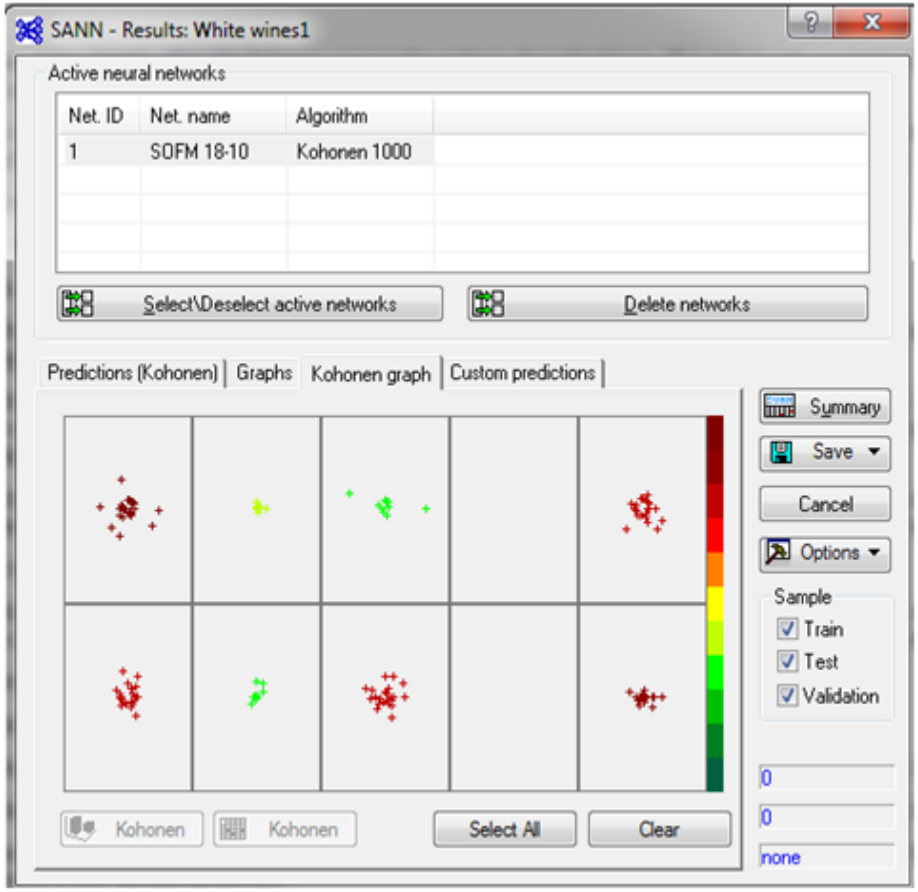


Рис.5.2.11

Кнопка Frequencies (Таблица частот) инициирует построение трехмерного графика частот количества образцов в 10 ячейках топологической карты. На рис.5.2.12 изображены частоты для тестовой выборки.

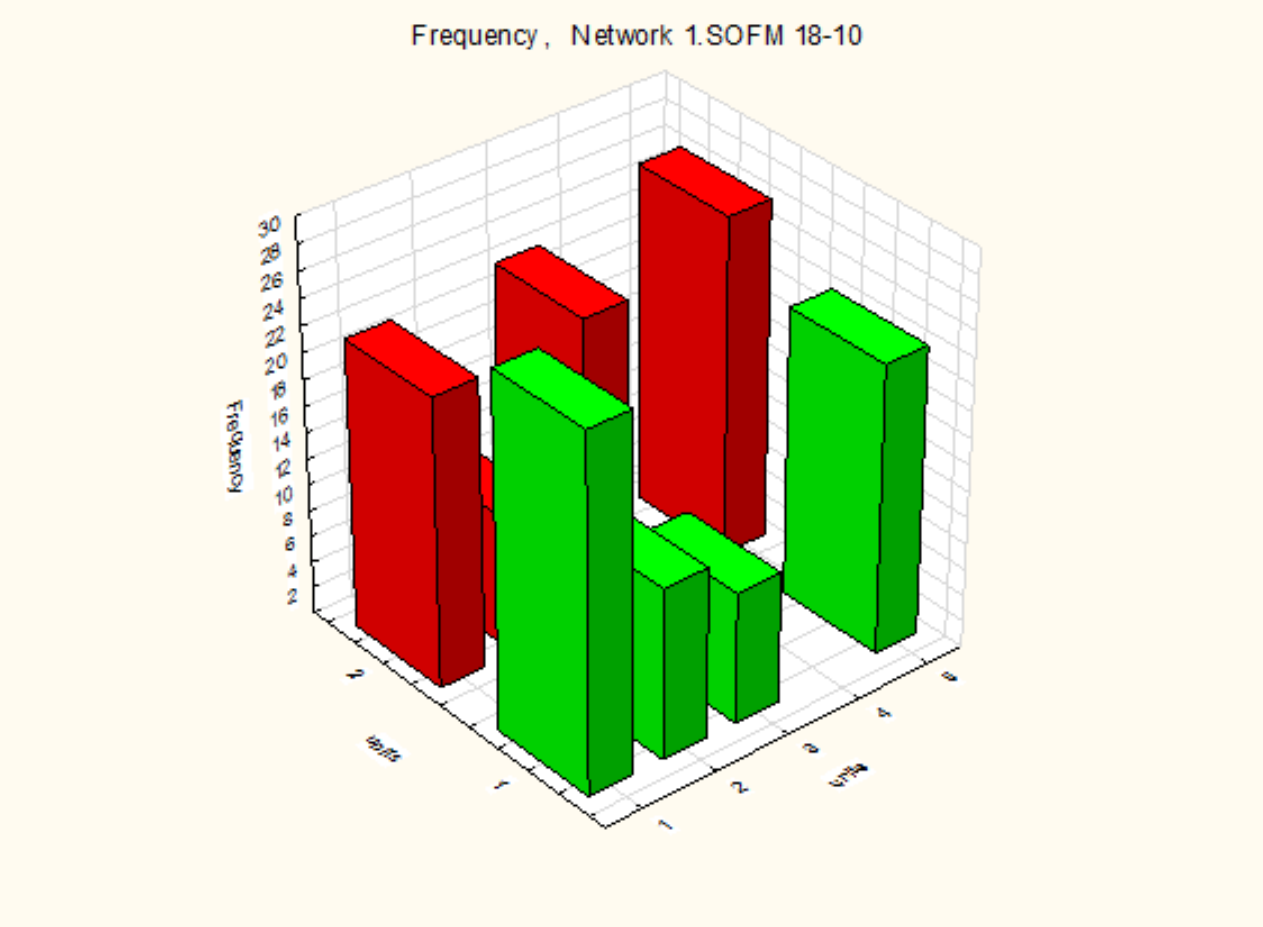


Рис.5.2.12

При помощи кнопки Weights (Веса) можно построить таблицу весов 10 нейронов (по каждому кластеру) для 15 непрерывных предикторов (концентраций металлов) и 3 значений категориального предиктора – сортов вин.

Кнопка Data statistics (Описательные статистики) предназначена для построения таблицы с основными описательными статистиками непрерывных предикторов на входе нейронной сети по выборкам, обозначенным в рамке Sample.

Рамка Single predictions (Прогноз) представляет пользователю доступ для просмотра активации нейронов для каждого объекта, номер которого указан в поле Datacase (Наблюдение) – по умолчанию указан номер первого объекта кластеризации.

Кнопка Activations со значком электронной таблицы (Таблица активаций) инспирирует создание таблицы результатов активаций 10 нейронов выходного слоя для выбранного объекта, в нашем случае выбран образец № 2 из первой строчки табл.5.2.1. Из табл.5.2.2 видно, что наименьшая активация достигается в ячейке (2, 5), поэтому образец № 2 при кластеризации отнесен к кластеру № 10.

Таблица 5.2.2. Активация нейронов образца №2

	Activations spreadsheet (White wines1) Network: 1.SOFM 18-10 Datacase: 2				
	1	2	3	4	5
1	1,515593	1,844265	1,775225	1,430023	0,827100
2	1,715184	1,579293	1,711438	1,430023	0,667575

Для визуализации активаций при помощи кнопки Activations (Гистограмма активаций) можно построить трехмерную гистограмму активаций образца № 2 (рис.5.2.13)

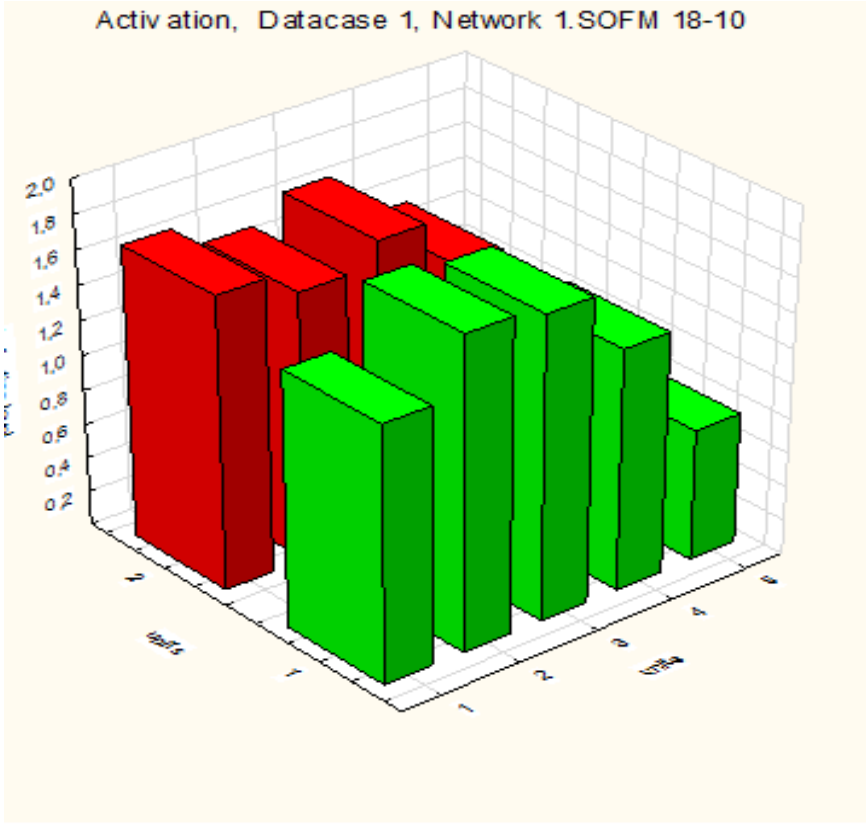


Рис.5.2.13

Если в рамке Sample установить флажки для каждой выборки – обучающей, тестовой, контрольной и щелкнуть по кнопке Frequency (Таблица частот) программа построит таблицу (табл.5.2.3) распределения частот всех 153 образцов по ячейкам топологической карты, т.е. по кластерам. Из таблицы видно, что наиболее многочисленный кластер 1 (1, 1) – 27 образцов, наименьшее количество образцов в кластерах 3 (1, 3) и 7 (2, 2) – по 10 образцов.

Если в диалоге на рис.5.2.7 щелкнуть по кнопке Summary в верхнем правом углу окна (Итоги моделей) программа построит таблицу с указанием значений функция оценки Q качества работы кластеризатора нейронной сети Кохонена для всех 3 выделенных выборок – обучающей, тестовой и контрольной (табл.5.2.4).

Видно, что наибольшая ошибка, равная 0,473 на тестовой выборке, наименьшая – 0,268 на обучающей выборке.

С увеличением размеров топологической карты, т.е. количества выделяемых кластеров, ошибки кластеризации имеют тенденцию к уменьшению.

Таблица 5.2.3. Распределение частот вин по кластерам

	Frequency spreadsheet (White wines1) Network: 1.SOFM 18-10 Samples: Train, Test, Validation				
	1	2	3	4	5
1	27	13	10	0	22
2	22	10	23	0	26

Таблица 5.2.4. Итоговая таблица кластеризации

	Summary of active networks (White wines1)					
	Index	Net. name	Training error	Test error	Validation error	Training algorithm
	1	SOFM 18-10	0,268218	0,473350	0,424020	Kohonen 1000